

Nazwa przedmiotu:

Bioinformatyka w proteomice

Wersja przedmiotu:

2025/26_2

Przygotował:

Igor Kaczmarczyk

Zmodyfikowała:

Agata Raczyńska

Kanały komunikacji:

- email: araczynska@pjawstk.edu.pl
- grupa na platformie Microsoft Teams:

[Kanał Studiów](#)

[Kanał Przedmiotu](#)

[Wykłady](#)

Katedra Bioinformatyki

Spis treści

Ogólne zasady obowiązujące na przedmiocie.....	5
Szczegółowe zasady obowiązujące na przedmiocie	6
BIOINFORMATYKA W PROTEOMICE	7
1. Definicja i zakres proteomiki. Krótki przegląd technik eksperymentalnych stosowanych w proteomice	7
1.1 Wstęp.....	7
1.2 Co to jest białko? Podstawowe parametry opisujące białka.....	9
1.3 Co to jest proteom? Definicja i zakres proteomiki.....	15
1.4 Krótki przegląd technik eksperymentalnych stosowanych w proteomice	17
2. Bioinformatyczne bazy danych białkowych	20
2.1 Wstęp.....	20
2.2 Klasyfikacja baz danych proteomicznych.....	20
3. Formaty danych surowych w proteomice. Oprogramowanie do przetwarzania danych surowych	24
3.1 Wprowadzenie.....	24
3.2 Formaty danych surowych z MS.....	24
3.3 Oprogramowanie do przetwarzania danych surowych	25
B. ThermoRawFileParser – lekka, szybka alternatywa do konwersji plików .RAW z instrumentów Thermo. – w pełni open-source, idealna do pipeline’ów w chmurze. – generuje pliki .mzML oraz pliki metadanych.	Błąd! Nie zdefiniowano zakładki.
3.4 Znaczenie standaryzacji	27
3.5 Przypomnienie – to będzie potrzebne na każdym kroku analiz białek	28
c. Identyfikacja białek w proteomice	31
4.1 Wstęp.....	31
4.2 Klasyczne podejście: spektrometria masowa	31
4.3 Problem inferencji białek	33
4.4 Nowe perspektywy: Cryo-EM i identyfikacja białek na podstawie struktury	34
4.5 Integracja danych i przyszłość identyfikacji	38
5. Metody kwantyfikacji białek w proteomice	40
5.1 Wstęp.....	40
5.2 Metody znakowane (label-based).....	40
Metoda działania	41
5.3 Metody nieznakowane (label-free).....	42
B. Bezwzględna kwantyfikacja	42
5.4 Inne techniki kwantyfikacji białek	43
5.5 Narzędzia bioinformatyczne wspierające kwantyfikację	44
6. Analiza danych potranslacyjnych modyfikacji białek (PTMs)	47

6.1 Wstęp.....	47
6.2 Wyzwania w analizie PTMs.....	47
6.3 Strategie analizy PTMs.....	48
→ Bioinformatyczna identyfikacja PTMs	48
6.4 Typowe rodzaje modyfikacji i ich analiza	49
Modyfikacje potranslacyjne są „umieszczane” na białkach przez inne enzymy, które rozpoznają określony motyw w sekwencji i strukturze modyfikowanego targetu. Znając dokładne mechanizmy molekularne działania enzymów modyfikujących białka potranslacyjnie, jesteśmy w stanie przewidzieć, w jakich regionach możemy spodziewać się określonej modyfikacji.	
6.5 Bazy danych PTMs.....	50
6.6 Znaczenie biologiczne analizy PTMs.....	51
7. Interakcje białkowe i sieci białkowe w proteomice	53
7.1 Wstęp.....	53
7.2 Rodzaje interakcji białkowych	53
7.3 Metody wykrywania interakcji białkowych	54
7.4 Sieci białkowe: tworzenie i analiza	55
7.5 Narzędzia i bazy danych.....	55
8. Metody analizy i predykcji struktury białek.....	58
8.1 Wprowadzenie.....	58
8.2 Organizacja strukturalna białek.....	58
8.3 Metody eksperymentalne rozszyfrowywania struktur białek.....	59
8.4 Metody bioinformatyczne – predykcja struktury białek	62
8.5 Analiza struktury białek	64
8.6 Źródła danych i bazy strukturalne	64
Podsumowanie	64
9. Zastosowanie algorytmów uczenia maszynowego w analizie danych proteomicznych..	67
9.1 Wprowadzenie	67
9.2 Przykłady zastosowań uczenia maszynowego w proteomice	68
9.3 Przyszłość i wyzwania	69
10. Wizualizacja danych proteomicznych.....	71
10.1 Wstęp.....	71
10.2 Podstawowe wykresy w analizie proteomicznej	71
10.3 Wizualizacja zmienności ewolucyjnej	74
11. Integracja danych proteomicznych z danymi NGS.....	80
11.1 Wstęp.....	80
11.2 Poziomy integracji danych – gen, transkrypt, białko	80
11.2 Przykłady zastosowań integracji NGS i proteomiki.....	81

11.3 Techniki i narzędzia integracyjne.....	81
11.4 Wyzwania integracji.....	82
11.5 Przyszłość integracji: multi-omics	83
W tym zadaniu porównamy ekspresję genu i białka TP53 w nowotworach piersi (TCGA + CPTAC). Sprawdzimy, czy poziom RNA (z danych RNA-Seq) dla genu TP53 koreluje z poziomem białka TP53 (z danych proteomicznych) w nowotworach piersi.	83
12. Kontynuacja nauki i rozwój umiejętności - przegląd zasobów online i możliwości dalszego kształcenia w tematyce przedmiotu.....	85
12.1 Wstęp.....	85
12.2 Kursy online i platformy edukacyjne	85
12.3 Interaktywne środowiska i szkoleniowe platformy bioinformatyczne.....	86
12.4 Praktyczne narzędzia i bazy danych z dokumentacją edukacyjną	86
12.4 Konferencje i warsztaty	87
12.5 Literatura i podręczniki	88



POLSKO-JAPOŃSKA
AKADEMIA TECHNIK
KOMPUTEROWYCH

Polsko-Japońska Akademia Technik Komputerowych

Ogólne zasady obowiązujące na przedmiocie

1. Warunkiem wystawienia oceny końcowej z przedmiotu jest uzyskanie **oceny pozytywnej** z testu końcowego, **zaliczenie rozwiązań przykładów obligatoryjnych do samodzielnego wykonania (łącznie 20 zadań)** oraz zaliczenie jednego z **projektów** opisanych na końcu niniejszego podręcznika.
2. Ocena końcowa z przedmiotu to ocena uzyskana z testu.
3. Zaliczenie zadań oraz projektu końcowego jest ekwiwalentem zaliczenia ćwiczeń w trybie stacjonarnym.
4. Projekt oceniany będzie na podstawie poprawności, kompletności, jakości rozwiązań oraz zgodności z opisanymi wymaganiami.
5. Test będzie miał postać minimum 20 pytań jednokrotnego wyboru, które zostaną udostępnione słuchaczowi na koniec przedmiotu. Prowadzący może zmienić formę egzaminu w uzasadnionych przypadkach.
6. Aby uzyskać ocenę pozytywną z testu, należy uzyskać co najmniej 50% poprawnych odpowiedzi.
7. W terminie podanym przez prowadzącego uczestnicy powinni przygotować rozwiązania przykładów do samodzielnego wykonania oraz projekt i przesłać je w formacie .pdf na adres e-mail prowadzącego.
8. Brak dostarczenia projektu w wyznaczonym terminie skutkuje niezaliczeniem przedmiotu, chyba że prowadzący zdecyduje o przedłużeniu terminu w uzasadnionych przypadkach.
9. Uzyskanie oceny negatywnej z testu skutkuje koniecznością przystąpienia do testu w kolejnym terminie. Ponowne uzyskanie oceny negatywnej skutkuje koniecznością przystąpienia do testu w trzecim i ostatnim terminie. Uzyskanie oceny negatywnej w trzecim terminie skutkuje niezaliczeniem przedmiotu.

10. Uzyskanie oceny negatywnej z testu w I terminie skutkuje tym, że maksymalną oceną, którą można zdobyć w II terminie jest 3.0. Nieprzystąpienie do testu w I terminie oznacza, że maksymalną oceną, którą można zdobyć w kolejnym terminie jest 3.0.
11. Wszystkie prace muszą być wykonane samodzielnie. Wszelkie przypadki plagiatu będą skutkować niezaliczeniem przedmiotu.
12. Wszystkie przedmioty należy zaliczyć w semestrze, w którym się odbywają.

Szczegółowe zasady obowiązujące na przedmiocie


1. Kanały komunikacji:
 - a. araczynska@pjawst.edu.pl,
 - b. MS Teams: jw., na pierwszej stronie.
2. Data rozpoczęcia przedmiotu: 16.11.2025 (udostępnienie materiałów PDF oraz materiałów video)
3. Data zakończenia przedmiotu: 20.12.2025 (należy przerobić cały materiał i dostarczyć rozwiązania zadań)
4. Czas na przesłanie projektu zaliczeniowego: do 30.12.2025
5. Okienko na wykonanie testu końcowego z przedmiotu:
 - a. I termin: 20.12.2025
 - b. II termin: 21.12.2025 – 07.02.2026

BIOINFORMATYKA W PROTEOMICE

1. Definicja i zakres proteomiki.

Krótki przegląd technik eksperymentalnych stosowanych w proteomice

1.1 Wstęp



„Life is an equilibrium state between synthesis and degradation of proteins”

~ Yoshinori Osumi, laureat Nagrody Nobla w dziedzinie fizjologii lub medycyny w 2016 roku, za odkrycia mechanizmów autofagii.

Życie na ziemi wyewoluowało w kierunku samoregulujących się układów biochemicznych, zwanych organizmami, które reagują na bodźce ze środowiska zewnętrznego, odżywiają się, oddychają, wydalają, rosną i rozmnażają się. Przez wieki, możliwości technologiczne ograniczały lub uniemożliwiały pełne zrozumienie fundamentalnych procesów życiowych, skupiając się na obserwacji fenotypów*, zachowań organizmów oraz ich organizacji, a dolną granicą badania struktur biologicznych była długość światła widzialnego, stojąca u podstaw funkcjonowania oka ludzkiego lub jego uzbrojonej wersji, czyli mikroskopu. Ale dlaczego roślina kieruje swoje liście w kierunku światła? Skąd wie, gdzie jest światło, skoro nie ma oczu? Skąd algi wiedzą, kiedy zacząć się namnażać? Dlaczego drożdże produkujące alkohol w którymś momencie zatrzymują jego produkcję i obumierają? Dlaczego niektóre zwierzęta mogą nurkować o wiele dłużej niż ludzie? Dlaczego niektóre osoby rodzą się chore, jeśli ich rodzice byli w pełni zdrowi? Nierozwiązanych pytań było nieskończenie wiele.

Pełne wyjaśnienie mechanizmów życia i obserwowanych procesów komórkowych czy reakcji na poziomie organizmu, leżało jednak niżej: w funkcjonowaniu cząsteczek mniejszych niż długość fali światła widzialnego. XX wiek przyniósł nam dynamiczny rozwój chemii oraz fizyki kwantowej, a idący za nią postęp technologiczny dostarczył wielu nowych metod biofizycznych, które umożliwiły zajrzenie tam, gdzie nie dosięgały mikroskopy świetlne. Rozpoczęła się era biochemii, która dostarczyła nam odpowiedzi na wiele nurtujących pytań. Podstawowym odkryciem (uważanym dzisiaj za pewnik) było zrozumienie, że życie na ziemi to sieci skomplikowanych, wpływających na siebie nawzajem, precyzyjnie zorganizowanych reakcji chemicznych, katalizowanych przez wyspecjalizowane maszyny molekularne – enzymy, które w większości są **białkami**. Naturalnie, wraz z dynamicznym rozwojem metod badania białek i rosnącą ilością informacji wymagających usystematyzowania, narodziła się nowa dziedzina nauki: proteomika. W związku z tym, że białka oraz układy biochemiczne, w jakie te są zaangażowane, mają ogromny poziom skomplikowania – ich analiza oraz opis wymagały wygenerowania wielkich ilości danych. Poza badaniami białek jako pojedynczych, odseparowanych molekuł (za pomocą technik biochemicznych i strukturalnych), rozwój i zwiększenie dostępności spektrometrów masowych, a także zwiększenie mocy obliczeniowej komputerów, były niewątpliwie kolejnymi punktami zwrotnymi w poznawaniu tajemnic proteomu. Umożliwiły one na analizowanie całych zestawów białek, które znajdują się w określonym czasie, w określonym typie komórki. Bez zaawansowanej informatyki nie moglibyśmy prowadzić globalnych analiz czy prób symulacji układów biologicznych *in silico*. Dziedziną informatyki, która obejmuje biologiczne lub medyczne jej zastosowania, jest bioinformatyka.

Niniejszy kurs ma na celu przybliżyć metody stosowane we współczesnej proteomice oraz ich możliwości, z naciskiem na narzędzia bioinformatyczne. Mam nadzieję, że będzie stanowił przydatny zbiór wiedzy, który umożliwi spojrzenie na projekty badawcze z nowej, nieco bardziej proteomicznej perspektywy. Kurs rozpocznie się krótkim, skondensowanym i absolutnie niezbędnym wstępem teoretycznym, aby omawiane dalej metody były jasne i klarowne. Treści zaprezentowane w skrypcie są ściśle powiązane z materiałami wykładowymi, które są integralną częścią kursu i w których, gdzie tylko to możliwe technicznie, będziemy

posługiwać się metodą *case study*, polegającą na analizie konkretnych przykładów z praktyki. Przykładowo będą towarzyszyły zadania do samodzielnego wykonania, które pozwolą upewnić się, że treści zostały przyswojone i w pełni zrozumiałe. Kurs zostanie zwieńczony zadaniem projektowym o dwóch wariantach trudności.


1.2 Co to jest białko? Podstawowe parametry opisujące białka.

W najprostszym ujęciu, białko to biopolimer zbudowany z aminokwasów (aminokwasy białkowe, aminokwasy alfa), połączonych ze sobą wiązaniem peptydowym, o długości większej niż około 100 aminokwasów (krótsze nazywamy peptydami, polipeptydami), oraz pełniący funkcję biologiczną po uzyskaniu odpowiedniego kształtu przestrzennego. Warto podkreślić, że **nie każde białko jest enzymem**.

Białko to ogólne określenie wszystkich cząsteczek białkowych pełniących różnorodne funkcje biologiczne – strukturalne (np. kolagen, keratyna), transportowe (np. hemoglobina), sygnałowe (np. insulina) czy obronne (np. przeciwciała).

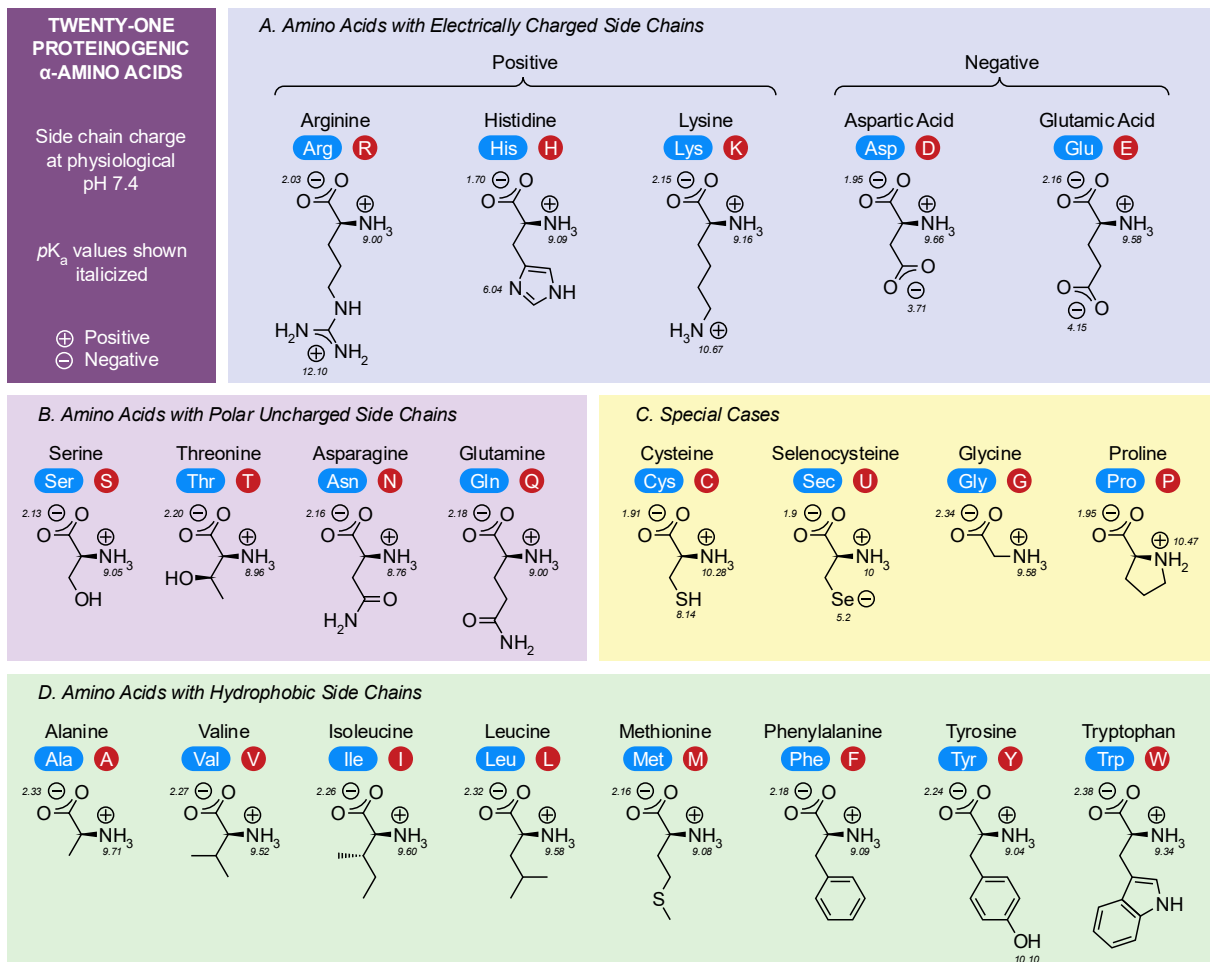
Enzym natomiast to specjalny rodzaj białka, którego zadaniem jest katalizowanie reakcji biochemicznych, czyli przyspieszanie ich przebiegu bez trwałego zużycia własnej struktury. Przykładowo, enzym amylaza obecna w ślinie rozkłada skrobię na cukry proste.

Produkcja białek stanowi końcowy etap tzw. centralnego dogmatu biologii molekularnej (Ryc. 1), który mówi o tym, że informacja o sekwencji białka zapisana jest w za pomocą kodu genetycznego (kod trójkowy) w DNA (jednostka niosąca informację o sekwencji jednego białka to gen), która po przepisaniu na mRNA dostarczana jest do rybosomu. Rybosom, to ogromny kompleks zbudowany z rRNA oraz białek, który tłumaczy informację zakodowaną kodem genetycznym w mRNA na język białek.



Ryc. 1. Centralny dogmat biologii molekularnej

Białka zbudowane są z 20 różnych aminokwasów, które posiadają łańcuchy boczne o różnych właściwościach chemicznych (Ryc. 2).



Ryc. 2 . Aminokwasy białkowe i ich właściwości

Definiujemy różne poziomy organizacji białek (Ryc. 3):


1) **struktura pierwszorzędowa** – określa **kolejność aminokwasów** w łańcuchu polipeptydowym danego białka. To właśnie sekwencja aminokwasów decyduje o dalszym sposobie jego fałdowania i funkcji biologicznej.

2) **struktura drugorzędowa** – opisuje **lokalne elementy przestrzenne łańcucha polipeptydowego**, takie jak alfa-helisy (α -helisy) i beta-harmonijki (β -kartki). Te regularne układy stabilizowane są głównie przez wiązania wodorowe pomiędzy grupami aminowymi i karbonyłowymi w szkieletie peptydowym.

3) **struktura trzeciorzędowa** – przedstawia **trójwymiarowe ułożenie całego łańcucha polipeptydowego**. Wynika ona z **oddziaływań między łańcuchami bocznymi aminokwasów**, takich jak wiązania wodorowe, oddziaływania hydrofobowe, mostki disiarczkowe czy siły elektrostatyczne. Na przykład białka rozpuszczalne w wodzie zazwyczaj kierują reszty hydrofobowe do wnętrza, a reszty hydrofilowe na zewnątrz cząsteczki.

4) **struktura czwartorzędowa** – opisuje **sposób wzajemnego oddziaływania kilku łańcuchów polipeptydowych (podjednostek)**, które nie są połączone kowalencyjnie, lecz tworzą razem **funkcjonalny kompleks białkowy**. W wielu przypadkach, aby białko mogło pełnić swoją funkcję, konieczna jest również obecność **kofaktora** – cząsteczki niebiałkowej, niezbędnej do aktywności enzymu.

- Jeśli kofaktor jest **trwale związany** z białkiem, nazywa się go **grupą prostetyczną**.
- Jeśli wiąże się **nietrwale**, mówimy o **koenzymie**. Część białkowa enzymu to **apoenzym**, natomiast **apoenzym połączony ze swoim kofaktorem** tworzy **holoenzym**, czyli aktywną formę enzymu zdolną do katalizy reakcji biochemicznej.



Ryc. 3

Rzędowość struktury białka

Podsumowując – wyprodukowanie przez rybosom samej sekwencji polipeptydu nie wystarczy do jego pełnej funkcjonalności. Peptydy i białka są w pełni funkcjonalne dopiero wtedy, gdy przyjmą odpowiednią formę przestrzenną, oraz w niektórych przypadkach, intensywną obróbkę potranslacyjną. Przybieranie przez łańcuchy polipeptydowe odpowiedniej struktury przestrzennej to tzw. fałdowanie. Proces ten jest wspomagane przez szereg mechanizmów komórkowych, a jego prawidłowy przebieg jest niezbędny do stabilności proteomu i prawidłowego funkcjonowania komórek.

Denaturacja białka, czyli zniszczenie struktur przestrzennych pod wpływem czynników fizycznych lub chemicznych jest nieodwracalne i pozbawia białko możliwości pełnienia jego funkcji.

W poniższej tabeli zebrano podstawowe parametry opisujące białka, które są rutynowo używane w proteomice.

Podstawowe parametry opisujące białka	
Sekwencja	Zapisywana jest za pomocą jednoliterowych (ciągłem, bez przerw, np. DYKDDDDK) lub trzyliterowych

	kodów aminokwasów (oddzielone myślnikiem, np. Asp-Tyr-Lys-Asp-Asp-Asp-Asp-Lys). Zwyczajowo, po lewej stronie zapis zaczyna się tzw. N-końcem (wolna grupa NH_2 pierwszego aminokwasu polipeptydu), a skrajnie po prawej mamy C-koniec (wolna grupa karboksylowa ostatniego aminokwasu peptydu).
Masa molekularna (molecular weight)	Wyrażana w kilodaltonach [kDa] $1 \text{ Da} = 1 \text{ u}$ Np. masa atomu węgla wynosi 12 u, co równa się 12 Da. Masy białek są duże, np. białko zabudowane z ok. 100 aminokwasów, może zawierać ok. 10000 atomów, dlatego opisując jego masę, używamy jednostki kDa ($1 \text{ kDa} = 1000 \text{ Da}$) lub MDa ($1 \text{ MDa} = 1000000 \text{ Da}$).
Współczynnik adsorpcji białka	Parametr określający jak bardzo dane białko absorbuje światło o określonej długości fali. Jest uzależniony od kompozycji aminokwasów i możliwy do obliczenia. Potrzebujemy go, aby dokładnie określić stężenie białka w badanym roztworze.
Punkt izoelektryczny	Wartość pH, w której ładunki ujemne i dodatnie aminokwasów budujących białko, równoważą się wzajemnie.
Struktura przestrzenna	Opisywana modelami przestrzennymi (zagadnienie to zostanie omówione w dalszych rozdziałach).

Wyżej omówione elementy struktury oraz podstawowe parametry białek, zostaną omówione na dwóch przykładach:

- 1) polipeptydu – insuliny (jest to hormon peptydowy, który jest zaangażowany w regulowanie ilości glukozy we krwi), oraz
- 2) białka – hemoglobiny (jest odpowiedzialna za transport tlenu w krwi).

→Materiały wykładowe:

Case study 1


Insulina. O skomplikowanej produkcji „prostego” peptydu sygnałowego

Case study 2

Hemoglobina – klasyczny przykład białka o czwartorzędowej strukturze przestrzennej

1.3 Co to jest proteom? Definicja i zakres proteomiki

Zacznijmy od zastanowienia się, czy genomika jest w stanie odpowiedzieć nam na wszystkie nurtujące nas pytania dotyczące funkcjonowania i rozwoju organizmu? Na przykładzie cyklu rozwojowego motyla (Ryc. 4) widzimy, że mimo iż wszystkie komórki tego owada zawierają takie samo, stałe DNA, to na różnych etapach rozwoju, organizm wygląda i zachowuje się zupełnie inaczej.



Ryc. 3

Cykl rozwojowy motyla jako emblematyczny przykład zmian w proteomie na różnych etapach rozwoju tego samego organizmu.

Do pewnego stopnia ten fenomen wyjaśnia gałąź genomiki - transkryptomika, która mówi o tym, że określone zestawy genów ulegają ekspresji w ściśle określonych typach tkanek i w określonych warunkach. Nie jest to jednak obraz pełen, ponieważ informacje zawarte w DNA oraz RNA dają nam tylko pośredni obraz tego, co dzieje się na poziomie całego zestawu białek danej komórki: jak jest zbudowany, jak wygląda i jak funkcjonuje?

Proteom to pojęcie, które wyewoluowało właśnie na wzorcach nomenklaturowych przyjętych w genomice. Skoro genom oznaczał pełen zestaw informacji genetycznej występującej w danym organizmie czy komórce, to proteom będzie pełnym zestawem białek występujących w organizmie, komórce, tkance lub narządzie w określonym czasie i w określonych warunkach. W przeciwieństwie do genomu (który jest względnie stały), **proteom jest dynamiczny** – zmienia się w odpowiedzi na czynniki środowiskowe, etap rozwoju, stan zdrowia organizmu czy sygnały komórkowe.

Proteomika to dziedzina biologii molekularnej zajmująca się badaniem proteomu i obejmuje:

- **Identyfikację białek** – określenie, jakie białka są obecne w próbce.
- **Charakteryzację strukturalną i funkcjonalną** – poznanie budowy i mechanizmów działania białek, ich modyfikacji potranslacyjnych, lokalizacji w komórce i interakcji z innymi cząsteczkami.
- **Analizę ilościową** – porównanie poziomów ekspresji białek w różnych warunkach (np. tkanka w stanie zdrowia porównana ze stanem choroby).
- **Badanie interakcji białek** – tworzenie map sieci oddziaływań białkowych (tzw. interaktom).

Zakres proteomiki obejmuje badania podstawowe (np. zrozumienie mechanizmów biologicznych), jak również zastosowania praktyczne, takie jak diagnostyka chorób, poszukiwanie biomarkerów określonych stanów chorobowych, projektowanie nowych leków czy badania toksykologiczne i farmakologiczne.

Jak łatwo się domyślić, proteomika to niesamowicie szeroka, interdyscyplinarna dziedzina wiedzy, która wymaga integrowania danych pochodzących z różnych podejść metodologicznych, co w praktyce zwykle jest dość skomplikowane. Projekty proteomiczne, jeśli mają na celu kompleksową odpowiedź na postawione biologiczne pytanie badawcze, muszą korzystać z ekspertyzy specjalistów z różnych dziedzin i angażują zwykle duże, międzynarodowe i interdyscyplinarne zespoły.

1.4 Krótki przegląd technik eksperymentalnych stosowanych w proteomice

Ludzki genom zawiera około 20 000 jednostek kodujących, czyli genów. W uproszczeniu, jeden gen = instrukcja budowy jednego białka (jego struktury pierwszorzędowej). W rzeczywistości jednak liczba białek występujących w organizmie człowieka jest znacznie większa niż liczba genów, ze względu na alternatywny splicing oraz różne modyfikacje potranslacyjne (np. odcinanie fragmentów białek (patrz Case study 1; dodawanie grup chemicznych itp.). Łatwo sobie wyobrazić, że analiza tak skomplikowanego zbioru różnorodnych pod względem rozmiaru i właściwości chemicznych molekuł, będzie bardzo wymagającym technicznie zadaniem. O ile badanie genomu czy transkryptomu opiera się na relatywnie prostych metodach ekstrakcji kwasów nukleinowych oraz ich sekwencjonowania, w przypadku białek, potrzebne było opracowanie wielu metod fizykochemicznych i biochemicznych, aby rozdzielić tak skomplikowaną mieszaninę i móc miarodajnie analizować jej składniki.

Metody analizy proteomu można podzielić na dwie grupy, które omówiono poniżej.

1. Metody szerokiej/globalnej analizy proteomu:

- **Elektroforeza dwuwymiarowa (2D-PAGE)**
 - Rozdziela białka według punktu izoelektrycznego i masy cząsteczkowej.
 - Umożliwia analizę tysięcy białek jednocześnie.
- **Spektrometria mas (MS)**
 - Kluczowa technika identyfikacji i charakterystyki białek.
 - Analizuje masę i strukturę peptydów po trawieniu enzymatycznym.
 - Typowe metody: MALDI-TOF, ESI-MS, LC-MS/MS.
- **Chromatografia ciekłowa (LC)**
 - Stosowana przed spektrometrią mas do separacji mieszanin białek lub peptydów.
 - Najczęściej: chromatografia ciekłowa wysokociśnieniowa (HPLC).
- **Mikromacierze białkowe (protein microarrays)**
 - Pozwalają badać ekspresję białek, ich interakcje i modyfikacje.
 - Umożliwiają analizę setek białek jednocześnie.

- **Bioinformatyka proteomiczna**
 - Analiza danych proteomicznych: identyfikacja białek, przewidywanie funkcji, analiza sieci interakcji.

2. Metody skupione na konkretnym białku/kompleksie białkowym.

- **Western blot**
 - Technika półilościowa do wykrywania konkretnych białek z użyciem przeciwciał.
 - Często stosowana jako metoda potwierdzająca obecność danego białka.
- **Techniki immunologiczne (ELISA, immunoprecypitacja)**
 - Wykorzystują przeciwciała do wykrywania i izolacji konkretnych białek.
- **Heterologiczne systemy ekspresji białek**
 - Stosowane w celu wyprodukowania dużej ilości konkretnego białka do analiz biochemicznych i strukturalnych *in vitro*.
- **Chromatografia**
 - Metody oczyszczania rekombinowanych białek: chromatografia powinowactwa, chromatografia jonowymienna, sączenie molekularne.
 - Ma na celu uzyskanie dużej ilości czystego materiału do analiz biochemicznych i strukturalnych *in vitro*.
- **Metody strukturalne: krystalografia rentgenowska, NMR oraz CryoEM**
 - Umożliwiają rozszyfrowanie struktury przestrzennej białka lub kompleksu białkowego z rozdzielczością atomową.
- **Spektroskopia Ramana i FTIR**
 - Analiza struktury drugorzędowej białek.
 - Stosowane w badaniach konformacyjnych.

Pamiętajmy, że zastosowanie w projekcie badawczym technik pochodzących tylko z jednej z w/w grup, poza dużą wartością deskryptywną czy mechanistyczną, zazwyczaj nie jest w stanie dać nam pełnej, kompleksowej odpowiedzi na określone pytanie badawcze na poziomie komórki. Dlatego, w wiodących pracach biologicznych widzimy współcześnie łączenie specjalistycznych analiz biochemicznych *in vitro*, skupionych na konkretnym białku, kompleksie białkowym czy szlaku reakcji biochemicznych, które jest

komplementowane przez globalne analizy proteomiczne próbek pochodzących z hodowli komórkowych lub pobranych z organizmu.

Zadania 1 i 2

Zadanie 1

W bazie danych Uniprot (<https://www.uniprot.org/>) wyszukaj następujące białka:

- Insulina (insulin, human)
- Hemoglobina (hemoglobin subunit beta, human)
- Lizozym (lysozyme C, human)

Dla każdego białka zbierz następujące dane w tabeli porównawczej: nazwa białka, ID UniProt, sekwencja, masa molekularna (Mass w [Da]), funkcja, czy występuje w kompleksie („Complex viewer”)?

Zadanie 2

Na podstawie informacji w bazie Uniprot, odpowiedz na pytania:

1. Jaka mutacja w ludzkiej hemoglobinie powoduje jej odporność na malarię? Podaj nr pozycji w sekwencji i na jaki aminokwas jest on podstawiony. Wskazówka: Szukaj w zakładce „Disease & Variants”
2. Podaj nr aminokwasów-cystein, które są odpowiedzialne za tworzenie mostków disiarczkowych pomiędzy łańcuchami A i B w insulinie. Wskazówka: Szukaj w zakładce „PTM/Processing”
3. Podaj numer EC lizozymu. Co to jest numer EC? Dlaczego insulina i hemoglobina nie posiadają numeru EC?

2. Bioinformatyczne bazy danych białkowych

2.1 Wstęp

Współczesna proteomika generuje ogromne ilości danych, które wymagają odpowiedniego przechowywania, organizacji i analizy. Bazy danych stanowią nieodzowny element każdego etapu analizy proteomicznej: od identyfikacji sekwencji białek i ich modyfikacji, przez analizę ilościową, aż po integrację informacji o interakcjach czy ekspresji w różnych tkankach. Znajomość dostępnych baz danych oraz umiejętność ich praktycznego wykorzystania to kluczowe kompetencje w bioinformatyce proteomicznej.

2.2 Klasyfikacja baz danych proteomicznych

A. Sekwencyjne i funkcjonalne bazy białek

- **UniProt (Universal Protein Resource)** – najważniejsza, międzynarodowa baza danych zawierająca informacje o sekwencjach, strukturach, funkcjach i modyfikacjach potranslacyjnych białek. Składa się z części **Swiss-Prot** (ręcznie adnotowane dane) oraz **TrEMBL** (dane generowane automatycznie).
- **RefSeq (NCBI)** – referencyjne sekwencje genów, transkryptów i białek, kuratorowane przez National Center for Biotechnology Information.
- **Ensembl** – europejska baza danych integrująca informacje genomowe i proteomiczne, uwzględniająca m.in. alternatywny splicing i izoformy białek.

B. Spektrometryczne repozytoria danych

- **PRIDE (PRoteomics IDentifications Database)** – jedno z największych archiwów danych z eksperymentów spektrometrii mas (MS) prowadzonych na organizmach modelowych i klinicznych. Umożliwia pobieranie surowych danych oraz przeszukiwanie opublikowanych zestawów.
- **MassIVE** – platforma udostępniania danych proteomicznych, część Global Proteome Machine. Pozwala na interaktywne przeszukiwanie danych, analizę oraz integrację z innymi zasobami.

- **PeptideAtlas** – atlas peptydów i białek oparty na publicznych danych MS, wspierający budowę baz dla DIA (data-independent acquisition).
- **ProteomeXchange** – konsorcjum integrujące kilka repozytoriów (w tym PRIDE i MassIVE) w celu ułatwienia globalnej wymiany danych.

C. Bazy modyfikacji potranslacyjnych (PTMs) i interakcji

- **PhosphoSitePlus** – specjalistyczna baza danych PTMs (fosforylacja, acetylacja, ubikwitynacja), zawierająca dane eksperymentalne głównie dla ludzkich i mysich białek.
- **dbPTM** – kompendium modyfikacji potranslacyjnych z wielu organizmów, łączące dane literaturowe i bioinformatyczne przewidywania.
- **STRING** – baza interakcji białko-białko, zawierająca dane eksperymentalne oraz przewidywane na podstawie homologii i współekspresji.
- **BioGRID** i **IntAct** – bazy interakcji molekularnych, ściśle bazujące na literaturze naukowej.

D. Bazy ekspresji i lokalizacji

- **Human Protein Atlas (HPA)** – zasób łączący dane transkryptomiczne i proteomiczne. Zawiera informacje o lokalizacji białek w tkankach, komórkach i strukturach subkomórkowych.
- **PaxDb** – baza abundancji białek w różnych tkankach i organizmach, przydatna w analizie funkcjonalnej.
- **Cell Atlas** – część HPA skupiająca się na subkomórkowej lokalizacji białek w ludzkich komórkach.

→Materiały wykładowe:

Case study 3

Analiza proteomu raka piersi według: Mertins et al., "Proteogenomics connects somatic mutations to signalling in breast cancer", Nature (2016)

Zadanie 3

W tym zadaniu przetestujemy wybrane bazy danych (tylko kilka wybranych przykładów, ze względu na fakt, że proteomicznych baz danych jest o wiele więcej niż te wspomniane wyżej. Dlatego przyjrzymy się tym najbardziej reprezentatywnym z punktu widzenia programu naszego kursu), wyszukując w każdej z nich białko p53.

Białko p53, kodowane przez gen **TP53**, jest jednym z najważniejszych czynników regulujących cykl komórkowy i nazywane bywa „strażnikiem genomu”. Chroni komórkę przed namnażaniem się z uszkodzonym DNA, zatrzymując cykl komórkowy, uruchamiając naprawę DNA lub – w razie poważnych uszkodzeń – prowadząc do apoptozy. Mutacje w genie TP53 występują w ponad połowie wszystkich nowotworów, dlatego białko to jest kluczowym obiektem badań nad rakiem i kontrolą wzrostu komórek.

Zapoznaj się z następującymi bazami danych i wykonaj polecenia:

1. PRIDE Archive

Zapoznaj się z bazą danych (<https://www.ebi.ac.uk/pride/archive>).

Wyszukaj w niej białko **TP53 (p53)** człowieka (*Homo sapiens*).

Wybierz **jeden projekt** (dataset), w którym występuje TP53, i opisz go:

- podaj jego **identyfikator**,
- opisz **cel eksperymentu**,
- napisz, **jakie dane** są dostępne (np. surowe dane MS, identyfikacje peptydów, pliki wynikowe).

3. PhosphoSitePlus

Zapoznaj się z bazą danych (<https://www.phosphosite.org>).

W polu wyszukiwania wpisz TP53 (*Homo sapiens*).

Na stronie białka zlokalizuj na grafie aminokwas K120 (lizyna 120) i zidentyfikuj modyfikacje potranslacyjne, które zostały tam oznaczone (kliknij lub najedź na pinezkę).

4. Human Protein Atlas

Zapoznaj się z bazą danych (<https://www.proteinatlas.org>)

Szukaj: *TP53*

W polu wyszukiwania wpisz TP53.

Otwórz stronę białka i odpowiedz na pytania:

- a) W jakiej części komórki zlokalizowane jest białko p53?
- b) W jakich tkankach obserwuje się jego najwyższy poziom ekspresji?

5. PaxDb

Zapoznaj się z bazą danych (<https://pax-db.org>)

Szukaj: *TP53 Homo sapiens*

Czy znajdziesz informację o ilościowym poziomie TP53? W których tkankach jest najwięcej? (Wskazówka: Posortuj tabelę „TP53 abundance information”)

3. Formaty danych surowych w proteomice.

Oprogramowanie do przetwarzania danych surowych

3.1 Wprowadzenie

W proteomice, dane surowe stanowią punkt wyjścia do wszystkich dalszych analiz – zarówno jakościowych (identyfikujących konkretne białka), jak i ilościowych (identyfikujących poziomy ekspresji białek), funkcjonalnych czy strukturalnych. Źródłem tych danych są najczęściej eksperymenty z użyciem spektrometrii mas, ale również inne metody takie jak spektroskopia Ramana, pomiary fluorescencyjne czy techniki biologii strukturalnej (krystalografia rentgenowska i mikroskopia krioelektronowa). Aby umożliwić ich analizę, interpretację oraz integrację z innymi danymi biologicznymi, konieczne jest stosowanie ustandaryzowanych formatów plików.

Formaty danych surowych w proteomice pełnią fundamentalną rolę w przechowywaniu, przetwarzaniu i udostępnianiu wyników eksperymentów. Oprócz klasycznych formatów spektralnych, takich jak mzML i RAW, równie istotne są formaty sekwencyjne (FASTA) oraz strukturalne (PDB, mmCIF, MRC). Zrozumienie ich funkcji, zalet i ograniczeń jest niezbędne do prowadzenia skutecznych analiz bioinformatycznych w nowoczesnej proteomice.

3.2 Formaty danych surowych z MS

A. Formaty binarne (proprietarne)

- **.RAW** (Thermo Fisher), **.WIFF** (Sciex), **.D** (Agilent), **.TDF** (Bruker)
- Są generowane bezpośrednio przez oprogramowanie spektrometru.
- Często zawierają bardzo szczegółowe dane (spektra MS/MS, metadane eksperymentu, parametry instrumentu).
- Problem: ograniczony dostęp (potrzebne firmowe biblioteki lub narzędzia do konwersji).

B. Formaty otwarte (ustandaryzowane)

- **mzML** – aktualnie najbardziej wszechstronny i zalecany standard.
 - oparty na XML.
 - zawiera zarówno dane spektralne, jak i szczegółowe metadane.
 - obsługiwany przez większość narzędzi open-source (OpenMS, ProteoWizard, MaxQuant).
- **mzXML** – starszy format, również oparty na XML.
 - mniej rozwijany, ale nadal używany w niektórych narzędziach.
- **mzData** – format wczesny, obecnie niemal całkowicie wyparty przez mzML.
- **mgf (Mascot Generic Format)**
 - prosty tekstowy format do przechowywania widm MS/MS.
 - idealny do eksportu fragmentów danych do identyfikacji za pomocą algorytmów wyszukiwania takich jak Mascot.
- **ANDI-MS / netCDF** – format przenośny dla danych chromatograficznych, wykorzystywany rzadziej.

3.3 Oprogramowanie do przetwarzania danych surowych

Przetwarzanie danych surowych w proteomice to pierwszy krok prowadzący od plików spektrometrycznych do wyników biologicznych. Obejmuje konwersję formatów, detekcję pików, przetwarzanie chromatogramów, oraz ekstrakcję i organizację danych spektralnych. Kluczową rolę odgrywa tu specjalistyczne oprogramowanie.

A. ProteoWizard (MSConvert)

- **Zastosowanie:** Konwersja danych z formatów firmowych (np. .RAW, .WIFF) na otwarte formaty (.mzML, .mzXML, .mgf).
- **Cechy:**
 - obsługuje różne platformy (Windows, Linux, macOS).
 - umożliwia filtrację danych, centroidyzację i ekstrakcję zakresów m/z.
- **Interfejs:** graficzny (GUI) oraz wiersz poleceń (CLI).

B. ThermoRawFileParser

- lekka, szybka alternatywa do konwersji plików .RAW z instrumentów Thermo.
- w pełni open-source, idealna do pipeline'ów w chmurze.
- generuje pliki .mzML oraz pliki metadanych.

C. OpenMS

- Rozbudowane środowisko do przetwarzania danych proteomicznych.
- Moduły do:
 - identyfikacji pików (PeakPicker),
 - ekstrakcji chromatogramów (FeatureFinder),
 - konwersji i filtracji danych (FileConverter, IDFilter),
 - integracji z narzędziami wyszukującymi (X!Tandem, Mascot, MS-GF+).
- Interfejs: narzędzia wiersza poleceń, GUI (TOPPAS).

D. MaxQuant

- Kompletny pakiet do analizy danych MS, popularny w połączeniu z instrumentami Orbitrap.
- Funkcje:
 - przetwarzanie surowych danych .RAW (Thermo),
 - wykrywanie i kwantyfikacja pików (LFQ, SILAC),
 - wbudowane algorytmy identyfikacji (Andromeda).
- Wymaga danych w formacie .RAW – nie obsługuje mzML.

E. Skyline

- Narzędzie skoncentrowane na analizie celowanej (SRM, PRM).
- Obsługuje wiele formatów danych surowych (Thermo, Sciex, Agilent).
- Interaktywna wizualizacja chromatogramów i wyników.

F. MSFragger / FragPipe

- Bardzo szybkie narzędzie do przeszukiwania baz danych, zintegrowane z narzędziem **IonQuant** do kwantyfikacji.
- Przyjmuje dane w formacie mzML.

- Umożliwia analizę również modyfikacji PTM i danych DIA.

3.4 Znaczenie standaryzacji

Zastosowanie wspólnych, otwartych formatów danych umożliwia:

- Interoperacyjność między narzędziami analitycznymi.
- Automatyzację przetwarzania danych (budowanie pipeline'ów do analizy danych).
- Publikację danych w publicznych repozytoriach (PRIDE, MassIVE, PDB).
- Reprodukowalność badań i transparentność metod.

Ważną rolę w polu proteomiki odgrywają organizacje takie jak HUPO-PSI (Proteomics Standards Initiative), które promują i rozwijają wspólne standardy formatów danych.

Oprogramowanie do przetwarzania danych surowych jest niezbędnym elementem każdej analizy proteomicznej. Wybór konkretnego narzędzia zależy od:

- rodzaju instrumentu (Orbitrap, QTOF, TripleTOF),
- preferowanego formatu wyjściowego (mzML, mgf),
- typu analizy (DDA, DIA, SRM),
- wymogów integracyjnych (np. współpraca z MaxQuant lub Skyline),
- dostępności zasobów (komercyjne vs. open-source).

W praktyce często stosuje się pipeline, który łączy kilka z powyższych narzędzi – np. konwersja raw → mzML (MSConvert), następnie analiza w OpenMS. Oprogramowanie MaxQuant przyjmuje pliki typu raw.

3.5 Przypomnienie – to będzie potrzebne na każdym kroku analiz białek

1. Format FASTA – dane sekwencyjne

Chociaż FASTA nie zawiera danych spektralnych, jest absolutnie kluczowym formatem w proteomice, ponieważ zawiera sekwencje białek wykorzystywane do dopasowania peptydów (czyli ich identyfikacji).

- **FASTA** – tekstowy format sekwencji (DNA, RNA lub białek), w którym każdy wpis zaczyna się od znaku „>” z nagłówkiem identyfikacyjnym, a kolejne linie zawierają sekwencję aminokwasową. Jest używany w bazach danych jak np. UniProt, NCBI, Ensembl.

2. Formaty danych w biologii strukturalnej

A. Format PDB

- **Protein Data Bank (PDB)** – standardowy format zapisu danych strukturalnych (X-ray, NMR, Cryo-EM).
- Zawiera:
 - Współrzędne atomów białka w przestrzeni 3D
 - Informacje o łańcuchach, ligandach, jonach metali
 - Adnotacje o strukturze wtórnej, wiązaniach, modyfikacjach
- Używany m.in. do wizualizacji w PyMOL, Chimera, UCSF ChimeraX, RCSB PDB.

B. Format mmCIF (macromolecular Crystallographic Information File)

- Format nowszy niż PDB, bardziej rozszerzalny, zgodny z bazami strukturalnymi i lepiej przystosowany do dużych struktur (jak kompleksy Cryo-EM).
- Zalecany przez PDB jako nowy standard.

C. Formaty dla Cryo-EM

- **.map / .mrc** – zawierają dane gęstości elektronowej.

- Zastosowanie: rekonstrukcja 3D, dopasowywanie modeli atomowych.
- Używane np. w oprogramowaniu RELION, cryoSPARC.

D. Do przetwarzania danych z biologii strukturalnej wykorzystujemy:

- **EMAN2, CCP4, Phenix** – narzędzia do przetwarzania danych strukturalnych (Cryo-EM, X-ray).

→Materiały wykładowe:

Case study 4

Jak odczytywać formaty danych w proteomice?

Zadania 4 i 5

4. Struktura przestrzenna białka p53

Wejdź na stronę **Protein Data Bank**: <https://www.rcsb.org>

Wyszukaj identyfikator **3KMD**.

Otwórz model w widoku 3D (3D View).

Odpowiedz:

- Jakie metody zostały użyte do wyznaczenia struktury tego kompleksu (NMR, X-ray?)
 - Ile łańcuchów białkowych zawiera ta struktura i jaki typ kompleksu tworzą (np. dimer, tetramer)?
 - Czy w strukturze widoczne jest DNA lub inne ligandy?
 - Jakie elementy struktury drugorzędowej przeważają (alfa-helisy, beta-harmonijki)?
- (Zadanie dla własnej eksploracji) Kliknij na cząsteczkę DNA i poobserwuj, jakie oddziaływania tworzą poszczególne zasady azotowe z aminokwasami białka p53.

5. Struktura kompleksu p53 z nukleosomem (cryo-EM)

Wejdź na stronę <https://www.ebi.ac.uk/emdb/>

Wyszukaj kompleks p53 z nukleosomem (cryo-EM): **EMD-33533**

Ta struktura pokazuje kompleks domeny wiążącej DNA białka p53 z nukleosomem, czyli z DNA owiniętym wokół histonów. To bardzo ładny, realistyczny przykład tego, jak p53 rozpoznaje DNA w kontekście chromatyny – i da się go oglądać bez specjalistycznego oprogramowania.

Obejrzyj galerię („Gallery” po lewej stronie).

- a) Jakiego typu wizualizacje są tam widoczne?
- b) Czy obraz cryo-EM pozwala dokładnie zobaczyć cząsteczkę?
- c) Czy potrzebny jest dopasowany model, aby rozpoznać elementy strukturalne?

Otwórz zakładkę „3D View”.

- Spróbuj odnaleźć fragment, który odpowiada kompleksowi p53–DNA oglądanemu w zadaniu 3.
- Na dole okna 3D View znajdziesz **PDB ID dopasowanego modelu (7XZX)**.

Otwórz strukturę **7XZX** w bazie [PDB](#)

- d) W zakładce „Macromolecules” sprawdź, z jakich podjednostek histonowych (typów histonów) składa się ten kompleks i ile kopii każdej z nich zawiera.

c. Identyfikacja białek w proteomice

4.1 Wstęp

Identyfikacja białek to kluczowy etap każdej analizy proteomicznej (niezależnie od grupy metod, w obrębie której się poruszamy, patrz. Rozdział 1.4). Pozwala określić, jakie białka występują w badanej próbce, w jakich ilościach, jakich są rozmiarów, jakie zawierają modyfikacje oraz czy występują jako wolne formy, czy w kompleksach. Wiedza ta jest niezbędna do zrozumienia funkcjonowania białek i ich układów, co przekłada się na homeostazę komórek, tkanek i organizmów (lub jej zaburzenia).

Współczesna bioinformatyka proteomiczna dysponuje wieloma metodami służącymi identyfikacji białek. Najczęściej wykorzystywanym podejściem jest spektrometria masowa sprzężona z analizą bioinformatyczną, jednak dynamicznie rozwijają się również techniki strukturalne, takie jak mikroskopia krioelektronowa (Cryo-EM) oraz zintegrowane podejścia wykorzystujące dane z różnych źródeł.

4.2 Klasyczne podejście: spektrometria masowa

Spektrometria masowa (MS) jest najpowszechniejszą techniką stosowaną w proteomice do identyfikacji białek. W podejściu bottom-up analizę zaczyna się od enzymatycznego trawienia białek (zwykle trypsyną) na krótsze peptydy (→ **Materiały wykładowe: jak działa spektrometria mas**). Zwykle, przed naniesieniem takiej próbki na układ spektrometru masowego, stosuje się metody chromatograficzne, którego są w stanie rozdzielić mieszaninę peptydów, aby „nie wrzucać wszystkiego na raz” ryzykując przeładowaniem układu eksperymentalnego. Uzyskane po chromatografii peptydy są następnie jonizowane i wprowadzane do spektrometru masowego, który mierzy ich masy oraz, w trybie MS/MS, fragmentuje je, tworząc widma charakterystyczne dla ich sekwencji.

Dane spektrometrii mas są następnie analizowane za pomocą specjalistycznego oprogramowania, które porównuje uzyskane widma do teoretycznych widm wygenerowanych na podstawie znanych sekwencji białek, np. z baz danych UniProt, Ensembl lub RefSeq. Narzędzia takie jak Mascot, Sequest, Andromeda (część

MaxQuant) czy MS-GF+ odpowiadają za przypisanie widm do konkretnych sekwencji peptydowych, a w efekcie – do źródłowych białek.

Równolegle stosuje się kontrolę jakości wyników, najczęściej poprzez estymację FDR (False Discovery Rate), aby wykluczyć błędne dopasowania. W przypadku badań organizmów bez dobrze poznanego genomu lub w celu wykrycia nowych wariantów białek, wykorzystuje się algorytmy sekwencjonowania de novo, które odczytują sekwencję peptydu bez potrzeby korzystania z bazy danych.

Alternatywą lub uzupełnieniem podejścia sekwencyjnego jest przeszukiwanie tzw. bibliotek widmowych – zbiorów wcześniej zidentyfikowanych widm peptydów – co pozwala na szybszą i bardziej precyzyjną identyfikację w znanych systemach biologicznych.

Jak przygotować próbkę do spektrometrii mas?

Białka w komórce nie są równomiernie rozproszone – mają swoje konkretne miejsca działania: cytoplazma, jądro komórkowe, mitochondria, retikulum endoplazmatyczne, błona komórkowa czy nawet przestrzeń zewnątrzkomórkowa. Co więcej, różnią się budową – niektóre są kuliste i rozpuszczalne (globularne), inne wchodzą w skład błon (mają regiony hydrofobowe), a jeszcze inne tworzą sztywne struktury (jak włókienka cytoszkieletu). Różnice mają ogromne znaczenie przy planowaniu badań proteomicznych, bo nie wszystkie białka da się wyizolować tym samym sposobem.

Pierwszy krok to rozbicie komórki – najczęściej przez homogenizację (mechaniczną lub z użyciem detergentów). Potem można przeprowadzić tzw. frakcjonowanie, czyli rozdzielenie przedziałów komórkowych za pomocą wirowania (często różnicowego lub w gradiencie gęstości). Tak można osobno odzyskać jądra komórkowe, mitochondria, retikulum endoplazmatyczne, cytoplazmę itd.

Istnieją też gotowe zestawy komercyjne, które pozwalają w prosty sposób oddzielić np. frakcję jądrową od cytoplazmatycznej.

Białka błonowe to jedna z najtrudniejszych grup do izolacji. Mają one fragmenty hydrofobowe, które „tkwią” w lipidach. Do ich wydobycia używa się detergentów –

łagodnych (jak Triton X-100) lub silniejszych (SDS). Coraz popularniejsze są detergenty kompatybilne z analizą MS – np. RapiGest, które można rozłożyć chemicznie np. po etapie trawienia białek, nie przeszkadzają więc w analizie peptydów.

Niektóre białka są wydzielane na zewnątrz komórki. Żeby je uchwycić, można zebrać medium z hodowli komórkowej, oznaczyć białka powierzchniowe na żywych komórkach za pomocą odpowiedniej metki, a potem oczyścić je metodami chromatografii powinowactwa, lub zastosować immunoprecypitację – czyli złapać konkretne białko specyficznym przeciwciałem.

Po izolacji białka trzeba odpowiednio przygotować:

1. **Rozpuścić i zdenaturować** – najczęściej w moczniku, detergencie lub przy pomocy ciepła.
2. **Zredukować i zablokować mostki disiarczkowe** – dzięki DTT i jodoacetamidowi.
3. **Pociąć na peptydy** – najczęściej używa się trypsyny.
4. **Oczyścić próbkę** – usunąć nadmiar soli, buforów i detergentów (np. filtracją lub na kolumnach C18).
5. **(Opcjonalnie) Wyznakować próbki do analizy ilościowej** – np. TMT lub iTRAQ.

Nieprawidłowa izolacja może skutkować zanieczyszczeniami lub utratą ważnych białek (np. błonowych). Białka cytoplazmatyczne są proste do wyizolowania, ale błonowe, wydzielane czy organellowe – już nie. Dlatego często stosuje się kilka protokołów jednocześnie, aby dostać się do różnych frakcji. Dobrze przemyślana izolacja i przygotowanie próbki to fundament udanej analizy proteomicznej.

4.3 Problem inferencji białek

Jednym z wyzwań w identyfikacji białek na podstawie peptydów jest tzw. problem inferencji: pojedynczy peptyd może występować w więcej niż jednym białku – szczególnie w przypadku izoform, produktów genów paralogicznych lub białek o wspólnych domenach. Dlatego bioinformatyka proteomiczna korzysta z metod statystycznych i heurystycznych (np. algorytmu parsymonii), by wybrać najbardziej prawdopodobny zestaw białek reprezentujących dane peptydy.

4.4 Nowe perspektywy: Cryo-EM i identyfikacja białek na podstawie struktury

Transmisyjna mikroskopia krioelektronowa w niskich temperaturach (Cryo-EM) wnosi nową jakość do identyfikacji białek (→ **Materiały wykładowe: metody stosowane w badaniach struktury białek**). Zamiast analizować pofragmentowane peptydy, Cryo-EM pozwala na bezpośrednie obrazowanie struktur pełnej długości białek w ich nienaruszonym stanie, często jako część większych kompleksów molekularnych. Wynikiem analizy Cryo-EM są mapy 3D analizowanego białka, których rozdzielczość może sięgać poniżej 3 Å, umożliwiając bezpośrednie dopasowanie modeli atomowych. Ograniczeniem CryoEM w podejściu SPA (single particle analysis) jest konieczność uzyskania względnie homogennej próbki (choć zanieczyszczenia innymi białkami nie są tu tak problematyczne jak w krystalografii rentgenowskiej) oczyszczonego laboratoryjnie białka lub kompleksu.

Gdy rozdzielczość mapy na to pozwala, białka (i ich domeny) można identyfikować poprzez dopasowanie znanych modeli strukturalnych (np. z PDB) lub predykcji AlphaFold3 do obserwowanych gęstości.

Jednym z nowych, bardziej zaawansowanych podejść jest tzw. identyfikacja białek na podstawie otrzymanych map 3D (density-based identification). Oprogramowanie w tym przypadku porównuje wzorce geometryczne, rozkład gęstości oraz cechy konformacyjne łańcuchów bocznych (bazując na modelach eksperymentalnych i predykcyjnych) z niezidentyfikowanymi strukturami Cryo-EM i wpasowuje pasujące aminokwasy do otrzymanych gęstości. Algorytmy takie jak np. ModelAngelo są w stanie przewidzieć sekwencję białka, mając do dyspozycji jedynie jego gęstość eksperymentalną. Oczywiście, takie dane eksperymentalne muszą być wysokiej jakości, o bardzo wysokiej rozdzielczości. Mimo potencjalnych błędów w dopasowaniu, podejście takie umożliwia nam poznanie nawet częściowej sekwencji niezidentyfikowanego białka, która może wystarczyć do odnalezienia jego pełnej wersji w innych bazach danych.

Cryo-EM jest szczególnie przydatne w badaniu endogennych kompleksów białkowych, takich jak rybosomy, proteasomy czy maszyny błonowe. Dzięki temu nie tylko

identyfikujemy, *jakie* białka występują w próbce, ale też w *jakiej strukturze i kontekście* funkcjonalnym występują.

Jak przygotować próbkę do single particle CryoEM?

Większość białek, które chcemy badać strukturalnie, szczególnie ludzkich, nie występuje naturalnie w ilościach wystarczających do analizy. Dlatego „zmuszamy” inne organizmy, by produkowały nasze białko – to właśnie jest ekspresja heterologiczna. Najczęściej korzysta się z takich systemów jak:

- **Bakterie (np. *E. coli*)** – tanie, szybkie, ale nie radzą sobie z modyfikacjami potranslacyjnymi i nie wszystkie białka się w nich poprawnie fałdują.
- **Drożdże** – bardziej eukariotyczne, lepsze do białek złożonych.
- **Komórki owadzie (np. Sf9)** – korzystają z wirusowego systemu transfekcji, dobre do białek eukariotycznych.
- **Komórki ssacze (np. HEK293, CHO)** – drogie i wymagające, trudno aby uzyskać duże ilości, ale produkują najbardziej „naturalne” białka.

Cały proces zaczyna się od **sklonowania** genu kodującego nasze białko do specjalnego wektora. Często dodaje się też tzw. **metki** (np. His-tag, FLAG, Strep), umożliwiające oczyszczanie metodą chromatografii powinowactwa.

Aby oczyścić wyprodukowane białko, najpierw musimy **rozbić komórki**. W zależności od źródła może to być sonikacja, homogenizacja czy detergenty.

Potem następuje **oczyszczanie**, które często odbywa się w kilku etapach:

1. **Chromatografia powinowactwa**– wykorzystujemy tag (np. His-tag łąpie się na kolumnę z niklem).
2. **Dializa lub ultrafiltracja** – żeby pozbyć się soli, detergentów, buforów.
3. **Chromatografia żelowa (SEC)** – pozwala oddzielić dobrze sfałdowane białka od agregatów.
4. **Sprawdzenie próbki** – SDS-PAGE, Western blot, czasem spektrometria mas.

Celem jest uzyskanie czystego, stabilnego i jednorodnego białka. Wtedy przychodzi pora na **przygotowanie siatek (gridów)** do Cryo-EM. Za pomocą specjalistycznych narzędzi, staramy się uzyskać cienką warstwę amorficznego lodu, w którym dystrybucja cząsteczek białka jest odpowiednia do analizy transmisyjnym mikroskopem elektronowym. Mikroskop zbiera obrazy cząsteczek w różnych orientacjach. Z tych danych, dzięki specjalistycznym algorytmom, można potem złożyć trójwymiarowy model białka [więcej w materiałach wykładowych].

→Materiały wykładowe:

Case study 5

Dynamika rybosomów podczas odcodowywania mRNA w rekonstruowanym systemie *in vitro*, według:

Jain, Sakshi, et al. "Modulation of translational decoding by m6A modification of mRNA." *Nature communications* 14.1 (2023): 4784.

oraz w komórkach, według:

Xue, Liang, et al. "Visualizing translation dynamics at atomic detail inside a bacterial cell." *Nature* 610.7930 (2022): 205-211.

Jedną z najnowocześniejszych technik w mikroskopii elektronowej układów biologicznych jest **CryoET** (Cryo-Electron Tomography). Jest to technika mikroskopii krioelektronowej, która umożliwia rekonstrukcję trójwymiarowych struktur biologicznych w ich **natywnym środowisku komórkowym**, bez potrzeby izolacji czy krystalizacji białek. W odróżnieniu od klasycznego cryo-EM typu single particle analysis (SPA), CryoET analizuje całe przekroje komórek lub ich fragmentów, tworząc trójwymiarową rekonstrukcję (tzw. tomogram) na podstawie obrazów uzyskanych pod różnymi kątami.

Cechy CryoET:

- Umożliwia analizę białek *in situ*, czyli w ich naturalnym kontekście komórkowym (na błonach, w organellach, itp.).
- Umożliwia badanie nie tylko pojedynczych białek, ale też **kompleksów białkowych, cytoszkieletu czy rybosomów** w komórkach, w ich naturalnym kontekście funkcjonalnym.

Problemem CryoET jest często niższa rozdzielczość uzyskiwanych rekonstrukcji 3D, która wynika z pewnych ograniczeń technicznych. Generuje to problemy z rozróżnieniem czym są gęstości, które obserwujemy.

Template matching to jedna z głównych metod wykorzystywanych do automatycznej identyfikacji struktur białkowych w danych tomograficznych. Polega na porównywaniu znanych modeli strukturalnych (tzw. szablonów) z fragmentami tomogramu w celu wykrycia ich obecności i lokalizacji.

Jak działa template matching?

1. Na wejściu posiadamy:
 - Tomogram 3D (czyli objętość komórkowa zawierająca wiele nieoznaczonych struktur),
 - Model referencyjny – np. struktura rybosomu lub kompleksu białkowego (często w formacie PDB),
2. Szablon jest obracany i przesuwany w tomogramie w różnych pozycjach i orientacjach.
3. Dla każdego położenia liczona jest korelacja przestrzenna – miara dopasowania.
4. Pozycje z najwyższą korelacją traktowane są jako potencjalne miejsca występowania danego białka.

Template matching stosuje się do identyfikowania znanych kompleksów (np. rybosomów, proteasomów) w skrawkach komórkowych, lokalizacji białek względem struktur ultrastrukturalnych (błony, mikrotubule), tworzenia map dystrybucji określonych białek w obrębie całych komórek, oraz weryfikacji obecności konkretnego białka w próbce – forma identyfikacji przestrzenno-strukturalnej.

CryoET z template matchingiem może w przyszłości stanowić uzupełnienie klasycznych metod identyfikacji (spektrometria mas, western blot, immunofluorescencja), dostarczając unikalnej informacji o lokalizacji przestrzennej białek, ich konformacjach i kompleksach w jakie wchodzą, oraz o ich funkcjonalnym kontekście w komórce. Dzięki temu możliwe staje się nie tylko potwierdzenie obecności konkretnego białka, ale także analiza jego roli w strukturach komórkowych, co ma szczególne znaczenie w badaniach mechanizmów molekularnych i patologii chorób.

→Materiały wykładowe:

Case study 6

Integrowanie danych ze spektrometrii masowych z danymi strukturalnymi w celu odkrywania mechanizmów działania kompleksów białkowych, według: O'Reilly, Francis J., et al. "In-cell architecture of an actively transcribing-translating expressome." *Science* 369.6503 (2020): 554-557.

4.5 Integracja danych i przyszłość identyfikacji

Nowoczesna proteomika coraz częściej integruje dane z różnych źródeł. Przykładowo, wyniki spektrometrii masowej można wykorzystać do potwierdzenia obecności białek w strukturach Cryo-EM, a modele strukturalne – do poprawienia jakości dopasowania widm MS/MS (np. przez uwzględnienie dostępności peptydów w strukturze białka).

Dzięki takim integracyjnym podejściom identyfikacja białek staje się nie tylko dokładniejsza, ale też bardziej biologicznie trafna. Obserwujemy przesunięcie od „listy białek” ku zrozumieniu ich funkcji w kontekście strukturalnym i interakcyjnym.

Zadania 6 i 7

Zadanie 6.

W kilku zdaniach opisz, jak spektrometria mas pozwala zidentyfikować białko w próbce biologicznej.

W swojej odpowiedzi uwzględnij pojęcia:

- trypsyna (enzym rozcinający białka na krótsze peptydy),
- masa cząsteczkowa peptydu (m/z),
- widmo MS/MS (fragmentacja peptydu),
- baza danych sekwencji (np. UniProt).

Zadanie 7.

Wejdź na serwer PeptideCutter: https://web.expasy.org/peptide_cutter/

Wyszukaj ludzkie białko **p53** (UniProt ID: P04637). Odpowiedz na pytania:

1. Na ile fragmentów podzieliłaby to białko **trypsyna**?
2. Przejdź na stronę **PhosphoSitePlus** (<https://www.phosphosite.org>) i wyszukaj to samo białko (tak jak w zadaniu 3). Jakie **modyfikacje potranslacyjne** (np. fosforylacja, acetylacja, ubikwitynacja) są opisane dla p53?
3. Skąd pochodzą te dane i jaką rolę odgrywa **spektrometria mas** w ich identyfikacji?

5. Metody kwantyfikacji białek w proteomice

5.1 Wstęp

Kwantyfikacja białek – czyli określenie ich ilości względnych lub bezwzględnych – stanowi drugi filar badań proteomicznych, zaraz obok identyfikacji. Pozwala odpowiedzieć na pytania nie tylko o to, **czy** dane białko występuje w próbce, ale również **ile** go jest i jak jego poziom zmienia się pomiędzy warunkami biologicznymi (np. w odpowiedzi na leczenie, infekcję, mutację genetyczną).

Współczesna proteomika oferuje wiele strategii kwantyfikacji, które różnią się podejściem, dokładnością, wymaganiami sprzętowymi i zastosowaniem. Najogólniej dzieli się je na metody znakowane (label-based) i niezankowane (label-free), z dodatkowym podziałem na podejścia oparte na spektrometrii mas oraz techniki alternatywne, takie jak metody immunologiczne czy fluorescencyjne.

5.2 Metody znakowane (label-based)

W podejściu znakowanym próbki biologiczne są oznaczane różnymi znacznikami chemicznymi, izotopowymi lub peptydowymi, które umożliwiają ich rozróżnienie podczas wspólnej analizy spektrometrii masowej. Takie metody zapewniają wysoką precyzję i powtarzalność, ponieważ próbki są analizowane jednocześnie w tej samej próbie MS.

A. SILAC (Stable Isotope Labeling by Amino Acids in Cell Culture)

Jedna z najwcześniej opracowanych technik znakowanych, SILAC polega na inkorporacji ciężkich izotopów (np. ^{13}C , ^{15}N) do białek podczas hodowli komórkowej. Dzięki temu uzyskuje się białka, które różnią się masą, ale są identyczne pod względem chemicznym z naturalnymi odpowiednikami. Po analizach próbki znakowanej i nieznakowanej, można precyzyjnie porównać względne ilości białek.

SILAC znajduje zastosowanie głównie w badaniach in vitro, jednak nie jest odpowiednia dla próbek klinicznych czy tkanek, gdzie nie ma możliwości kontrolowanego wzrostu komórek w obecności znakowanych aminokwasów.

B. iTRAQ i TMT

Techniki takie jak **iTRAQ (Isobaric Tags for Relative and Absolute Quantitation)** oraz **TMT (Tandem Mass Tags)** wykorzystują znakowanie peptydów chemicznie modyfikowanymi tagami izobarycznymi. Po trawieniu białek enzymem, peptydy są znakowane i łączone w jedną próbkę, analizowaną w spektrometrze. Kwantyfikacja opiera się na pomiarze intensywności reporterów generowanych na etapie fragmentacji (MS/MS).

Ich największą zaletą jest możliwość równoczesnej analizy nawet do 16 próbek, co pozwala na efektywne porównanie wielu warunków eksperymentalnych. Wadą jest skomplikowana analiza danych i potencjalna interferencja między sygnałami reporterów.

Metoda działania

1. Izolacja i trawienie białek

Białka z różnych próbek (np. różnych warunków eksperymentalnych) są izolowane i trawione enzymatycznie (zwykle trypsyną) do peptydów.

2. Znakowanie peptydów

Każda próbka jest znakowana innym izobarycznym znacznikiem iTRAQ lub TMT. Znaczniki mają identyczną masę całkowitą, więc nie wpływają na separację peptydów w etapie LC-MS przed fragmentacją.

3. Połączenie próbek

Znakowane próbki są mieszane i analizowane łącznie w jednej sesji spektrometrii mas.

4. Fragmentacja w MS/MS

W trakcie fragmentacji (MS/MS) każdy znacznik uwalnia swój unikalny „reporter ion” – krótki fragment o określonej masie (np. 114, 115, 116 Da dla iTRAQ). Ich intensywności odzwierciedlają ilość peptydu w danej próbce.

5. Kwantyfikacja

Porównując intensywność tych „reporterów”, określamy względne ilości peptydów (a więc i białek) w różnych próbkach.

5.3 Metody nieznakowane (label-free)

W przypadku metod nieznakowanych, każda próbka analizowana jest osobno, bez wcześniejszego znakowania. Takie podejście jest prostsze technicznie i tańsze, ale bardziej podatne na błędy związane z zmiennością analizy między próbkami.

A. Oparte na intensywności sygnału

Najczęściej stosowaną metodą nieznakowaną jest pomiar intensywności sygnału (peak intensity) odpowiadającego określonemu peptydowi lub białku. Zakłada się, że większa ilość danego białka w próbce skutkuje wyższą intensywnością sygnału jonów. Dane wymagają normalizacji i standaryzacji, ale w zamian dostarczają szerokiego spektrum informacji ilościowej. Przykładowe oprogramowanie wspierające tę metodę to MaxQuant, Skyline, Proteome Discoverer czy OpenMS.

Alternatywnym podejściem jest **zliczanie sygnałów MS/MS** przypisanych do danego białka – zakłada się, że im więcej fragmentów peptydów danego białka udało się zidentyfikować, tym wyższa jest jego obfitość. Metoda ta jest mniej precyzyjna niż analiza intensywności, ale bywa przydatna przy analizie dużych zbiorów danych lub dla bardzo niskich stężeń.

B. Bezwzględna kwantyfikacja

Większość metod proteomicznych dostarcza danych **ilości względnych**, pozwalając na porównanie poziomów białek między próbkami. Jednak w niektórych zastosowaniach – np. w badaniach klinicznych – konieczne jest określenie **bezwzględnych** stężeń białek (np. ng/ml).

C. SRM / MRM / PRM

Techniki takie jak **Selected Reaction Monitoring (SRM)**, **Multiple Reaction Monitoring (MRM)** oraz **Parallel Reaction Monitoring (PRM)** są oparte na celowanej spektrometrii masowej. Umożliwiają detekcję i kwantyfikację wybranych białek (lub peptydów) z bardzo wysoką czułością i specyficznością, często z użyciem syntetycznych peptydów referencyjnych jako standardów kalibracyjnych.

Są to metody szczególnie przydatne w walidacji biomarkerów, monitorowaniu odpowiedzi terapeutycznych lub analizie białek o bardzo niskim poziomie ekspresji.

5.4 Inne techniki kwantyfikacji białek

A. Western blot, ELISA i inne metody immunologiczne

Klasyczne metody immunochemiczne, takie jak Western blot czy ELISA nie zaliczają się do wysokoprzepustowej proteomiki, ale warto o nich wspomnieć, ponieważ nadal są używane do kwantyfikacji białek, szczególnie w badaniach walidacyjnych. Charakteryzują się wysoką specyficznością, jednak są ograniczone przez dostępność przeciwciał.

B. Kwantyfikacja oparta na mikroskopii

W przypadku technik obrazowania – np. mikroskopii fluorescencyjnej lub super rozdzielczej – również możliwa jest półilościowa lub względna ocena poziomu białek, najczęściej poprzez intensywność fluorescencji lub liczbę punktów sygnałowych.

C. SDS-PAGE i analiza densytometryczna

Jedną z najstarszych i najprostszych metod oceny ilościowej białek jest elektroforeza w żelu poliakryloamidowym z siarczanem dodecylosodu – **SDS-PAGE**. Białka są rozdzielane według masy cząsteczkowej, po czym wizualizowane przy użyciu barwników takich jak Coomassie Brilliant Blue czy srebro. Choć metoda ta jest głównie wykorzystywana do analizy jakościowej (np. sprawdzenia czystości preparatu), możliwa jest także prosta kwantyfikacja.

Po elektroforezie żele są skanowane i analizowane **densytometrycznie** – oprogramowanie oblicza intensywność sygnału (obszar pod krzywą) dla każdego prążka, co stanowi miarę względnej ilości białka. Porównując intensywności z serią standardów o znanym stężeniu, można uzyskać nawet przybliżone wartości bezwzględne.

Metoda ta jest niedroga, dostępna i niezależna od spektrometrii masowej, ale jej czułość i rozdzielczość są ograniczone – szczególnie w przypadku białek niskiej obfitości lub o

zbliżonej masie. W niektórych, wąskich przypadkach, jest to nadal przydatne narzędzie do określenia przybliżonego stężenia białka w danej próbce.

D. Metody chromatograficzne

Wysokociśnieniowa chromatografia cieczowa (HPLC) oraz jej bardziej zaawansowane warianty – takie jak **UPLC (Ultra-Performance Liquid Chromatography)** – są stosowane nie tylko do oczyszczania i rozdzielania białek, ale również do ich **ilościowej analizy**. W tym przypadku podstawą jest pomiar sygnału absorbancji (np. przy 280 nm) lub fluorescencji związanej z obecnością białka w kolumnie.

Kwantyfikacja chromatograficzna może być bardzo dokładna, szczególnie gdy stosuje się wewnętrzne standardy lub krzywe kalibracyjne. W połączeniu z detekcją masową (LC-MS) pozwala na kompleksowe podejście: rozdział, identyfikację i kwantyfikację w jednym układzie.

Niektóre warianty – np. chromatografia jonowymienna (IEX), w odwróconych fazach (RP-HPLC) czy żelowa (SEC) – są stosowane do oceny czystości lub stanu agregacji białek, co może mieć znaczenie przy analizie terapeutycznej lub strukturalnej.

→Materiały wykładowe:

Case study 7

Analiza proteomiczna komórek raka wątroby opornego na insulinę według: Yan, Jing, et al. "iTRAQ-Based Proteome Profiling of Differentially Expressed Proteins in Insulin-Resistant Human Hepatocellular Carcinoma." *Frontiers in Cell and Developmental Biology* 10 (2022): 836041.

5.5 Narzędzia bioinformatyczne wspierające kwantyfikację

Kwantyfikacja białek generuje ogromne ilości danych, dlatego kluczową rolę odgrywa odpowiednie oprogramowanie. Przykłady najczęściej stosowanych narzędzi to:

- **MaxQuant** – analiza danych LC-MS/MS, wsparcie dla iTRAQ, TMT, SILAC, label-free.
- **Skyline** – bardzo elastyczne narzędzie do analizy danych PRM, SRM i DIA.

- **OpenMS** – framework open-source do przetwarzania i kwantyfikacji danych MS.
- **Proteome Discoverer** – komercyjne rozwiązanie firmy Thermo Fisher z modułami kwantyfikacji i statystyki.

Zadania 8 i 9

Zadanie 8

Przeczytaj krótkie streszczenie, a następnie odpowiedz na pytania.

W metodzie Label-Free Quantification (LFQ) ilość białek porównuje się pomiędzy próbkami na podstawie intensywności sygnałów peptydów w spektrometrii mas, bez użycia znaczników izotopowych.

Wartości intensywności są normalizowane i wyrażane jako $\log_2$ fold change, który pokazuje, jak zmienia się poziom danego białka pomiędzy warunkami (np. kontrola vs leczenie).

Wskazówka:

Jak obliczyć $\log_2$ fold change?

$$\text{Log}_2 \text{ Fold Change} = \log_2 \left(\frac{\text{Ekspresja leczenie}}{\text{Ekspresja kontrola}} \right)$$

Jeśli nie ma zmian, wynik będzie równy 0. Wzrost wartości będzie miał >0 , a spadek <0 .

- Co oznacza, że białko ma $\log_2 \text{FC} = 0$?
- Co oznacza, że $\log_2 \text{FC} = +2$ lub $\log_2 \text{FC} = -1$?
- Jakie mogą być biologiczne przyczyny wzrostu lub spadku ekspresji danego białka po leczeniu?

Zadanie 9

Poniżej znajdują się przykładowe wartości intensywności białek (arbitralne jednostki LFQ) w warunkach „kontrola” i „leczenie”:

Białko	Ctrl_1	Ctrl_2	Drug_1	Drug_2
A	100	120	400	420
B	200	180	100	90
C	50	55	52	54
D	80	82	160	170

E	500	480	125	130	
---	-----	-----	-----	-----	--

a) Oblicz średnią wartość intensywności dla każdego białka w warunkach kontrolnych i po leczeniu.

b) Oblicz $\log_2$ fold change = $\log_2(\text{leczenie}/\text{kontrola})$.

c) Zaznacz, które białka są regulowane w górę ($\log_2 \text{FC} > 0$), a które w dół ($\log_2 \text{FC} < 0$).

d) Narysuj prosty wykres słupkowy zmian ekspresji.

6. Analiza danych potranslacyjnych modyfikacji białek (PTMs)

6.1 Wstęp

Potranslacyjne modyfikacje białek (Post-Translational Modifications, PTMs) to zmiany chemiczne, jakie zachodzą w białkach po ich translacji. Proces ten znacząco zwiększa różnorodność funkcjonalną proteomu i odgrywa kluczową rolę w regulacji niemal wszystkich procesów komórkowych – od przekazywania sygnałów, przez regulację cyklu komórkowego, aż po odpowiedź immunologiczną czy rozwój chorób nowotworowych.

Typowe modyfikacje obejmują m.in. fosforylację, acetylację, ubikwitynację, metylację, glikozylację, nitrozylację, sumoilację, przecinanie łańcuchów czy tworzenie mostków disiarczkowych. Niektóre PTMs są odwracalne i dynamicznie regulowane, inne – trwałe i nieodwracalne.

Z biologicznego punktu widzenia, zrozumienie PTMs jest niezbędne do interpretacji funkcji białek i ich stanu fizjologicznego. Z perspektywy proteomiki – stanowi to jedno z największych wyzwań analitycznych, wymagających precyzyjnych metod eksperymentalnych i zaawansowanych narzędzi bioinformatycznych.

6.2 Wyzwania w analizie PTMs

Analiza PTMs jest trudniejsza niż klasyczna identyfikacja białek, ponieważ:

- **PTMs są substechiometryczne** – tylko część cząsteczek z całej puli danego białka jest zmodyfikowana (nie zawsze wszystkie cząsteczki danego białka muszą być zmodyfikowane).
- **Często mają charakter przejściowy i niestabilny.**
- **Zmiana masy po modyfikacji może być bardzo niewielka** – np. fosforylacja zwiększa masę peptydu o zaledwie 79,97 Da – nie da się takiej różnicy

zaobserwować na klasycznym żelu w elektroforezie SDS-Page (ale są dostępne modyfikacje tej metody, umożliwiające wizualizację niektórych modyfikacji).

- **Lokalizacja PTM na konkretnym aminokwasie** wymaga wysokiej rozdzielczości i dokładności spektrometrii.
- Istnieje duża liczba możliwych modyfikacji i ich kombinacji na danym białku, co komplikuje obraz i utrudnia interpretację.

6.3 Strategie analizy PTMs

→ Eksperymentalna detekcja PTMs

W laboratoriach, identyfikacja PTMs opiera się głównie na technikach spektrometrii masowej (MS), ale wymaga dodatkowych zabiegów:

1. **Wzbogacanie próbek** – np. przez immunoprecypitację (dla fosfoprotein), oczyszczanie (IMAC, TiO₂) czy wybiórcze wiązanie glikoprotein.
2. **Trawienie enzymatyczne** – trypsyna i inne proteazy używane do generowania peptydów.
3. **Analiza MS/MS** – wysoka rozdzielczość i dokładność masy są kluczowe, szczególnie w detekcji i lokalizacji PTMs.
4. **Fragmentacja** – techniki takie jak ETD (electron-transfer dissociation) lub HCD (higher-energy collisional dissociation) są preferowane dla zachowania delikatnych modyfikacji.

→ Bioinformatyczna identyfikacja PTMs

Po uzyskaniu danych MS/MS, identyfikacja modyfikacji wymaga specjalistycznych narzędzi do:

- **Przeszukiwania baz danych z uwzględnieniem modyfikacji** (np. jako zmiennych w algorytmie wyszukiwania),
- **Lokalizacji miejsca modyfikacji** (czyli przypisania jej do konkretnego aminokwasu),

- Weryfikacji wyników i oceny ich wiarygodności.

→ Narzędzia do identyfikacji PTMs

- **MaxQuant** – jeden z najczęściej używanych pakietów do analizy danych MS, wspiera m.in. fosforylację, acetylację, ubikwitynację; zawiera algorytm lokalizacji PTM o nazwie *Andromeda*.
- **Mascot** – klasyczny silnik wyszukiwania z możliwością zadania modyfikacji stałych i zmiennych.
- **PEAKS** – oprogramowanie wspierające *de novo* identyfikację PTMs, co pozwala wykrywać rzadkie lub nowe modyfikacje.
- **PTMProphet** – narzędzie do oceny lokalizacji modyfikacji i statystycznej analizy danych z PTMs.
- **MSFragger + FragPipe** – nowoczesny pipeline do szybkiego przeszukiwania z PTMs.

→ Wizualizacja i integracja danych

Wizualizacja danych PTM często wymaga specjalistycznych przeglądarek:

- **ProteoWizard + Skyline** – do przeglądania chromatogramów i potwierdzania fragmentów.
- **PhosphoSitePlus** – do integracji z biologicznymi adnotacjami i sieciami interakcji.
- **UniProt** – sekcja "PTM / Processing" zawiera zweryfikowane dane nt. znanych modyfikacji.

6.4 Typowe rodzaje modyfikacji i ich analiza

Modyfikacje potranslacyjne są „umieszczane” na białkach przez inne enzymy, które rozpoznają określony motyw w sekwencji i strukturze modyfikowanego targetu. Znając dokładne mechanizmy molekularne działania enzymów modyfikujących białka potranslacyjnie, jesteśmy w stanie przewidzieć, w jakich regionach możemy spodziewać się określonej modyfikacji.

Fosforylacja

- Dotyczy głównie reszt seryny, treoniny i tyrozyny.
- Jest często analizowana w badaniach sygnalizacji komórkowej.
- Wymaga wzbogacania (IMAC, TiO_2) i wysokiej precyzji MS.

Ubikwitynacja

- Polega na przyłączeniu małego białka – ubikwityny – do lizyny.
- W analizie spektrometrii mas stosuje się trawienie trypsyną, enzymem, który rozcina peptydy po resztach lizyny (K) i argininy (R). Jeśli lizyna jest ubikwitynowana, nie zostaje przecięta w tym miejscu. Gdy ubikwitynowane białko jest trawione trypsyną, to sama ubikwityna (też będąca białkiem) również zostaje strawiona – ale pozostawia po sobie charakterystyczny fragment, który pozostaje przyłączony do lizyny w zmodyfikowanym białku. Tym fragmentem jest: diglicyna (GG) – czyli dwuaminokwasowy „ogon” składający się z dwóch reszt glicyny.
- W analizie stosuje się enzymatyczne "trypsynowe ślady" (GG remnant) jako dowód modyfikacji.

Acetylacja / metylacja

- Częste w histonach i innych regulatorach genowych.
- Analiza wymaga lokalizacji pojedynczego atomu, dlatego technika MS musi być wysoce precyzyjna.

Glikozylacja

- Trudna do analizy ze względu na heterogeniczność glikanów.
- Często wymaga odseparowania glikanów i analizy MS/MS w trybie negatywnym.

6.5 Bazy danych PTMs

Wspomagają analizę i interpretację modyfikacji poprzez porównanie z literaturą i danymi eksperymentalnymi:

- **PhosphoSitePlus** – bogata baza PTMs z danymi literaturowymi i eksperymentalnymi (ludzkie, mysie).
- **UniProt** – adnotacje PTM w obrębie sekwencji białek.
- **dbPTM** – baza PTM z funkcjami predykcyjnymi i strukturalnymi.
- **PTMcode** – sieci modyfikacji i analiza współwystępowania (crosstalk) między PTMs.

6.6 Znaczenie biologiczne analizy PTMs

Identyfikacja i kwantyfikacja PTMs ma istotne znaczenie w wielu biologicznych procesach, które są istotne z punktu widzenia medycyny. Są to na przykład obszary takie jak:

- **Signaling komórkowy** – np. fosforylacja kinaz, szlak MAPK.
- **Choroby neurodegeneracyjne** – np. hiperfosforylacja TAU w chorobie Alzheimera.
- **Onkologia** – zaburzenia ubikwitynacji i acetylacji w nowotworach.
- **Badania farmakologiczne** – np. aktywacja białek przez modyfikacje lub ich blokowanie.

Znaczenie modyfikacji potranslacyjnych białek oraz ich dynamiki postaramy się przeanalizować na przykładzie badań spike protein wirusa SARS-CoV-2, mających ogromne znaczenie w zrozumieniu biologii wirusa, który sparaliżował cały świat podczas ostatniej pandemii, oraz w opracowywaniu nowych, skutecznych strategii terapeutycznych. Przy okazji poznamy **nowe narzędzie**, które może okazać się przydatne w analizach strukturalno-funkcjonalnych białek błonowych.

→Materiały wykładowe:

Case study 8

Dynamika białka spike, znaczenie glikanów i GlycoSHIELD, według:

Turoňová, Beata, et al. "In situ structural analysis of SARS-CoV-2 spike reveals flexibility mediated by three hinges." *Science* 370.6513 (2020): 203-208.

oraz

Tsai, Yu-Xi, et al. "Rapid simulation of glycoprotein structures by grafting and steric exclusion of glycan conformer libraries." *Cell* 187.5 (2024): 1296-1311.

Zadanie 10

Zadanie 10.

W tym zadaniu przyjrzymy się fosforylacjom ludzkiego białka EGFR (Epidermal Growth Factor Receptor), które odgrywa kluczową rolę w sygnalizacji komórkowej.

Zweryfikuj modyfikacje w UniProt i PhosphoSitePlus

UniProt:

<https://www.uniprot.org/uniprot/P00533>

(białko EGFR – Homo sapiens)

- Przejdź do zakładki „PTM / Processing”.
- Sprawdź, czy fosforylacje są opisane, i jeśli tak – w jakich pozycjach.

PhosphoSitePlus:

<https://www.phosphosite.org>

- Wyszukaj: "EGFR_HUMAN"
- Sprawdź: Czy są dane o fosforylacjach? Ile pozycji? Jakie aminokwasy i jakie miejsca?

7. Interakcje białkowe i sieci białkowe w proteomice

7.1 Wstęp

W biologii komórki żadne białko nie działa w izolacji. Każda jego funkcja, lokalizacja, aktywność czy stabilność zależy od interakcji z innymi cząsteczkami – zarówno z innymi białkami, jak i z DNA, RNA, metabolitami czy elementami budującymi komórkę (np. błony). Dlatego zrozumienie interakcji białkowych (protein-protein interactions, PPI) jest niezbędne do pełnego poznania procesów biologicznych.

W proteomice badanie PPI przybrało wymiar systemowy. Zamiast skupiać się na jednej parze interakcji, współczesne podejścia analizują całe sieci oddziaływań białek (protein interaction networks), co pozwala tworzyć modele funkcjonalne komórek, identyfikować kluczowe regulatory i potencjalne cele terapeutyczne.

Podsumowując, badanie interakcji białkowych i sieci funkcjonalnych pomaga zrozumieć:

- Kompleksy białkowe i ich dynamikę,
- Organizację funkcjonalną komórki (kompartmentalizacja),
- Sieci sygnalizacji i odpowiedzi na bodźce,
- Mechanizmy chorób, szczególnie nowotworowych i neurodegeneracyjnych,
- Efekty działania leków i możliwości ich modulacji.

7.2 Rodzaje interakcji białkowych

Interakcje białkowe mogą mieć różny charakter:

- **Trwałe** – np. w strukturach stałych (rybosom, kompleksy błonowe),
- **Przejściowe** – np. interakcje enzym-substrat, czynnik transkrypcyjny-DNA,
- **Specyficzne** – dotyczące konkretnych miejsc wiązania,
- **Niespecyficzne** – np. wynikające z oddziaływań hydrofobowych, niskiej siły wiązań.

Interakcje mogą zachodzić pomiędzy dwoma białkami (binary PPI), wieloma białkami tworzącymi kompleksy, w określonym punkcie w czasie, np. w odpowiedzi na bodziec lub podczas cyklu komórkowego.

7.3 Metody wykrywania interakcji białkowych

A. Metody eksperymentalne

1. Koimmunoprecypitacja (Co-IP)

Klasyczna metoda biochemiczna – białko „przynęta” jest wyłapywane z ekstraktu komórkowego przy pomocy specyficznego przeciwciała, a interaktory identyfikowane technikami MS.

- Zaleta: analiza natywnych kompleksów.
- Wada: słaba rozdzielczość dla nietrwałych interakcji przejściowych.

2. Spektrometria masowa po wzbogaceniu kompleksów (AP-MS)

Affinity purification-MS pozwala wyłapać kompleksy białek i zidentyfikować ich skład w sposób systemowy.

- Zaleta: możliwość badania wielobiałkowych zespołów.
- Często stosowana z tagami (np. GFP, FLAG).

3. Crosslinking-MS (XL-MS)

Metoda pozwala chemicznie „związać” (za pomocą dodatku dedykowanych odczynników chemicznych do próbki) blisko położone reszty białkowe, co pomaga lokalizować kontaktowe domeny w obrębie kompleksu.

4. BioID / TurboID

Enzymatyczne znakowanie sąsiednich białek w żywych komórkach (biotynylacja), a następnie identyfikacja partnerów metodą MS.

B. Metody bioinformatyczne

1. **Predykcja interakcji** – na podstawie danych strukturalnych, homologii, korelacji ekspresji.
2. **Integracja danych omicznych** – z genetyki, transkryptomiki i filogenezy.
3. **Modelowanie strukturalne** – wykrywanie miejsc wiązania (docking), np. za pomocą AlphaFold-Multimer.
4. **Symulacje dynamiki molekularnej** – analiza stabilności i siły interakcji.

7.4 Sieci białkowe: tworzenie i analiza

Dane o interakcjach białkowych można przedstawić w formie sieci (graph), w której:

- Wierzchołki (nodes) reprezentują białka,
- Krawędzie (edges) – interakcje pomiędzy nimi.

Takie sieci mogą być analizowane za pomocą narzędzi bioinformatycznych, aby:

- Identyfikować **huby (białka o dużej liczbie interakcji)** – często kluczowe regulatory,
- Wykrywać **moduły funkcyjne** – np. zespoły rybosomowe, szlaki metaboliczne,
- Analizować **ścieżki sygnałowe** i zaburzenia w chorobach.

7.5 Narzędzia i bazy danych

Bazy danych interakcji białkowych:

- **STRING** (<https://string-db.org>) – integruje dane eksperymentalne, przewidywane i literaturowe; umożliwia wizualizację i analizę sieci.
- **BioGRID** – baza interakcji potwierdzonych eksperymentalnie.
- **IntAct** – część inicjatywy IMEx; zawiera dane z Y2H, AP-MS, itp.
- **MINT** – kuratowana baza interakcji fizycznych.
- **HPRD** – baza dla ludzkich białek, zawierająca także dane o lokalizacji i PTMs.

Oprogramowanie do analizy:

- **Cytoscape** – najpopularniejsze narzędzie do wizualizacji i analizy sieci biologicznych; wspiera analizę klastrow, nadreprezentowania GO (gene ontology), integrację z danymi ekspresji.
- **NAViGaTOR**, **Gephi**, **NetworkAnalyst** – alternatywne środowiska do interaktywnych analiz grafowych.
- **iRefIndex** – agreguje dane z wielu źródeł interakcji białkowych.

→ Materiały wykładowe

Case study 9

Badanie interakcji między białkami, na podstawie przykładu kompleksu elongatora, według:

Abbassi, Nour-el-Hana, et al. "Cryo-EM structures of the human Elongator complex at work." *Nature Communications* 15.1 (2024): 4094.

oraz:

Scherf, David, et al. "tRNA binding to Kti12 is crucial for wobble uridine modification by Elongator." *Nucleic Acids Research* 53.7 (2025): gkaf296.

Zadania 11 i 12

W tych zadaniach poznamy narzędzia do eksploracji sieci interakcji białkowych. Zidentyfikujemy kluczowe węzły (huby) i moduły funkcjonalne, aby powiązać dane białkowe z funkcją biologiczną i potencjalnym znaczeniem chorobowym.

Zadanie 11.

1. Otwórz stronę <https://string-db.org>
2. Wyszukaj białko: TP53, organizm: Homo sapiens
3. Wygeneruj sieć interakcji (w "Settings"):

- ustaw minimum required interaction score na „high confidence” (0.700),
- pokaż max 50 interaktorów pierwszego rzędu (lub mniej jeśli za dużo),

Zadanie 12.

Eksploruj sieć:

Zidentyfikuj:

- 3 białka o największej liczbie interakcji (huby),
- 2 białka związane z nowotworami (przykładowo: BRCA1, MDM2),
- czy występują moduły funkcyjne? (np. białka regulujące cykl komórkowy, apoptozę),
- kliknij białko i sprawdź jego funkcję (zakładka: „function” i „GO terms”).

8. Metody analizy i predykcji struktury białek

8.1 Wprowadzenie

Struktura białka (co omówiono w Rozdziale 1.) – jego przestrzenne ułożenie atomów – jest kluczowa dla funkcji biologicznej. Mimo że sekwencja aminokwasów (struktura pierwszorzędowa) determinuje sposób, w jaki białko się zwiija, to ze względu na duże różnice we właściwościach łańcuchów bocznych aminokwasów białkowych, przewidzenie tej struktury było (do niedawna) zadaniem niemalże niewykonalnym, a eksperymentalne jej rozwiązanie pozostaje bardzo trudne i kosztowne. Analiza i predykcja struktury białek stanowią ważny element bioinformatyki strukturalnej, a ich znaczenie w proteomice stale rośnie, m.in. dzięki rozwojowi sztucznej inteligencji, nowym algorytmom predykcyjnym oraz integracji danych eksperymentalnych z modelami komputerowymi.

8.2 Organizacja strukturalna białek

Organizację strukturalną białek omówiono szerzej w Rodziale 1, ale przypominając, białka można opisywać na kilku poziomach strukturalnych:

- **Struktura pierwszorzędowa** – liniowa sekwencja aminokwasów,
- **Struktura drugorzędowa** – lokalne motywy, jak α -helisy, β -harmonijki,
- **Struktura trzeciorzędowa** – trójwymiarowe ułożenie całego łańcucha,
- **Struktura czwartorzędowa** – sposób, w jaki wiele podjednostek tworzy kompleksy.

Celem bioinformatyki strukturalnej jest przewidywanie lub analizowanie tych struktur – najczęściej trzeciorzędowej i czwartorzędowej – przy użyciu dostępnych danych lub algorytmów predykcyjnych. Tylko znając przestrzenną architekturę białka, jesteśmy w stanie w pełni zrozumieć jak działa i zastosować tę wiedzę do biotechnologicznych i medycznych celów.

8.3 Metody eksperymentalne rozszyfrowywania struktur białek

A. Krystalografia rentgenowska (X-ray crystallography)

To najstarsza i jedna z najdokładniejszych metod określania struktury trójwymiarowej białek. Polega na krystalizacji białka, naświetlaniu kryształu promieniami X i analizie otrzymanego wzoru dyfrakcyjnego. Za pomocą narzędzi matematycznych jesteśmy w stanie obliczyć, jak wygląda struktura białka, która dała określony wzór dyfrakcyjny.

- Zalety: bardzo wysoka rozdzielczość (do 1–2 Å), możliwość analizy centrów aktywnych.
- Wady: wymaga krystalizacji białka (co nie zawsze jest możliwe, ze względu na to, że wiele białek jest wewnętrznie dynamicznych).

Obserwując trendy we współczesnej biologii strukturalnej, trudno nie odnieść wrażenia, że przez pewne ograniczenia metodologiczne, szczególnie w badaniu dużych, wielokomponentowych kompleksów białkowych, lub kompleksów białek z kwasami nukleinowymi, krystalografia rentgenowska traci na popularności i jest wypierana z mainstreamu przez metody mikroskopowe. Z tego powodu, my również poświęcimy więcej uwagi CryoEM.

B. Kriomikroskopia elektronowa (cryo-EM)

Technika ta polega na szybkim zamrażaniu próbek tak, aby uzyskać na dedykowanej siatce warstwę lodu amorficznego, w którym zawieszone są białka lub kompleksy białkowe. Obrazowanie następuje w warunkach próżniowych przy bardzo niskich temperaturach, za pomocą transmisyjnej mikroskopii elektronowej. W ostatniej dekadzie, dzięki rozwojowi szybkich detektorów elektronów, technika ta przeszła przez tzw. „rewolucję w rozdzielczości” i umożliwiła obrazowanie białek z rozdzielczością, która w wielu przypadkach jest porównywalnie wysoka, z rozdzielczościami uzyskiwanymi w krystalografii rentgenowskiej.

- Zalety: nie wymaga krystalizacji, doskonała do dużych, dynamicznych wewnętrznie kompleksów, badanie w roztworach zbliżonych do fizjologicznych.

- Wady: słabsza rozdzielczość dla małych białek (choć to się sukcesywnie poprawia), bardzo kosztowna infrastruktura.

Procesowanie danych Cryo-EM obejmuje szereg etapów, które prowadzą od surowych danych obrazowych do uzyskania trójwymiarowej rekonstrukcji cząsteczki. Poniżej przedstawiono typowy przebieg takiego procesu, z uwzględnieniem podstawowych operacji oraz wykorzystywanego oprogramowania.

1. Pierwszym etapem analizy jest rejestracja obrazów próbki zamrożonej w warstwie lodu na gridzie. Obrazy (mikrografie) rejestrowane są przy użyciu bezpośrednich detektorów elektronów (Direct Electron Detectors), które umożliwiają zapis tzw. "filmów" – sekwencji klatek w czasie rzeczywistym. Rejestrowany materiał zawiera dane o wielu orientacjach cząsteczek w matrycy lodowej.

Formaty danych:

- .mrc – standardowy format mikroskopowy, często stosowany w Cryo-EM
- .eer, .tiff – formaty związane z konkretnymi kamerami
- Pliki kalibracyjne, np. .gain

2. Ze względu na oddziaływanie wiązki elektronów z próbką, dochodzi do niewielkich przesunięć cząsteczek w czasie ekspozycji. Aby zminimalizować rozmycie obrazu, stosuje się korekcję ruchu próbki w każdej zarejestrowanej klatce. Wyrównanie pozwala na uzyskanie ostrzejszych, bardziej informatywnych mikrografii. Wykorzystywane w tym celu narzędzia to:

- MotionCor2 – szybka i skuteczna korekcja ruchu dla plików .mrc
- Unblur, RELION (moduł wbudowany)
- cryoSPARC patch motion correction (moduł wbudowany)

3. Funkcja przenoszenia kontrastu (Contrast Transfer Function, CTF) opisuje, jak różne przestrzenne składowe obrazu są deformowane przez układ optyczny mikroskopu. Estymacja CTF dla każdej mikrografii pozwala na odtworzenie oryginalnej amplitudy i fazy sygnału, co jest kluczowe dla dokładnej rekonstrukcji struktury.

Najczęściej używane oprogramowanie:

- CTFFIND4, Gctf, CryoSPARC CTF estimation

4. Na podstawie oczyszczonych i skorygowanych mikrografii należy zidentyfikować pojedyncze cząsteczki białek. Może to być realizowane ręcznie lub automatycznie przy użyciu algorytmów uczenia maszynowego, następującymi metodami:

- Ręczne: np. w RELION lub cryoSPARC
- Automatyczne: Topaz (uczenie głębokie), crYOLO, Warp, DeepPicker

5. Zidentyfikowane cząsteczki są wycinane i poddawane klasyfikacji dwuwymiarowej (2D), która pozwala odseparować dobrze ułożone cząsteczki od uszkodzonych, zanieczyszczonych lub źle zorientowanych. Efektem tego etapu są reprezentatywne klasy 2D pokazujące różne orientacje białka.

6. Z wybranych frakcji cząsteczek, wykorzystując różnice ich orientacji przestrzennych, buduje się trójwymiarowy model struktury. Na tym etapie konieczne jest zastosowanie algorytmów dopasowujących orientacje cząsteczek i wykonujących rekonstrukcję objętościową.

Etapy:

- *Ab initio* 3D reconstruction – tworzenie początkowego modelu
- *3D classification* – rozdzielenie cząsteczek wg konformacji
- *3D refinement* – zwiększanie rozdzielczości modelu

Narzędzia:

- RELION, CryoSPARC (są to najlepsze dostępne narzędzia, które posiadają zintegrowane moduły umożliwiające przeprowadzenie każdego z etapów anlizy).

7. Ostateczna rekonstrukcja 3D oceniana jest pod kątem rozdzielczości (np. kryterium FSC – Fourier Shell Correlation), poprawności topologii oraz zgodności z danymi biologicznymi. W tym celu przeprowadza się: filtrowanie mapy (low-pass filter),

estymację lokalnej rozdzielczości, walidację struktury atomowej (jeśli model został dopasowany)

8. Po uzyskaniu mapy gęstości elektronowej możliwe jest zbudowanie i dopasowanie modelu atomowego – ręcznie lub półautomatycznie. W tym celu wykorzystuje się oprogramowanie:

- Coot – interaktywny edytor modeli białkowych
- Phenix – dopasowanie i walidacja
- ISOLDE – dopasowanie modeli do map gęstości

C. NMR (magnetyczny rezonans jądrowy)

Działa na zasadzie pomiarów oddziaływań magnetycznych między jądrami atomów. Nadaje się do badania białek w roztworze, co pozwala obserwować dynamiczne zmiany strukturalne.

- Zalety: możliwe badanie struktury w warunkach zbliżonych do fizjologicznych.
- Wady: ograniczenie raczej do mniejszych białek (do ok. 30 kDa), złożona analiza, szczególnie w przypadku większych białek.

8.4 Metody bioinformatyczne – predykcja struktury białek

1. Metody homologii (modelowanie porównawcze)

Jeśli znana jest struktura białka o podobnej sekwencji (homologa), można przyjąć, że badane białko będzie miało podobną strukturę.

- Narzędzia: **SWISS-MODEL**, **MODELLER**.
- Wymaga: obecności homologicznego wzorca (template) o znanej strukturze.

2. Modelowanie oparte na fragmentach (threading/fold recognition)

Jeśli brak jest znanej struktury homologu białka, ale znane są ogólne typy struktur przestrzennych (tzw. folds), można próbować dopasować fragmenty sekwencji białka (domeny) do wzorców o znanych strukturach.

- Narzędzia: **Phyre2, I-TASSER, RaptorX**.

3. Modelowanie ab initio

W przypadkach, gdy nie ma dostępnych struktur homologicznych, można próbować przewidzieć strukturę całkowicie od podstaw, opierając się na zasadach fizyko-chemicznych i statystyce.

- Narzędzia: **Rosetta, QUARK, trRosetta**.
- Wyzwanie: bardzo duża przestrzeń konformacyjna do przeszukania.

4. Predykcja oparta na sztucznej inteligencji – AlphaFold

Rewolucyjny przełom przyniosło AlphaFold2 – model głębokiego uczenia opracowany przez DeepMind, który w 2021 roku zademonstrował zdolność do przewidywania struktury białek, bazując jedynie na sekwencji aminokwasowej, z najlepszą jak dotąd dokładnością spośród wszystkich innych, dostępnych narzędzi bioinformatycznych. W wielu przypadkach dokładność przewidzianych modeli jest porównywalna z danymi eksperymentalnymi. Obecnie dostępna wersja to AlphaFold3 i jest dostępna przez AlphaFold Server. Narzędzie to stało się filarem wielu badań proteomicznych, a jego predykcje dostępne są publicznie w bazie AlphaFold DB.

AlphaFold 3 umożliwia predykcję struktur białek o nieznanej konformacji, dysponując jedynie sekwencją aminokwasową, a jego wersja AlphaFold-Multimer wspiera także modelowanie interakcji białek w kompleksach.

Ważna uwaga:

Należy pamiętać, że AlphaFold produkuje jedynie predykcje, czyli przewidywania struktur, które wymagają dokładnej weryfikacji eksperymentalnej. Potencjalne

zagrożenia wynikające ze zbyt mało krytycznej interpretacji predykcji z AlphaFold zostaną omówione na kolejnym przykładzie praktycznym.

→ Materiały wykładowe

Case study 10

AlphaFold a struktury białek wiążących kwasy nukleinowe.

8.5 Analiza struktury białek

Po uzyskaniu modelu strukturalnego można przeprowadzać dalsze analizy:

- **Ocena jakości modelu** – np. Ramachandran plot, ocena energii, porównanie z wzorcami.
- **Identyfikacja centrów aktywnych, domen, motywów** – za pomocą narzędzi takich jak CASTp, Prosite, InterPro.
- **Modelowanie wiązania ligandów lub interakcji białko-białko** (tzw. *docking*).
- **Symulacje dynamiki molekularnej (MD)** – obserwacja zmian strukturalnych w czasie.
- **Porównanie struktur (superpozycja)** – za pomocą narzędzi jak PyMOL, Chimera.

8.6 Źródła danych i bazy strukturalne

- **Protein Data Bank (PDB)** – główna baza danych eksperymentalnych struktur białek.
- **AlphaFold DB** – baza zawierająca miliony predykcji struktur białek.
- **PDBe-KB** – zbiera informacje funkcjonalne i strukturalne o białkach.

Podsumowanie

Integracja danych strukturalnych z analizami proteomicznymi umożliwia dokładne mapowanie miejsc interakcji, centrów aktywnych, modyfikacji potranslacyjnych, co w efekcie daje pełne zrozumienie mechanizmów działania białek i ich funkcji biologicznych. Nowoczesne narzędzia predykcyjne dają możliwość wczesnej

weryfikacji hipotez badawczych i wnoszą projektowanie eksperymentów biochemicznych na wyższy poziom. Ułatwiają również znacząco wczesne etapy dopasowywania modeli białek do gęstości eksperymentalnych, szczególnie w przypadkach, kiedy rozwiązujemy strukturę białka, która nie ma dostępnych rozwiązanych analogów.

Predykcja i analiza struktury białek to jeden z najbardziej dynamicznie rozwijających się obszarów bioinformatyki. Dzięki połączeniu metod eksperymentalnych z nowoczesną analizą komputerową i metodami sztucznej inteligencji, możliwe staje się o wiele szybsze poznanie budowy białek. W proteomice strukturalnej otwiera to nowe drogi do interpretacji funkcji białek, projektowania leków oraz badania molekularnych podstaw chorób.

→ Materiały wykładowe

Case study 11

Integrowanie CryoEM, metod proteomicznych oraz algorytmu predykcyjnego AlphaFold w celu odkrywania działania wielkich kompleksów białkowych, na przykładzie kompleksu integratora:

Razew, Michal, et al. "Structural basis of the Integrator complex assembly and association with transcription factors." *Molecular Cell* 84.13 (2024): 2542-2552.

Zadania 13 i 14

W tych zadaniach przeprowadzisz predykcję struktury wybranego białka z wykorzystaniem zasobów AlphaFold DB, a następnie dokonasz wstępnej analizy modelu strukturalnego.

Zadanie 13.

1. Znajdź w wybranej bazie danych sekwencję białka
 - tRNA (cytosine(38)-C(5))-methyltransferase (Uniprot id : **O14717**)
2. Wejdź na serwer AlphaFold3 (<https://alphafoldserver.com/welcome>) i wklej sekwencję, uruchom predykcję.

- Format wyjściowy: .pdb lub .cif

3. Wstaw screenshoty wizualizacji. Zidentyfikuj fragmenty o niskiej ufności predykcji – czy te fragmenty mają strukturę drugorzędową?

Zadanie 14.

4. Pobierz program PyMOL lub ChimeraX. Wyświetl uzyskany w predykcji model (wybierz „model0”).
5. W bazie Uniprot sprawdź, czy dla tego białka jest dostępna jakakolwiek struktura eksperymentalna? Jeśli tak, pobierz model i również otwórz go w programie ChimeraX. (Podpowiedź: PDB id: 1G55)

W PyMOL, można nałożyć struktury poprzez wpisanie komendy: align (obiekt A), (obiekt B), gdzie obiekt – nazwa danej struktury.

W razie problemów z programem PyMOL/ChimeraX, polecam odwiedzenie strony z tutorialiem, gdzie objaśnione są wszystkie wzbudowane funkcje.

W ChimeraX użyj narzędzia “structure analysis” i “matchmaker”. Pozwoli to nałożyć model eksperymentalny na model z predykcji.

6. Bazując na dostępnych danych (np. publikacja źródłowa eksperymentalnej struktury i jej sekcja metod (<https://doi.org/10.1093/nar/29.2.439>)) zastanów się, jaki może być powód niskiego poziomu predykcji w niektórych obszarach. Jak obszary te korespondują ze strukturą eksperymentalną? Czy pokrywają się z określonym poziomem ufności predykcji?

9. Zastosowanie algorytmów uczenia maszynowego w analizie danych proteomicznych

9.1 Wprowadzenie

Wraz z gwałtownym wzrostem ilości danych generowanych przez techniki proteomiczne – zarówno eksperymentalne (spektrometria mas, cryo-EM), jak i bioinformatyczne (predykcja struktury, funkcji, modyfikacji białek) – wzrosło zapotrzebowanie na metody analizy zdolne do automatyzacji, uogólniania i wyciągania wzorców z ogromnych, złożonych zbiorów danych. W tym kontekście **uczenie maszynowe (ML – Machine Learning)** oraz **sztuczna inteligencja (AI)** odegrywają kluczową rolę w transformacji nowoczesnej bioinformatyki proteomicznej.

Uczenie maszynowe odnosi się do grupy metod, które automatycznie uczą się rozpoznawać wzorce i przewidywać wyniki na podstawie dostępnych danych, bez konieczności ręcznego programowania reguł. W proteomice, dzięki dostępności dużych zbiorów danych opisujących sekwencje, struktury, modyfikacje i interakcje białek, ML znajduje zastosowanie w wielu kluczowych obszarach.

Uczenie maszynowe na stałe weszło do arsenału narzędzi bioinformatycznych w proteomice. Umożliwia nie tylko automatyczną analizę sekwencji, struktur i funkcji białek, ale również otwiera nowe ścieżki w badaniach nad interakcjami, projektowaniem leków i integracją danych wielkoskalowych. Dzięki modelom takim jak AlphaFold, PIPR czy DeepGO, naukowcy mogą wzmacniać hipotezy startowe projektów o wyniki predykcji, oraz coraz szybciej przekształcać dane surowe w biologiczne wnioski.

Główne typy uczenia maszynowego w proteomice:

1. Uczenie nadzorowane (supervised learning)

Wymaga zestawu danych uczących (np. sekwencji białek z przypisaną funkcją), na podstawie których model uczy się dokonywać predykcji. Używane np. do klasyfikacji funkcji białek, przewidywania lokalizacji komórkowej, interakcji białkowych.

2. **Uczenie nienadzorowane (unsupervised learning)**

Pozwala odkrywać ukryte wzorce lub grupy (klastry) w danych bez przypisanych etykiet. Stosowane m.in. do analizy profili ekspresji białek czy detekcji tzw. outlierów.

3. **Uczenie głębokie (deep learning)**

Wykorzystuje sieci neuronowe o wielu warstwach. Jest szczególnie skuteczne w pracy z danymi sekwencyjnymi, obrazowymi i strukturalnymi.

4. **Uczenie przez wzmocnienie (reinforcement learning)**

Rzadziej wykorzystywane w proteomice, ale pojawiają się próby jego użycia w modelowaniu dynamiki białek lub projektowaniu sekwencji.

9.2 Przykłady zastosowań uczenia maszynowego w proteomice

1. **Predykcja funkcji białek na podstawie sekwencji**

Uczenie maszynowe umożliwia przypisanie funkcji nieznanym białkom (np. z genomów nieopisanych organizmów) na podstawie sekwencji aminokwasów, domen i motywów.

- Narzędzia: **DeepGO, ProtFun, PANNZER2, DeepFRI**
- Dane wejściowe: sekwencje FASTA, profile ewolucyjne, GO annotations
- Zastosowanie: automatyczna anotacja białek w bazach danych, predykcja ról enzymatycznych i biologicznych

2. **Predykcja lokalizacji komórkowej**

Uczenie nadzorowane może analizować sygnały lokalizacyjne (np. peptydy sygnałowe, kotwiczenie w błonach) i przewidywać miejsce działania białka.

- Narzędzia: **DeepLoc, WoLF PSORT, TargetP**
- Architektura: CNN i RNN analizujące sekwencje

3. Predykcja interakcji białko-białko (PPI)

Uczenie maszynowe pomaga przewidzieć, które białka potencjalnie oddziałują ze sobą, na podstawie sekwencji, struktury lub danych z eksperymentów.

- Metody: modele SVM, sieci neuronowe, sieci grafowe (Graph Neural Networks, GNN)
- Narzędzia: **PIPR**, **D-SCRIPT**, **DeepPPI**
- Zastosowanie: rekonstrukcja sieci białkowych, analiza interaktomów

4. Predykcja struktury białek

Najbardziej spektakularnym przykładem zastosowania ML w bioinformatyce białek jest predykcja ich struktury trójwymiarowej. Przełom nastąpił wraz z premierą **AlphaFold2**, który przewiduje strukturę białka wyłącznie na podstawie sekwencji z dokładnością porównywalną z eksperymentem.

- Narzędzia: **AlphaFold3**, **RoseTTAFold**
- Wykorzystane technologie: głębokie sieci neuronowe, mechanizm attention, multiple sequence alignment (MSA)

5. Identyfikacja miejsc modyfikacji posttranslacyjnych (PTMs)

ML może rozpoznawać potencjalne miejsca modyfikacji takich jak fosforylacja, acetylacja, ubikwitynacja, na podstawie sekwencji i kontekstu strukturalnego.

- Narzędzia: **MusiteDeep**, **PhosID**, **DeepPhos**
- Dane wejściowe: sekwencje białek, kontekst sąsiadujących reszt

9.3 Przyszłość i wyzwania

Choć algorytmy ML przynoszą znakomite rezultaty, ich stosowanie w proteomice wiąże się z pewnymi wyzwaniami:

- **Brak wystarczających danych wysokiej jakości** – w wielu przypadkach dane są niepełne lub zawierają błędy.

- **Nadmierne dopasowanie modeli (overfitting)** – zwłaszcza przy niewielkich zbiorach.
- **Brak interpretowalności modeli** – niektóre sieci neuronowe działają jak „czarne skrzynki”.
- **Integracja różnych typów danych** – konieczność łączenia danych sekwencyjnych, strukturalnych, ekspresyjnych i eksperymentalnych.

Zadania 15 i 16

W tych zadaniach rozważymy możliwości wykorzystania narzędzi ML do zbadania struktury, funkcji i potencjalnych interakcji białek, na przykładzie dobrze poznanych białek wchodzących w skład dużego kompleksu – rybosomu 80S (duża i mała podjednostka) u człowieka.

Zadanie 15.

1. Wybierz trzy białka rybosomalne z kompleksu 80S

Można skorzystać z bazy PDB lub UniProt, np.:

- RPL3, RPS6, RPL13A, RPS27A

2. Dla każdego z wybranych białek:

- Pobierz sekwencję aminokwasową (format FASTA).
- Użyj narzędzia ML do *predykcji funkcji* (np. DeepGOPlus lub PANNZER2).
- Użyj narzędzia ML do *predykcji lokalizacji komórkowej* (np. DeepLoc 2.0).
- (Opcjonalnie) Skorzystaj z AlphaFold/ColabFold, aby przewidzieć 3D strukturę białka.

Zadanie 16.

Podsumuj wyniki:

- Jakie funkcje zostały przewidziane? Czy zgadzają się z anotacjami z UniProt?
- Czy lokalizacja białek ma sens w kontekście rybosomu?

10. Wizualizacja danych proteomicznych

10.1 Wstęp

Jak już wiele razy zostało to podkreślone, w proteomice ilość generowanych danych – zarówno ilościowych, jakościowych, jak i strukturalnych – jest ogromna. Dane te obejmują setki lub tysiące białek, ich poziomy ekspresji, modyfikacje potranslacyjne, lokalizacje komórkowe czy interakcje z innymi białkami. Wizualizacja tego typu danych stanowi kluczowy etap analizy, ponieważ umożliwia ich interpretację biologiczną, identyfikację wzorców, anomalii oraz relacji pomiędzy badanymi elementami.

W odróżnieniu od klasycznych tabel i zestawień, metody wizualizacji przekładają złożone dane numeryczne na formy graficzne, które są bardziej przystępne dla oka i łatwiejsze do interpretacji. W tym rozdziale przedstawione zostaną najważniejsze rodzaje wizualizacji stosowane w analizie proteomicznej oraz przykłady narzędzi i bibliotek używanych do ich generowania.

10.2 Podstawowe wykresy w analizie proteomicznej

Wykresy słupkowe i pudełkowe

W przypadku mniejszych zbiorów danych, podstawowe wykresy statystyczne, takie jak barploty (wykresy słupkowe) czy boxploty (wykresy pudełkowe), pozwalają na wizualizację poziomu ekspresji wybranych białek w różnych warunkach. Mogą pokazywać zmiany poziomu danego białka między próbkami np. zdrowymi i chorymi.

Boxploty dodatkowo prezentują rozkład danych, ich mediany oraz obecność potencjalnych wartości odstających (ang. outliers), co ma znaczenie przy ocenie jakości danych.

Wykresy rozrzutu (scatter plots)

Wizualizują zależność pomiędzy dwoma zmiennymi, np. intensywnościami sygnałów z dwóch różnych próbek. Typowym przykładem jest wykres MA (log ratio vs mean average), często stosowany w porównaniach ilościowych (np. w TMT/iTRAQ).

Heatmapy

Jednym z najczęściej stosowanych narzędzi wizualizacyjnych w proteomice są **heatmapy**, czyli mapy cieplne. Pokazują one poziomy ekspresji wielu białek w różnych warunkach (np. próbkach) w postaci kolorowych kwadratów, których intensywność koloru odpowiada wartości danego parametru (np. poziom ekspresji).

Heatmapy często łączone są z **hierarchiczną analizą skupień (clusteringiem)**, co umożliwia grupowanie białek i/lub próbek o podobnych profilach ekspresji. Dzięki temu można łatwo zaobserwować np. grupy białek współregulowanych lub próbki o podobnym charakterze biologicznym.

PCA i t-SNE – redukcja wymiarowości

Wysokowydajne dane proteomiczne są zwykle wielowymiarowe – każdy pomiar to wartość dla dziesiątek lub setek tysięcy cech (np. poziomów ekspresji białek). Aby lepiej zrozumieć strukturę tych danych, stosuje się metody **redukcji wymiarowości**, takie jak:

- **PCA (Principal Component Analysis)** – analiza głównych składowych,
- **t-SNE (t-distributed Stochastic Neighbor Embedding)** – nieliniowa metoda grupowania danych.

Metody te pozwalają na rzutowanie danych na płaszczyznę 2D lub 3D, gdzie próbki podobne do siebie grupują się razem. To niezwykle przydatne przy wizualizacji różnic między stanami chorobowymi a kontrolą, czy identyfikacji klas fenotypowych.

Volcano plot – znaczenie statystyczne i biologiczne

Volcano plot to specjalistyczna forma wykresu rozrzutu, stosowana do przedstawiania wyników analizy różnic w ekspresji białek. Na osi X znajduje się logarytm różnicy w ekspresji ($\log_2$ fold change), a na osi Y – wartość istotności statystycznej (najczęściej – $\log_{10}$ p-value).

Taki wykres umożliwia szybką identyfikację białek, które są zarówno istotnie statystycznie, jak i biologicznie różne między porównywanymi grupami. Białka o największym znaczeniu często oznaczane są kolorami lub etykietami.

Wizualizacja interakcji białkowych

Proteomika nie ogranicza się do badania pojedynczych białek – istotne są także ich interakcje i sieci funkcjonalne. W tym celu stosuje się:

- **sieci interakcji białkowych (protein-protein interaction networks),**
- **grafy funkcjonalne**, np. mapy ścieżek sygnałowych.

Do ich tworzenia używa się narzędzi takich jak:

- **Cytoscape** – popularny program do wizualizacji sieci biologicznych, z wieloma wtyczkami wspierającymi dane proteomiczne,
- **STRING** – baza danych i platforma do tworzenia interakcji białkowych na podstawie eksperymentów, predykcji i tekstu naukowego.

Przestrzenna i strukturalna wizualizacja białek

Jeśli dane proteomiczne odnoszą się do struktur białek (np. identyfikacja zmian w określonych domenach, mutacji czy modyfikacji potranslacyjnych), przydatna jest ich wizualizacja przestrzenna.

W tym celu stosuje się:

- **PyMOL, Chimera** – programy do oglądania struktur PDB i modeli z AlphaFold,
- Możliwość nakładania danych (np. miejsc ubikwitynacji, fosforylacji) na strukturę przestrzenną.

Pozwala to na lepsze zrozumienie funkcjonalnych skutków modyfikacji lub interakcji białkowych w kontekście strukturalnym.

Narzędzia i biblioteki do wizualizacji danych

Do generowania wykresów i map cieplnych stosuje się zarówno programy bioinformatyczne, jak i ogólne biblioteki programistyczne:

- **Perseus** – narzędzie do analizy danych proteomicznych (MaxQuant), z wieloma funkcjami wizualizacyjnymi,

- **GraphPad Prism** – intuicyjne środowisko do analizy statystycznej i tworzenia wykresów,
- **Python (matplotlib, seaborn, plotly)** i **R (ggplot2, pheatmap, ComplexHeatmap)** – elastyczne środowiska programistyczne dla bardziej zaawansowanych użytkowników,
- **Shiny apps, Dash, Tableau** – interaktywne dashboardy do eksploracji danych.

10.3 Wizualizacja zmienności ewolucyjnej

Multiple Sequence Alignment (MSA) - Dopasowanie wielosekwencyjne

Multiple Sequence Alignment (MSA) to metoda bioinformatyczna służąca do jednoczesnego dopasowania trzech lub więcej sekwencji biologicznych (białkowych lub nukleotydowych) w celu identyfikacji regionów podobieństwa, które mogą odzwierciedlać relacje funkcjonalne, strukturalne lub ewolucyjne między sekwencjami.

Kluczowe cechy MSA:

- Identyfikacja regionów konserwatywnych - pozwala wykryć fragmenty sekwencji, które pozostały niezmienione w toku ewolucji, co sugeruje ich kluczowe znaczenie funkcjonalne lub strukturalne
- Wykrywanie zmienności - umożliwia lokalizację regionów o różnym stopniu zmienności ewolucyjnej, od całkowicie konserwatywnych po hiperzmienne
- Insercje i delecje (indels) - wprowadzenie przerw (gap) w sekwencjach pozwala na właściwe wyrównanie regionów, w których doszło do insercji lub delecji fragmentów podczas ewolucji
- Wizualizacja - sekwencje są przedstawiane jedna pod drugą, co umożliwia łatwą identyfikację pozycji konserwatywnych (tych samych aminokwasów/nukleotydów w danej kolumnie) oraz zmiennych

Zastosowania MSA:

- Identyfikacja funkcjonalnie ważnych reszt aminokwasowych
- Przewidywanie struktury drugorzędowej i trzeciorzędowej białek
- Projektowanie starterów do PCR

- Analiza ewolucji genów i białek
- Podstawa do konstrukcji drzew filogenetycznych

Popularne programy do MSA:

- MAFFT - szybki i dokładny, wykorzystuje transformację Fouriera
- Clustal Omega - klasyczny program, łatwy w użyciu
- MUSCLE - zoptymalizowany pod kątem dokładności i szybkości
- T-Coffee - zwiększona dokładność dzięki bibliotece par dopasowań

Drzewa filogenetyczne

Drzewo filogenetyczne to diagram przedstawiający hipotetyczne relacje ewolucyjne (filogenetyczne) między grupami organizmów, genów lub białek. Drzewo ilustruje, w jaki sposób różne sekwencje lub taksony wyewoluowały z wspólnego przodka poprzez kolejne zdarzenia specjacji lub duplikacji genów.

Elementy drzewa filogenetycznego:

- Liście (taxa) - końcowe gałęzie reprezentujące analizowane sekwencje lub organizmy
- Węzły wewnętrzne - punkty rozgałęzienia reprezentujące hipotetycznych wspólnych przodków
- Gałęzie (branches) - linie łączące węzły, których długość może odpowiadać dystansowi ewolucyjnemu (liczbie substytucji)
- Korzeń (root) - najstarszy wspólny przodek wszystkich analizowanych sekwencji (w drzewach zakorzenionych)

Typy drzew:

- Drzewa zakorzenione (rooted) - posiadają określony kierunek ewolucji, pokazują wspólnego przodka
- Drzewa niezakorzenione (unrooted) - pokazują jedynie relacje między sekwencjami bez wskazania kierunku ewolucji
- Kladogramy - pokazują tylko topologię rozgałęzień bez informacji o dystansie ewolucyjnym
- Fylogramy - długość gałęzi odpowiada liczbie zmian ewolucyjnych

Metody konstrukcji drzew:

- Metody dystansowe:
 - Neighbor-Joining (NJ) - szybka metoda oparta na macierzy dystansów
 - UPGMA - zakłada stały zegar molekularny
- Metody oparte na charakterach:
 - Maximum Parsimony (MP) - wybiera drzewo wymagające najmniejszej liczby zmian
 - Maximum Likelihood (ML) - znajduje drzewo o największym prawdopodobieństwie dla danych sekwencji
 - Bayesian inference - metoda probabilistyczna uwzględniająca niepewność parametrów

Interpretacja drzewa:

- Grupy monofiletyczne (klady) - organizmy/sekwencje pochodzące od wspólnego przodka
- Wartości bootstrap/wsparcia - miara pewności dla poszczególnych rozgałęzień (typowo 70-100% wskazuje na dobre wsparcie)
- Dystans ewolucyjny - długość gałęzi odzwierciedla liczbę substytucji na pozycję

Zastosowania:

- Badanie ewolucji organizmów i genów
- Klasyfikacja taksonomiczna
- Śledzenie epidemii chorób zakaźnych
- Analiza ewolucji odporności na antybiotyki lub leki
- Identyfikacja ortologów i paralogów
- Datowanie zdarzeń ewolucyjnych (zegar molekularny)

Związek MSA i drzew filogenetycznych

Dopasowanie wielosekwencyjne (MSA) stanowi podstawę do konstrukcji drzew filogenetycznych. Jakość MSA bezpośrednio wpływa na wiarygodność otrzymanego drzewa filogenetycznego, ponieważ algorytmy konstrukcji drzew opierają się na założeniu, że pozycje w kolumnach MSA są homologiczne (pochodzą od wspólnego

przodka). Błędy w dopasowaniu mogą prowadzić do nieprawidłowych wniosków o relacjach ewolucyjnych.

Zadania 17 - 19

Zadanie 17.

W tym zadaniu przygotujesz i przeanalizujesz wielokrotne wyrównanie sekwencji (MSA).

1. Otwórz serwer MAFFT: <https://mafft.cbrc.jp/alignment/server/index.html>
2. Wklej poniższe sekwencje w formacie FASTA jako input (format FASTA).

Przejrzyj ustawienia i kliknij Submit (możesz zostawić ustawienia domyślne lub wybrać L-INS-i dla większej dokładności):

```
>Seq_A
MKTAIIGKGGIGRNPTVEVDLSTAGTEAMALKLSDNGIKVVVSEQHGPEFVDITGDA
FLKQPKNVIFADKTYERGLTPEQIRAAVHAAAKRGDCPVILVGNKCDLPQQQPPPQPQ
PQPARSGAVGAIVKVRGTPLSE
>Seq_B
MKTAIIGKGGIGRNPTVEVDLSTAGTEAMAFKLSNNGIKVVVSEQYGPEFVDITGDT
FLKQPENNVIFADKTYERGLTPEQIKAALHGASKRGDCPVILVGNKCDLPQQPPQQQPQ
PQPAKSGAVGAIVKVRGTPL
>Seq_C
MKTAIIGKGGIGRNPTVEVDLSTPGSEAWALKISDNGVKVVVSEQHGPEFVDITGDA
FLKQPKNVIFADKTAERGLTPEQVQKAIHPATNRGDCPVILVGNKCDLAGGGGSSGGG
GSTRNGAMGAIVKAKGSALEGH
>Seq_D
MKTAIIGKGGIGRNPTVEVDLSTPGSDFNWGFRVHDSGIRMVISQTHGPEFVDITGNP
YLKQAENVIFADKTSKGLTCEQLHDSLFGNVNQGDPCPVILVGNKCDLSEEEDEDKED
EDSRPGTLGALLKPRGTYFDSHIM
>Seq_E
MKTAIIGKGGIGRNPTVEVDLSTNGVQYPWSLTIQDPGVSMVITQPHGPEFVDITGEP
WLKQSDNVIFADKTSTKGLASDQFYDALGSGINSGDCPVILVGNKCDLPNNNNSTNSN
NTTRSGTYGA MVQPKGDFWQAHVPK
>Seq_F
MKTAIIGKGGIGRNPTVEVDLSTSGVDAFALHLTDPGVKVVVSQQHGPEFVDITGDS
YLKQPDNVIFADKTSEGLTPQQISAALNSAVKRGDCPVILVGNKCDLPKKKRKKKRK
KRPAGAVGAMVKVKGSPLE
>Seq_G
MKTAIIGKGGIGRNPTVEVDLSTPGAQDFWSLSIDDRGVSIIVISETHGPEFVDITGQP
FLKQTKNVIFADKTAQKGLSAEQMQDVIHSGTTRGDCPVILVGNKCDLPTTTTATATV
TSTRQGSGLGALIKSQGAWLDGH
```

3. Po zakończeniu obliczeń **zapisz plik FASTA z MSA**, a następnie kliknij „View” i „Start MSA Viewer”.

Odpowiedz:

- a) Czy widzisz regiony konserwatywne o małej zmienności? Wskaż ich przybliżone zakresy (numery pozycji w MSA).
- b) Czy widzisz region(y) o dużej zmienności? Wskaż zakres(y) pozycji w MSA, gdzie występują (zakresy podawaj jako np. 45–78).

Zadanie 18.

W tym samym widoku (MAFFT) kliknij zakładkę Tree (u góry), zostaw ustawienia domyślne i kliknij „Go!”. Po obliczeniu kliknij „View tree in Phylo.io”.

Odpowiedz:

1. Czy widzisz wyodrębnione klastry sekwencji? Które sekwencje są najbardziej podobne do siebie (podaj pary lub grupy)?
2. Sformułuj krótkie wnioski: co mówią o ewolucyjnej / funkcjonalnej różnorodności tych fragmentów?

Zadanie 19.

Wróć do wyników z serwera MAFFT i pobierz swoje przyrównanie (MSA) w formacie FASTA (zrobiłeś/aś to w zadaniu 17). Otwórz stronę generatora **WebLogo** (<https://weblogo.berkeley.edu/logo.cgi>). Wklej pobrane przyrównanie (MSA) w pole tekstowe i kliknij „Create Logo”.

Dla chętnych: Zamiast używać webservera, napisz skrypt, który wygeneruje Logo plot w formie wykresów (może być mniejszy zakres pozycji, np. 10-30). W tym celu możesz wczytać dopasowanie (MSA) jako macierz i policzyć %występowania każdego z 20 aminokwasów na każdej pozycji MSA, następnie wykreślić logo plot gdzie wielkość liter odpowiadających aminokwasom na danej pozycji będzie odpowiadać procentowi ich występowania.

Odpowiedz:

- a) Zapisz wygenerowany obraz (logo) i dołącz do sprawozdania.

b) Spójrz na region wokół pozycji 60-70. Które aminokwasy (litery) są tam najwyższe i co to oznacza w kontekście ich zmienności w toku ewolucji? c) Jak ten wykres ma się do Twoich obserwacji "na oko" z Zadania 17a?

Wskazówki:

Regiony konserwatywne: szukaj kolumn, gdzie większość sekwencji ma ten sam aminokwas (brak gapów). To będą łatwe do wskazania (np. początek sekwencji jest zwykle konserwowany).

Regiony zmienne: to kolumny z dużą liczbą różnych aminokwasów i/lub z wieloma gaps („-”).

Interpretacja drzewa:

- sekwencje z bardzo krótkimi odległościami (małe gałęzie) są bardzo podobne
→ zgrupuj je razem;
- długie gałęzie oznaczają większe różnice;
- klaster = grupa taksonów (sekwencji) mających wspólnego przodka w drzewie.

11. Integracja danych proteomicznych z danymi NGS

11.1 Wstęp

Współczesna biologia molekularna coraz częściej opiera się na wielowymiarowej analizie danych pochodzących z różnych poziomów regulacji komórkowej – od genomu i transkryptomu, aż po proteom i metabolom. Takie podejście, zwane biologią systemów, wymaga integracji danych z różnych technologii analitycznych, w tym przede wszystkim z proteomiki i sekwencjonowania nowej generacji (NGS).

NGS umożliwia analizę informacji genetycznej i transkryptomicznej: identyfikację mutacji, ekspresji genów (RNA-Seq), struktury transkryptów, a także różnorodnych modyfikacji epigenetycznych. Z kolei proteomika dostarcza wiedzy o końcowych produktach ekspresji genów – białkach – ich poziomach, modyfikacjach, lokalizacji i funkcjach. Choć RNA i białko są ze sobą ściśle powiązane, to ich poziomy ekspresji nie zawsze korelują bezpośrednio. Dlatego łączenie danych proteomicznych i NGS pozwala uzyskać pełniejszy obraz stanu biologicznego komórki.

11.2 Poziomy integracji danych – gen, transkrypt, białko

Integracja danych zaczyna się od powiązania pomiarów RNA (np. RNA-Seq) z odpowiadającymi im produktami białkowymi (np. LC-MS/MS). W tym celu tworzy się mapy korelacji, profile ekspresji i porównuje się ścieżki biologiczne reprezentowane na obu poziomach.

Przykładowe relacje:

- **Ekspresja genu (RNA) vs. ilość białka** – korelacja często umiarkowana, ponieważ translacja i stabilność białka są dodatkowo regulowane.
- **Transkryptom a alternatywne warianty białkowe** – analiza danych RNA-Seq pozwala wykrywać alternatywne splicingowe formy białek, które można potwierdzić na poziomie proteomu.
- **Mutacje (np. SNP)** w kodujących sekwencjach genów mogą prowadzić do **zmian sekwencji aminokwasów**, które z kolei można próbować identyfikować jako „neoantygeny” w danych proteomicznych.

11.2 Przykłady zastosowań integracji NGS i proteomiki

Nowotwory i medycyna precyzyjna

W onkologii analiza RNA-Seq ujawnia zmienione ścieżki sygnałowe, które mogą prowadzić do nieprawidłowej ekspresji białek. Proteomika potwierdza, czy zmienione transkrypty faktycznie przekładają się na obecność lub brak określonych białek, co umożliwia:

- identyfikację biomarkerów nowotworowych,
- wskazanie potencjalnych celów terapeutycznych (np. enzymów nadekspresjonowanych w danym typie nowotworu),
- detekcję mutacji prowadzących do nowych form białek (neoepitopów),
- ocenę skuteczności terapii poprzez monitorowanie poziomów białek związanych z mechanizmem działania leków.

Choroby neurologiczne i autoimmunologiczne

W chorobach takich jak stwardnienie rozsiane czy choroba Alzheimera, integracja danych transkryptomicznych i proteomicznych pomaga zidentyfikować **molekularne sygnatury patofizjologii**, nawet jeśli nie są one wyraźnie widoczne tylko na jednym poziomie danych.

11.3 Techniki i narzędzia integracyjne

Mapowanie danych (data mapping)

Pierwszym krokiem jest przyporządkowanie danych z różnych źródeł do wspólnych identyfikatorów:

- **ENSEMBL, UniProt, RefSeq** – bazy używane do standaryzacji nazw genów i białek,
- W przypadku alternatywnych wariantów transkryptów – używa się danych o izoformach (np. z GTF),
- W kontekście proteomiki często tworzy się **własne bazy FASTA** uwzględniające warianty wykryte w RNA-Seq lub DNA-Seq.

Tworzenie hybrydowych baz danych

Z danych NGS (np. RNA-Seq) można wygenerować tzw. **customized FASTA files** – zawierające nie tylko znane sekwencje białek, ale również te pochodzące z alternatywnych transkryptów, wariantów allelicznych, czy mutacji somatycznych. Tak przygotowana baza służy do ponownej identyfikacji białek na poziomie MS, zwiększając szansę detekcji rzadkich wariantów.

Narzędzia integracyjne

- **ProteoWizard + MaxQuant** lub **FragPipe** – umożliwiają import danych proteomicznych i integrację z zewnętrznymi bazami,
- **Galaxy, R/Bioconductor** – środowiska do obróbki i analizy danych NGS oraz ich integracji z proteomiką (np. za pomocą pakietów DESeq2, edgeR, limma, MSstats),
- **OmicsPipe, OpenMS, Jupyter Notebooks** – używane do budowy własnych workflow integracyjnych,
- **cBioPortal, LinkedOmics** – pozwalają na przeglądanie danych NGS i proteomicznych z projektów takich jak TCGA czy CPTAC.

11.4 Wyzwania integracji

Różne skale i jednostki danych

- RNA podawane jest zwykle w TPM lub FPKM, białka w intensywnościach MS, iTRAQ, TMT czy LFQ – porównanie wymaga normalizacji.

Niepełna korelacja

- Ekspresja RNA i białka nie zawsze są zgodne – wpływają na to translacja, stabilność białek, modyfikacje potranslacyjne.

Alternatywne izoformy białek

- Jeden gen może kodować wiele wariantów białek – trudność w dokładnym przypisaniu sygnału białkowego do konkretnego transkryptu.

Problemy z anotacją

- Niewłaściwa lub niekompletna adnotacja białek i genów może prowadzić do błędów interpretacyjnych. Konieczna jest aktualizacja baz i kontrola jakości.
-

11.5 Przyszłość integracji: multi-omics

Kierunkiem rozwoju jest **multi-omics**, czyli integracja nie tylko danych transkryptomicznych i proteomicznych, ale także:

- epigenomiki,
- metabolomiki,
- danych przestrzennych (spatial omics),
- obrazowania (np. single-cell proteomics + spatial transcriptomics).

Takie podejście pozwala uzyskać pełen kontekst biologiczny zmian obserwowanych w komórce i jest podstawą systemowej biologii oraz nowoczesnej medycyny precyzyjnej.

Zadanie 20

W tym zadaniu porównamy ekspresję genu i białka TP53 w nowotworach piersi (TCGA + CPTAC). Sprawdzimy, czy poziom RNA (z danych RNA-Seq) **dla genu TP53 koreluje z** poziomem białka TP53 **(z danych proteomicznych) w nowotworach piersi.**

Zadanie 20.

1: Wejdź do cBioPortal

1. Kliknij „Explore”
2. Wybierz projekt “Breast Invasive Carcinoma (TCGA, PanCancer Atlas)”
3. Wyszukaj gen: TP53 (Wpisz w „Query” i kliknij wyszukaj)
4. Kliknij zakładkę Plots
5. Wybierz:
 - oś X: TP53 mRNA Expression (RNA Seq V2 RSEM)

- oś Y: TP53 Protein Expression (RPPA)

Otrzymasz wykres rozrzutu, który pokazuje zależność między ekspresją RNA i białka.

Odpowiedz na pytania

- a. Czy istnieje korelacja między RNA a białkiem TP53? (popatrz na wartość korelacji Spearmana i Pearsona).
- b. Jakie mogą być proste przyczyny, że poziom RNA i białka nie zawsze są identyczne? (np. „białko może szybciej się rozkładać” albo „nie zawsze każde RNA zamienia się w białko”).

12. Kontynuacja nauki i rozwój umiejętności - przegląd zasobów online i możliwości dalszego kształcenia w tematyce przedmiotu

12.1 Wstęp

Proteomika i bioinformatyka to dynamicznie rozwijające się dziedziny, w których nowe technologie, metody analizy i oprogramowanie pojawiają się niemal nieustannie. Aby utrzymać aktualność swojej wiedzy i umiejętności, ważne jest aktywne korzystanie z dostępnych zasobów edukacyjnych i uczestnictwo w społeczności naukowej. W tym rozdziale omówione zostaną kluczowe źródła wiedzy, platformy edukacyjne, konferencje oraz narzędzia, które umożliwiają kontynuację nauki po zakończeniu kursu lub studiów.

Nauka bioinformatyki i proteomiki nie kończy się na zajęciach dydaktycznych – przeciwnie, to dopiero początek długiego i dynamicznego procesu. Korzystanie z bogactwa dostępnych kursów online, literatury, otwartych danych i społeczności naukowych pozwala nie tylko poszerzać wiedzę, ale też szybko reagować na zmieniające się potrzeby badawcze i technologiczne. Zachęcam do wybrania jednej z dostępnych ścieżek rozwoju – niezależnie, czy chcemy pisać własne pipeline'y, analizować dane z laboratoriów, czy rozumieć kontekst biologiczny zjawisk proteomicznych – zasoby są na wyciągnięcie ręki.

12.2 Kursy online i platformy edukacyjne

Wiele renomowanych instytucji oferuje darmowe i płatne kursy z zakresu proteomiki, bioinformatyki, analizy danych omicznych oraz programowania.

Platformy e-learningowe

- **Coursera** – kursy uniwersytetów takich jak Stanford, Yale czy University of Washington. Warto szukać tematów: *Bioinformatics*, *Proteomics*, *Data Science for Genomics*.

- **edX** – kursy MIT, Harvard, EMBL-EBI. Szczególnie godne uwagi są kursy z transkryptomiki, statystyki oraz biologii systemowej.
- **EMBL-EBI Training** – European Bioinformatics Institute prowadzi bogatą ofertę bezpłatnych kursów (wideo + materiały PDF), m.in. z przetwarzania danych proteomicznych, interpretacji wyników MS, analizy PTM.
- **FutureLearn** – platforma z kursami poświęconymi naukom biologicznym, często we współpracy z Uniwersytetem w Glasgow lub Wellcome Genome Campus.
- **YouTube** – kanały takie jak **"OpenMS"**, **"Proteomics Academy"**, **"Broad Institute"** czy **"MaxQuant Tutorials"** oferują praktyczne prezentacje krok po kroku.

12.3 Interaktywne środowiska i szkoleniowe platformy bioinformatyczne

Galaxy Project

Umożliwia analizę danych proteomicznych, transkryptomicznych i genomowych bez potrzeby instalacji lokalnej. Oferuje:

- tutoriale do każdej funkcji,
- repozytorium gotowych pipeline'ów,
- publiczne instancje (np. usegalaxy.eu),
- wsparcie społeczności i fora.

Jupyter Notebooks

Dla osób chcących pisać własne skrypty w Pythonie lub R. W sieci dostępne są setki otwartych notebooków z analizami proteomicznymi, np.:

- eksploracja danych LC-MS/MS,
- wizualizacja ekspresji białek,
- analiza PTM lub danych z proteomiki ilościowej.

12.4 Praktyczne narzędzia i bazy danych z dokumentacją edukacyjną

UniProt

Najważniejsza baza danych białek. Posiada rozbudowaną sekcję pomocy, schematy interaktywne i aktualne wpisy z adnotacjami biologicznymi. Idealna do nauki identyfikacji i funkcji białek.

PRIDE / ProteomeXchange

Rejestr publicznych eksperymentów proteomicznych. Możliwość pobrania danych i samodzielnej analizy jako ćwiczenie praktyczne. Często dołączone są pliki konfiguracyjne, bazy FASTA oraz dane wynikowe.

STRING, BioGRID, IntAct

Dane o interakcjach białkowych. Pozwalają na tworzenie sieci interakcji – przydatne do eksploracji danych i nauki interpretacji wyników.

AlphaFold Database

Baza przewidywanych struktur białkowych. Dobra okazja do nauki porównywania danych strukturalnych z informacjami z sekwencji i proteomiki.

12.4 Konferencje i warsztaty

Regularne uczestnictwo w wydarzeniach branżowych daje możliwość poznania najnowszych trendów, metod i narzędzi. Wiele z nich oferuje transmisje online i dostęp do materiałów po wydarzeniu.

- **HUPO (Human Proteome Organization)** – coroczna konferencja proteomiczna z sekcjami warsztatowymi.
- **EMBO Conferences and Courses** – konferencje i szkolenia organizowane przez Europejską Organizację Biologii Molekularnej, często we współpracy z EMBL (Europejskie Laboratorium Biologii Molekularnej). Odbývają się w wielu lokalizacjach na świecie, często w Heidelbergu w Niemczech i są świetną okazją nie tylko do zdobycia najnowszej wiedzy, ale również do poznania najlepszych specjalistów z dziedziny na świecie. Kursy EMBO poprzedza wymagający proces rekrutacyjny, ale warto próbować, bo są to wydarzenia na najwyższym naukowym poziomie. Link do listy dostępnych kursów: <https://www.embo.org/conferences-training/#/>
- **CPTAC Workshops** – warsztaty i nagrania z zakresu standaryzacji danych proteomicznych.

- **Google Summer of Code / ELIXIR Training Events** – programy dla studentów i początkujących programistów bioinformatycznych.

12.5 Literatura i podręczniki

Wciąż istotne miejsce mają klasyczne źródła wiedzy:

- **"Introduction to Proteomics"** – **Daniel C. Liebler** – świetne wprowadzenie teoretyczne i praktyczne.
- **"Bioinformatics Data Skills"** – **Vince Buffalo** – praktyczna książka dla bioinformatyków, także z przykładami danych proteomicznych.
- **Artykuły przeglądowe w czasopismach takich jak *Nature Methods, Molecular & Cellular Proteomics, Bioinformatics, Journal of Proteome Research*.**

Warto korzystać z Google Scholar i portali takich jak PubMed, by śledzić najnowsze publikacje w interesującym obszarze.

Zadanie projektowe ma na celu umożliwienie Państwu przetestowania narzędzi, które poznaliśmy oraz umiejętności, które nabyliśmy podczas kursu w praktyce. Zadania mają charakter otwarty – nie ma jednego słusznego klucza do ich rozwiązania. To Państwo wybierają metody poznane na kursie, które uważają Państwo za słuszne i wystarczające, aby odpowiedzieć na postawione pytania. Zaplanowano dwa warianty trudności zadań, które różnią się wymaganiami analizy. W obu wariantach, efekt projektu zawierał będzie zestaw analiz, które potencjalnie mogłyby zostać wykorzystane jako część wstępu do publikacji naukowej lub wniosku o grant. Odpowiedź na każdy z punktów nie może przekroczyć strony A4. Wymagany format raportu to .pdf.

Zadanie projektowe 1

Cel: Zrozumieć w jaki sposób porównanie sekwencji homologicznych może ujawnić ewolucyjną konserwację kluczowych elementów strukturalnych i funkcjonalnych białek enzymatycznych.

1. Wybór białka: Wybierz jedno ludzkie białko enzymatyczne.

Propozycje białek:

- MAPK1 (ERK2) – kinaza z pętlą aktywacyjną i dobrze zachowanymi motywami
- CDK2 – kinaza serynowo-treoninowa
- LDHA – enzym metaboliczny, dobrze opisane reszty katalityczne
- ENO1 – enzym glikolityczny, wysoko konserwowany
- GAPDH – enzym glikolizy, liczne PTM i homologi w wielu gatunkach

2. Znajdź je w UniProt ID i zapisz jego Uniprot ID.

W zakładce Function odszukaj: aminokwasy centrum aktywnego, motywy katalityczne i znane PTM (fosforylacje, acetylacje, ubikwitynacje).

3. Zebranie homologów.

Wyszukaj homologiczne sekwencje w UniProt, BLAST lub NCBI BLAST (protein) używając ludzkiej sekwencji FASTA.

Wybierz ok. 8–12 sekwencji z różnych gatunków (kilka kręgowców, bezkręgowców, ew. bakterie dla enzymów uniwersalnych).

Zapisz sekwencje w formacie FASTA, zachowując nazwę gatunku w nagłówku.

4. Dopasowanie sekwencji (MSA)

Wgraj plik w formacie FASTA ze wszystkimi zebranymi sekwencjami do webserwera MAFFT lub Clustal Omega. Ustaw ludzką sekwencję jako pierwszą dla referencji.

Dopasuj sekwencje i pobierz wynik MSA i otwórz w przeglądarce MSA viewerze.

Zaznacz nad MSA pozycje aminokwasów centrum aktywnego i motywów katalitycznych.

5. Analiza konserwacji i zmienności.

Oceń, czy reszty centrum aktywnego są identyczne lub mają konserwatywne substytucje (czyli takie o podobnym charakterze chemicznym, np. polarny, aromatyczny).

Zidentyfikuj regiony silnie zmienne (liczne różnice, delecje/wstawki) i zanotuj ich zakresy.

Sprawdź, o ile znajdziesz taką informację, czy regiony zmienne odpowiadają np. pętlom regulatorowym lub domenom funkcjonalnym.

6. Modyfikacje potranslacyjne (PTM)

Odtwórz pozycje PTM z UniProt lub PhosphoSitePlus w MSA.

Oceń, czy PTM leżą w konserwowanych resztach czy w zmiennych regionach.

Sprawdź, czy PTM występują w pobliżu centrum aktywnego i czy są zachowane w homologach (w programie do wizualizacji, np. PyMOL lub Chimera lub w viewerze online na stronie PDB).

7. Raport końcowy

Dołącz plik lub zrzut ekranu MSA z zaznaczonymi resztami aktywnymi i PTM.

Przygotuj krótką tabelę z opisanymi ważnymi funkcjonalnie aminokwasami:

| Pozycja UniProt | Funkcja reszty | Konserwacja (tak/nie) | Uwagi |

Napisz interpretację (do 400 słów), odpowiadając na pytania:

Czy centrum aktywne jest silnie konserwatywne?

Czy PTM mogą regulować aktywność enzymu wg ich położenia?

Jakie wnioski można wyciągnąć o ewolucyjnej stabilności i regulacji białka?

Zadanie projektowe 2

Cel: Poznać możliwości narzędzi machine learningowych w przewidywaniu funkcji, lokalizacji i struktury białek oraz porównać te predykcje z informacjami eksperymentalnymi dostępnymi w bazach danych.

1. Wybór białek

Wybierz **TRZY** dobrze opisane białka ludzkie, które mają dostępne dane w UniProt (przykładowo kinazy, enzymy metaboliczne, białka regulatorowe, możesz zerknąć na sugestie w poprzedniej propozycji projektu). Zanotuj ich UniProt ID i krótką charakterystykę funkcjonalną.

2. Przewidywanie lokalizacji

Użyj serwisu DeepLoc 2.0 (<https://services.healthtech.dtu.dk/services/DeepLoc-2.0/>), aby przewidzieć lokalizację komórkową każdego białka.

Zapisz przewidywane miejsca w komórce (np. jądro, cytoplazma, mitochondrium) i prawdopodobieństwa przypisania.

3. Przewidywanie funkcji

Skorzystaj z DeepGOPlus (<https://deepgo.cbrc.kaust.edu.sa/deepgo/>) do przewidywania funkcji białka.

Zapisz przewidywane funkcje i przypisane terminy GO (Gene Ontology), w tym procesy biologiczne, funkcje molekularne i lokalizacje komórkowe.

4. Przewidywanie struktury

Wykorzystaj AlphaFold lub ColabFold, aby uzyskać przewidywaną strukturę 3D każdego białka.

Jeśli dostępna jest struktura krystaliczna w PDB, porównaj ją z modelem przewidzianym przez AlphaFold. Zwróć uwagę na zgodność kluczowych domen i regionów aktywnych.

5. Analiza wyników i wnioski

Porównaj wyniki predykcji z adnotacjami w UniProt i innych bazach danych.

Oceń, czy przewidywania ML zgadzają się z eksperymentalnymi danymi.

Zastanów się, czy modele sugerują dodatkowe funkcje lub lokalizacje, które nie były wcześniej opisane.

Krótko podsumuj obserwacje w formie tabeli lub krótkiego raportu (do 400 słów):

Białko	UniProt funkcja	DeepLoc lokalizacja	DeepGOPlus funkcje	AlphaFold struktura	Uwagi / różnice
--------	-----------------	---------------------	--------------------	---------------------	-----------------

Zadanie projektowe 3

Cel: Kompleksowa charakterystyka wybranego ludzkiego białka z wykorzystaniem zintegrowanych metod bioinformatycznych i proteomicznych.

1. Wybierz ludzkie białko globularne (rozpuszczalne, niezwiązane z błoną komórkową, inne niż w poprzednich zadaniach do wykonania) lub błonowe, które ma rozwiązana strukturę 3D za pomocą krystalografii rentgenowskiej (w co najmniej 70% długości sekwencji) lub za pomocą CryoEM i przedstaw jego sekwencję, oraz podstawowe parametry fizykochemiczne. Białko musi być związane z zagadnieniem medycznym oraz muszą być dostępne dane proteomiczne (MS) z jego udziałem. Opisz motywację naukową, jaka stała za wyborem konkretnego białka.
2. Przeprowadź predykcję struktury tego białka za pomocą serwera AlphaFold (nie jest dopuszczalne pobranie predykcji z bazy danych UniProt) i w programie ChimeraX nałóż predykcję na model eksperymentalny. Omów obserwowane różnice i jak mają się one do poziomu ufności predykcji? Jakie mogą być przyczyny takich różnic?
3. Przeprowadź analizę interaktomu, w jaki może wchodzić to białko. Wynik przedstaw jako sieć interakcji i krótko skomentuj.
4. W jakich komórkach białko to ulega ekspresji? Wyszukaj dane MS o ekspresji tego białka w określonym typie komórek (jeśli są dostępne, to w warunkach zdrowia vs warunki choroby). Przedstaw te dane w informatywny, graficzny sposób.
5. Za pomocą poznanych narzędzi do predykcji funkcji oraz lokalizacji komórkowej białka, sprawdź, czy predykcje pokrywają się z dostępnymi danymi eksperymentalnymi.