

BIOINFORMATYKA W PROTEOMICE

Pełny skrypt do nauki

Na podstawie podręcznika „Bioinformatyka w proteomice”, wersja 2025/26_2

Układ: definicje • procesy • narzędzia • pułapki • pytania kontrolne

Spis treści

Jak korzystać ze skryptu

1. Podstawy proteomiki i białek (podręcznik: s. 7-19)
2. Bazy danych białkowych (podręcznik: s. 20-23)
3. Formaty danych i przetwarzanie danych surowych (podręcznik: s. 24-30)
4. Identyfikacja białek (podręcznik: s. 31-39)
5. Kwantyfikacja białek (podręcznik: s. 40-46)
6. Modyfikacje potranslacyjne (PTM) (podręcznik: s. 47-52)
7. Interakcje i sieci białkowe (podręcznik: s. 53-57)
8. Struktura białek: eksperyment i predykcja (podręcznik: s. 58-66)
9. Uczenie maszynowe w proteomice (podręcznik: s. 67-70)
10. Wizualizacja danych proteomicznych (podręcznik: s. 71-79)
11. Integracja proteomiki z NGS (podręcznik: s. 80-84)
12. Dalsza nauka i rozwój (podręcznik: s. 85-88)

Zadania projektowe

Lista kontrolna przed testem

Jak korzystać ze skryptu

Skrypt porządkuje materiał źródłowy bez rozszerzania go o zewnętrzne informacje. Najpierw przeczytaj „Sedno rozdziału”, następnie przeanalizuj tabelę pojęć i pułapki. Na końcu odpowiedz ustnie na pytania kontrolne. Oryginalny podręcznik pozostaje źródłem zadań praktycznych, ilustracji i szczegółowych instrukcji.

Najważniejszy ogólny przepływ analizy:

**próbka biologiczna → przygotowanie i rozdział → pomiar → dane surowe → identyfikacja →
kwantyfikacja/PTM → integracja i wizualizacja → wniosek biologiczny**

1. Podstawy proteomiki i białek

Zakres w podręczniku: strony 7-19

Cele nauki

- Wyjaśnić różnicę między białkiem, proteomem i proteomiką.
- Rozpoznawać poziomy organizacji struktury białka i podstawowe parametry fizykochemiczne.
- Rozróżniać metody globalnej analizy proteomu od metod skupionych na pojedynczym białku.

Sedno rozdziału

Od biochemii do bioinformatyki proteomicznej

Proteomika powstała wraz z rozwojem metod badania białek, spektrometrii mas oraz mocy obliczeniowej. Jej przedmiotem nie jest wyłącznie pojedyncza cząsteczka, lecz całe zestawy białek obecne w określonej komórce, tkance lub organizmie w danym czasie i warunkach.

Białko i enzym

Białko jest biopolimerem aminokwasowym, który pełni funkcję biologiczną po uzyskaniu właściwego kształtu przestrzennego. Nie każde białko jest enzymem. Enzym jest szczególnym rodzajem białka katalizującym reakcję biochemiczną bez trwałego zużycia własnej struktury.

Centralny dogmat

Informacja o sekwencji białka jest zapisana w DNA, przepisywana na mRNA, a następnie tłumaczona przez rybosom na sekwencję aminokwasów. Sam polipeptyd zwykle nie wystarcza do uzyskania pełnej funkcji: potrzebne są fałdowanie, czasem kofaktory oraz obróbka potranslacyjna.

Poziomy struktury

Struktura pierwszorzędowa to sekwencja aminokwasów. Drugorzędowa obejmuje lokalne elementy, głównie alfa-helisy i beta-kartki. Trzeciorzędowa opisuje trójwymiarowe ułożenie jednego łańcucha, a czwartorzędowa - organizację kilku podjednostek w kompleks.

Kofaktory

Cząsteczka niebiałkowa konieczna do aktywności enzymu jest kofaktorem. Kofaktor trwale związany to grupa prostetyczna, nietrwale związany - koenzym. Apoenzym wraz z kofaktorem tworzy aktywny holoenzym.

Proteom i proteomika

Proteom jest pełnym zestawem białek występujących w określonym układzie biologicznym, czasie i warunkach. W przeciwieństwie do względnie stałego genomu jest dynamiczny. Proteomika obejmuje identyfikację białek, ich charakterystykę strukturalną i funkcjonalną, analizę ilościową oraz badanie interakcji.

Techniki globalne i ukierunkowane

Do metod globalnych należą 2D-PAGE, spektrometria mas, chromatografia cieczowa, mikromacierze białkowe i analiza bioinformatyczna. Do metod ukierunkowanych zaliczono Western blot, ELISA, immunoprecypitację, heterologiczną ekspresję, chromatografię oczyszczającą, krystalografię, NMR, Cryo-EM, spektroskopię Ramana i FTIR.

Pojęcia i rozróżnienia

Hasło	Znaczenie
-------	-----------

Sekwencja	Zapis jedno- lub trzyliterowy, od N-końca do C-końca.
Masa molekularna	Najczęściej podawana w Da, kDa lub MDa.
Współczynnik absorpcji	Zależy od składu aminokwasowego i służy m.in. do wyznaczania stężenia.
Punkt izoelektryczny (pI)	pH, przy którym ładunki dodatnie i ujemne białka się równoważą.
Struktura przestrzenna	Model trójwymiarowy opisujący ułożenie atomów i podjednostek.

Pułapki interpretacyjne

- Genom nie jest tym samym co proteom: proteom zależy od czasu, tkanki, warunków i modyfikacji.
- Nie każde białko jest enzymem.
- Denaturacja niszczy strukturę przestrzenną i funkcję, ale nie musi rozrywać wiązań peptydowych.

Pytania kontrolne

1. Dlaczego liczba form białkowych może być większa od liczby genów?
2. Czym różni się apoenzym i holoenzym?
3. Które techniki dają obraz globalny, a które badają konkretne białko?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

2. Bazy danych białkowych

Zakres w podręczniku: strony 20-23

Cele nauki

- Klasyfikować bazy według rodzaju przechowywanych danych.
- Dobrać bazę do pytania o sekwencję, PTM, interakcję, lokalizację lub dane MS.

Sedno rozdziału

Znaczenie baz

Bazy danych organizują informacje potrzebne na każdym etapie proteomiki: od sekwencji i funkcji, przez surowe dane spektrometryczne, po modyfikacje, interakcje, ekspresję i lokalizację.

Bazy sekwencyjne i funkcjonalne

UniProt integruje sekwencję, funkcję, strukturę i PTM; Swiss-Prot jest adnotowany ręcznie, a TrEMBL automatycznie. RefSeq dostarcza referencyjne sekwencje, a Ensembl łączy dane genomowe z izoformami i alternatywnym splicingiem.

Repozytoria spektrometryczne

PRIDE i MassIVE przechowują publiczne zestawy danych proteomicznych. PeptideAtlas agreguje identyfikacje peptydów i wspiera budowę zasobów dla DIA. ProteomeXchange integruje repozytoria i ułatwia wymianę danych.

PTM i interakcje

PhosphoSitePlus i dbPTM gromadzą modyfikacje potranslacyjne. STRING łączy dane eksperymentalne i przewidywane, a BioGRID i IntAct bazują silnie na literaturze.

Ekspresja i lokalizacja

Human Protein Atlas łączy dane transkryptomiczne i proteomiczne dotyczące tkanek, komórek i lokalizacji subkomórkowej. PaxDb dostarcza informacje o abundancji białek.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Pytanie o sekwencję/funkcję	UniProt, RefSeq, Ensembl
Surowe dane MS	PRIDE, MassIVE, ProteomeXchange
Modyfikacje PTM	PhosphoSitePlus, dbPTM
Interakcje PPI	STRING, BioGRID, IntAct
Tkanka/lokalizacja/abundancja	Human Protein Atlas, Cell Atlas, PaxDb

Pułapki interpretacyjne

- Wynik przewidywany w STRING nie ma tej samej rangi co interakcja potwierdzona eksperymentalnie.
- TrEMBL zawiera adnotacje automatyczne, więc wymaga ostrożniejszej interpretacji niż Swiss-Prot.

Pytania kontrolne

1. W której bazie szukać publicznego eksperymentu MS?
2. Jak odróżnić bazę interakcji od bazy PTM?
3. Jaką informację wnosi Human Protein Atlas?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

3. Formaty danych i przetwarzanie danych surowych

Zakres w podręczniku: strony 24-30

Cele nauki

- Rozróżniać formaty firmowe, otwarte, sekwencyjne i strukturalne.
- Zbudować prosty pipeline konwersji i przygotowania danych.

Sedno rozdziału

Dane surowe

Najczęściej pochodzą ze spektrometrii mas, ale podręcznik uwzględnia też spektroskopię, fluorescencję i metody strukturalne. Standaryzacja jest konieczna, aby dane można było analizować, integrować i udostępniać.

Formaty firmowe

RAW, WIFF, D i TDF są generowane przez oprogramowanie aparatu i zawierają szczegółowe widma, metadane oraz parametry instrumentu. Ich ograniczeniem jest zależność od bibliotek i narzędzi producenta.

Formaty otwarte MS

mzML jest zalecanym, wszechstronnym standardem opartym na XML. mzXML jest starszy, mzData praktycznie wyparty. MGF jest prostym formatem tekstowym dla widm MS/MS. netCDF/ANDI-MS stosuje się rzadziej.

Narzędzia

ProteoWizard/MSConvert konwertuje formaty firmowe do mzML, mzXML lub MGF i wykonuje filtrację oraz centroidyzację. ThermoRawFileParser konwertuje pliki Thermo RAW. OpenMS oferuje modułowy pipeline. MaxQuant przetwarza RAW i zawiera Andromedę. Skyline wspiera analizy celowane. MSFragger/FragPipe szybko przeszukuje bazy i współpracuje z IonQuant.

FASTA

FASTA przechowuje sekwencje białek używane jako baza odniesienia do dopasowania peptydów. Każdy rekord zaczyna się od znaku > i nagłówka, po którym następuje sekwencja.

Dane strukturalne

PDB i mmCIF zapisują współrzędne atomów oraz adnotacje strukturalne; mmCIF jest nowszy i lepiej obsługuje duże kompleksy. MRC/MAP przechowuje mapy gęstości Cryo-EM.

Pojęcia i rozróżnienia

Hasło	Znaczenie
RAW/WIFF/D/TDF	Formaty producentów instrumentów.
mzML	Główny otwarty format danych MS.
MGF	Tekstowy eksport widm MS/MS.
FASTA	Sekwencje używane do identyfikacji.
PDB/mmCIF	Modele atomowe struktur.
MRC/MAP	Mapy gęstości elektronowej Cryo-EM.

Pułapki interpretacyjne

- MaxQuant według podręcznika przyjmuje pliki RAW i nie obsługuje mzML.
- FASTA nie zawiera widm, ale jest niezbędny przy identyfikacji peptydów.
- Mapa gęstości Cryo-EM nie jest tym samym co dopasowany model atomowy.

Pytania kontrolne

1. Dlaczego konwertuje się RAW do mzML?
2. Jaką rolę pełni FASTA w analizie MS?
3. Czym różni się PDB/mmCIF od MRC?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

4. Identyfikacja białek

Zakres w podręczniku: strony 31-39

Cele nauki

- Opisać przebieg identyfikacji bottom-up.
- Wyjaśnić problem inferencji białek.
- Rozumieć rolę Cryo-EM i integracji danych.

Sedno rozdziału

Bottom-up LC-MS/MS

Białka są trawione, zwykle trypsyną, do peptydów. Peptydy rozdziela chromatografia, następnie są jonizowane, mierzone i fragmentowane. Widma MS/MS porównuje się z teoretycznymi widmami wynikającymi z sekwencji bazodanowych.

Silniki wyszukiwania

W podręczniku wymieniono m.in. Mascot, Sequest, Andromedę, MS-GF+ i MSFragger. Wynikiem są dopasowania widmo-peptyd, które następnie agreguje się na poziomie białek.

Inferencja białek

Ten sam peptyd może występować w kilku białkach lub izoformach. Peptydy unikatowe jednoznacznie wspierają identyfikację, a peptydy współdzielone prowadzą do grup białkowych i niepewności przypisania.

FDR

Wiarygodność identyfikacji ocenia się statystycznie, m.in. z wykorzystaniem strategii target-decoy i kontroli false discovery rate. Niski FDR ogranicza liczbę fałszywie dodatnich identyfikacji.

Cryo-EM i CryoET

Cryo-EM pozwala analizować struktury kompleksów, a CryoET - struktury in situ w tomogramach komórek. Template matching porównuje model referencyjny z różnymi pozycjami i orientacjami w tomogramie, aby wykryć miejsca najlepszego dopasowania.

Integracja

Dane MS mogą potwierdzać obecność białek w strukturach, a modele strukturalne mogą pomagać interpretować identyfikacje. Kierunek rozwoju prowadzi od listy białek do rozumienia funkcji w kontekście struktury i interakcji.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Trawienie	Generowanie peptydów, najczęściej trypsyną.
m/z	Stosunek masy do ładunku jonu.
MS/MS	Fragmentacja peptydu i widmo informujące o sekwencji.
PSM	Dopasowanie widma do peptydu.
Peptyd unikatowy	Wspiera jednoznaczną identyfikację białka.
FDR	Kontrola odsetka fałszywych odkryć.

Pułapki interpretacyjne

- Identyfikacja peptydu nie zawsze jednoznacznie identyfikuje pojedyncze białko.
- Wysoka korelacja w template matching jest kandydatem, nie automatycznym dowodem biologicznym.

Pytania kontrolne

1. Jak przechodzi się od białka do widma MS/MS?
2. Dlaczego izoformy komplikują inferencję?
3. Co daje integracja MS i danych strukturalnych?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

5. Kwantyfikacja białek

Zakres w podręczniku: strony 40-46

Cele nauki

- Rozróżniać kwantyfikację względną i bezwzględną.
- Porównywać metody znakowane i label-free.

Sedno rozdziału

Cel kwantyfikacji

Kwantyfikacja odpowiada na pytanie, ile białka znajduje się w próbce i jak jego poziom zmienia się między warunkami. Może mieć charakter względny lub bezwzględny.

SILAC

Ciężkie izotopy są wbudowywane do białek podczas hodowli komórkowej. Próbkę różni się masą, ale zachowują podobne właściwości chemiczne. Metoda jest precyzyjna, lecz ograniczona głównie do kontrolowanych hodowli.

TMT i iTRAQ

Znaczniki izobaryczne umożliwiają multipleksowanie wielu próbek. Po fragmentacji pojawiają się jony reporterowe, których intensywności służą do porównań ilościowych.

Label-free

W podejściu bez znakowania porównuje się intensywności pików lub liczbę widm/peptydów między oddzielnymi analizami. Metoda jest elastyczna i tańsza, ale bardziej podatna na zmienność między pomiarami.

Kwantyfikacja bezwzględna

Wykorzystuje standardy o znanym stężeniu, np. peptydy izotopowo znakowane, aby oszacować rzeczywistą ilość analitu.

Techniki alternatywne

Western blot, ELISA, mikromacierze i metody fluorescencyjne mogą oznaczać wybrane białka. Są zwykle bardziej ukierunkowane niż proteomika MS.

Narzędzia

MaxQuant/Perseus, Skyline, OpenMS, Proteome Discoverer, FragPipe/IonQuant i biblioteki statystyczne wspierają ekstrakcję sygnału, normalizację, testowanie i wizualizację.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Względna	Porównuje próbki lub warunki.
Bezwzględna	Daje ilość w jednostkach dzięki standardowi.
Label-based	Próbki rozróżniane znacznikiem.
Label-free	Oddzielne przebiegi porównywane obliczeniowo.
Multipleksowanie	Jednoczesna analiza wielu próbek w jednym eksperymencie.

Pułapki interpretacyjne

- Większy sygnał nie zawsze oznacza biologicznie istotną zmianę - potrzebne są normalizacja i statystyka.
- Label-free wymaga dobrej porównywalności przebiegów.

Pytania kontrolne

1. Kiedy wybrać SILAC, a kiedy TMT?
2. Co odróżnia kwantyfikację bezwzględną od względnej?
3. Jakie są główne źródła zmienności label-free?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

6. Modyfikacje potranslacyjne (PTM)

Zakres w podręczniku: strony 47-52

Cele nauki

- Wymienić główne PTM i ich funkcje.
- Opisać eksperymentalny i bioinformatyczny workflow analizy PTM.

Sedno rozdziału

Znaczenie PTM

PTM zachodzą po translacji i zwiększają różnorodność funkcjonalną proteomu. Regulują sygnalizację, cykl komórkowy, odpowiedź immunologiczną i procesy chorobowe.

Przykłady

Podręcznik wymienia fosforylację, acetylację, ubikwitynację, metylację, glikozylację, nitrozylację, sumoilację, cięcia proteolityczne i mostki disiarczkowe.

Trudności

PTM mogą być substechiometryczne, przejściowe i niestabilne. Zmiana masy bywa niewielka, a lokalizacja na konkretnym aminokwasie wymaga wysokiej rozdzielczości i odpowiedniej fragmentacji.

Workflow eksperymentalny

Obejmuje wzbogacenie zmodyfikowanych peptydów lub białek, trawienie, MS/MS i dobór fragmentacji, np. ETD lub HCD.

Workflow bioinformatyczny

Wyszukiwanie uwzględnia modyfikacje stałe i zmienne, następnie ocenia lokalizację miejsca PTM i wiarygodność przypisania.

Narzędzia i bazy

MaxQuant/Andromeda, Mascot, PEAKS, PTMProphet i MSFragger/FragPipe wspierają identyfikację. PhosphoSitePlus, dbPTM i UniProt przechowują adnotacje.

Interpretacja

Położenie PTM względem domen, miejsc aktywnych i interfejsów może sugerować wpływ na aktywność, stabilność, lokalizację lub interakcje.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Fosforylacja	Często dynamiczna regulacja sygnalizacji.
Acetylacja	Może wpływać na aktywność, chromatynę i interakcje.
Ubikwitynacja	Może kierować białko do degradacji lub zmieniać sygnalizację.
Glikozylacja	Wpływa m.in. na białka sekrecyjne i błonowe.
Lokalizacja PTM	Przypisanie modyfikacji do konkretnej reszty aminokwasowej.

Pułapki interpretacyjne

- Wykrycie przesunięcia masy nie zawsze wystarcza do jednoznacznej lokalizacji PTM.

- Brak wykrycia PTM nie dowodzi jej biologicznego braku - może wynikać z niskiej obfitości lub przygotowania próbki.

Pytania kontrolne

1. Dlaczego wzbogacanie jest potrzebne?
2. Co oznacza substechiometryczność?
3. Jak baza PTM pomaga w interpretacji biologicznej?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

7. Interakcje i sieci białkowe

Zakres w podręczniku: strony 53-57

Cele nauki

- Rozróżniać rodzaje i metody wykrywania interakcji.
- Interpretować podstawowe elementy sieci PPI.

Sedno rozdziału

PPI

Funkcja, lokalizacja i stabilność białka zależą od interakcji z białkami, DNA, RNA, metabolitami i błonami. Proteomika bada zarówno pojedyncze pary, jak i całe sieci oddziaływań.

Rodzaje interakcji

Interakcje mogą być trwałe lub przejściowe, specyficzne lub niespecyficzne, bezpośrednie lub pośrednie. Ich znaczenie zależy od kontekstu komórkowego.

Metody eksperymentalne

Wymieniono m.in. yeast two-hybrid, koimmunoprecypitację, affinity purification-MS, proximity labeling, cross-linking MS i metody strukturalne.

Sieć jako graf

Białka są węzłami, a interakcje krawędziami. Analiza obejmuje stopień węzła, centralność, huby, klastry/moduły i nadreprezentację funkcji.

Bazy i narzędzia

STRING, BioGRID, IntAct, MINT i HPRD dostarczają danych. Cytoscape służy do wizualizacji i analizy; wymieniono też NAViGaTOR, Gephi, NetworkAnalyst i iRefIndex.

Interpretacja

Hub może być ważnym regulatorem, a moduł może odpowiadać kompleksowi lub procesowi. Należy jednak uwzględniać jakość dowodów, stroniczość literatury i kontekst tkankowy.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Węzeł	Białko lub inna cząsteczka.
Krawędź	Relacja/interakcja.
Hub	Węzeł o wielu połączeniach.
Moduł/klastr	Gęsto połączona grupa elementów.
Centralność	Miara znaczenia położenia w sieci.

Pułapki interpretacyjne

- Krawędź w bazie nie zawsze oznacza bezpośredni kontakt fizyczny.
- Sieć agregująca wiele eksperymentów może nie odzwierciedlać jednej tkanki lub warunku.

Pytania kontrolne

1. Czym AP-MS różni się od Y2H?
2. Co może oznaczać hub?

3. Dlaczego próg confidence zmienia interpretację sieci STRING?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

8. Struktura białek: eksperyment i predykcja

Zakres w podręczniku: strony 58-66

Cele nauki

- Porównać metody eksperymentalne wyznaczania struktur.
- Rozumieć predykcję homologiczną, de novo i AlphaFold.
- Oceniać jakość modelu strukturalnego.

Sedno rozdziału

Struktura a funkcja

Przestrzenne ułożenie atomów warunkuje aktywność, wiązanie ligandów, interakcje i stabilność. Bioinformatyka strukturalna analizuje głównie poziom trzeciorzędowy i czwartorzędowy.

Krystalografia rentgenowska

Daje struktury o wysokiej rozdzielczości, ale wymaga kryształów i może nie odzwierciedlać pełnej dynamiki białka.

NMR

Pozwala analizować białka w roztworze i dynamikę, lecz jest ograniczony rozmiarem i złożonością próbki.

Cryo-EM

Szczególnie przydatny dla dużych kompleksów i białek błonowych. Wynikiem jest mapa gęstości, do której dopasowuje się model atomowy.

Modelowanie homologiczne

Korzysta ze znanej struktury podobnego białka. Jakość zależy od podobieństwa sekwencji i jakości dopasowania.

Predykcja AI

AlphaFold i podobne narzędzia przewidują strukturę na podstawie sekwencji i wzorców ewolucyjnych. Wynik należy oceniać za pomocą miar ufności, a nie traktować jako równoważny danym eksperymentalnym.

Analiza struktur

PyMOL, Chimera/ChimeraX i przeglądarki PDB służą do oceny domen, ligandów, kontaktów, struktur drugorzędowych i nakładania modeli.

Bazy

PDB przechowuje modele eksperymentalne, AlphaFold DB - przewidywane, a EMDB - mapy Cryo-EM.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Rozdzielczość	Poziom szczegółowości danych eksperymentalnych.
pLDDT	Lokalna miara ufności modelu AlphaFold.
PAE	Niepewność wzajemnego położenia regionów/domen.
RMSD	Miara różnicy po nałożeniu struktur.
Ligand	Cząsteczka związana z białkiem.

Pułapki interpretacyjne

- Wysoki pLDDT lokalny nie gwarantuje poprawnej orientacji domen.
- Mapa Cryo-EM i model atomowy to dwa różne typy danych.
- Model predykcyjny może nie przedstawiać konkretnego stanu konformacyjnego lub kompleksu.

Pytania kontrolne

1. Kiedy Cryo-EM jest korzystniejszy od krystalografii?
2. Jak interpretować niski pLDDT?
3. Co mówi RMSD po superpozycji?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

9. Uczenie maszynowe w proteomice

Zakres w podręczniku: strony 67-70

Cele nauki

- Rozróżniać uczenie nadzorowane, nienadzorowane i głębokie.
- Wskazywać zastosowania ML w analizie białek.

Sedno rozdziału

Dlaczego ML

Dane proteomiczne są duże, złożone i wielowymiarowe. ML automatyzuje wykrywanie wzorców i predykcję na podstawie danych uczących.

Uczenie nadzorowane

Model uczy się na przykładach z etykietami. Zastosowania obejmują klasyfikację funkcji, lokalizacji, interakcji i stanów chorobowych.

Uczenie nienadzorowane

Bez gotowych etykiet odkrywa grupy i strukturę danych, np. klastry profili ekspresji lub białek o podobnych cechach.

Deep learning

Sieci neuronowe uczą się złożonych reprezentacji sekwencji i struktur. Podręcznik przywołuje AlphaFold, PIPR i DeepGO jako przykłady.

Zastosowania

Predykcja struktury, funkcji, lokalizacji, PTM i PPI; klasyfikacja próbek; biomarkery; integracja multi-omics; wspomaganie projektowania leków.

Wyzwania

Jakość i reprezentatywność danych, brakujące etykiety, nierównowaga klas, przeuczenie, interpretowalność i potrzeba walidacji eksperymentalnej.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Cecha	Zmienna wejściowa opisująca obiekt.
Etykieta	Znany wynik używany w uczeniu nadzorowanym.
Trening/walidacja/test	Rozdzielenie danych do uczenia, strojenia i oceny.
Overfitting	Dobre dopasowanie do treningu, słaba generalizacja.
Predykcja	Wynik modelu wymagający oceny ufności i walidacji.

Pułapki interpretacyjne

- Predykcja ML nie jest dowodem eksperymentalnym.
- Przeciek danych między zbiorem treningowym i testowym zawyża jakość modelu.

Pytania kontrolne

1. Kiedy używa się uczenia nienadzorowanego?
2. Dlaczego walidacja zewnętrzna jest ważna?

3. Jakie dane wejściowe można wykorzystać do predykcji funkcji białka?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

10. Wizualizacja danych proteomicznych

Zakres w podręczniku: strony 71-79

Cele nauki

- Dobrać wykres do pytania biologicznego.
- Rozpoznawać heatmapę, PCA, volcano plot i wizualizacje ewolucyjne.

Sedno rozdziału

Rola wizualizacji

Wizualizacja upraszcza interpretację tysięcy pomiarów, ujawnia wzorce, anomalie, grupowanie i zależności między próbkami lub białkami.

Barplot i boxplot

Barplot pokazuje porównanie wartości, a boxplot rozkład, medianę i obserwacje odstające.

Scatter i MA plot

Scatter pokazuje zależność dwóch zmiennych. MA plot przedstawia różnicę logarytmiczną względem średniego sygnału.

Volcano plot

Łączy wielkość zmiany, zwykle $\log_2$ fold change, z istotnością statystyczną. Pomaga wskazać białka silnie i istotnie zmienione.

Heatmapa

Macierz kolorów prezentuje wzorce ekspresji i często jest łączona z grupowaniem hierarchicznym.

PCA

Redukuje wymiar i pokazuje główne źródła zmienności między próbkami, grupami i potencjalnymi outlierami.

Sieci i struktury

Cytoscape przedstawia sieci, a PyMOL/Chimera struktury 3D. Wizualizacje powinny odpowiadać poziomowi danych.

Zmienność ewolucyjna

Multiple sequence alignment, logo sekwencyjne i drzewa filogenetyczne ujawniają konserwację reszt, motywów i relacje homologiczne.

Pojęcia i rozróżnienia

Hasło	Znaczenie
$\log_2$FC	Wielkość względnej zmiany na skali $\log_2$.
p-value/FDR	Miara istotności i korekta wielokrotnych testów.
PCA	Redukcja wymiarów i wizualizacja zmienności.
Clustering	Grupowanie podobnych próbek lub białek.
MSA	Dopasowanie wielu sekwencji homologicznych.

Pułapki interpretacyjne

- Volcano plot bez progów i informacji o korekcie wielokrotnych testów może być mylący.

- PCA pokazuje wariancję, ale nie automatycznie przyczynę biologiczną.
- Kolorystyka heatmapy wymaga opisanej skali i normalizacji.

Pytania kontrolne

1. Kiedy wybrać boxplot zamiast barplotu?
2. Co oznacza odseparowana próbka na PCA?
3. Jak MSA pomaga znaleźć reszty funkcjonalne?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

11. Integracja proteomiki z NGS

Zakres w podręczniku: strony 80-84

Cele nauki

- Wyjaśnić, dlaczego RNA i białko nie muszą silnie korelować.
- Opisać poziomy integracji genom-transkryptom-proteom.

Sedno rozdziału

Biologia systemów

Integracja łączy dane genomowe, transkryptomowe, proteomiczne i inne omiki, aby uzyskać pełniejszy obraz regulacji komórkowej.

RNA a białko

RNA-Seq mierzy transkrypty, a proteomika produkty białkowe, PTM i lokalizację. Korelacja jest często umiarkowana, ponieważ translacja, degradacja i stabilność białek podlegają dodatkowej regulacji.

Warianty i izoformy

RNA-Seq ujawnia alternatywny splicing i mutacje, a proteomika może próbować potwierdzać odpowiednie peptydy wariantowe lub izoformy.

Proteogenomika

Buduje spersonalizowane bazy sekwencji na podstawie danych NGS, a następnie wykorzystuje je do przeszukiwania widm MS.

Analizy zintegrowane

Stosuje się korelacje RNA-białko, analizy szlaków, sieci regulacyjne, wspólne klastrowanie i porównania między warstwami.

Wyzwania

Różne skale, brakujące wartości, dopasowanie identyfikatorów, różne czasy pomiaru, heterogeniczność próbek i konieczność spójnej normalizacji.

Multi-omics

Kierunek rozwoju obejmuje integrację dodatkowo metabolomiki, epigenomiki i danych klinicznych.

Pojęcia i rozróżnienia

Hasło	Znaczenie
RNA-Seq	Pomiar i charakterystyka transkryptów.
Proteogenomika	Wykorzystanie genomu/transkryptomu do interpretacji danych MS.
Neoantygen	Peptyd wynikający m.in. z wariantu somatycznego, potencjalnie rozpoznawany immunologicznie.
Mapowanie ID	Łączenie odpowiadających sobie genów, transkryptów i białek.
Multi-omics	Integracja wielu warstw molekularnych.

Pułapki interpretacyjne

- Brak korelacji RNA-białko nie oznacza błędu - może odzwierciedlać regulację potranslacyjną.

- Porównanie wymaga zgodnych próbek i poprawnego mapowania identyfikatorów.

Pytania kontrolne

1. Dlaczego poziom mRNA może różnić się od poziomu białka?
2. Jak powstaje spersonalizowana baza proteogenomiczna?
3. Jakie problemy powodują brakujące wartości?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

12. Dalsza nauka i rozwój

Zakres w podręczniku: strony 85-88

Cele nauki

- Zbudować plan dalszej nauki i praktyki.
- Rozpoznawać źródła kursów, danych, dokumentacji i społeczności.

Sedno rozdziału

Ciągłość nauki

Proteomika i bioinformatyka szybko się zmieniają, dlatego rozwój wymaga regularnej pracy z kursami, dokumentacją, otwartymi danymi i literaturą.

Platformy

Podręcznik wskazuje m.in. Courserę, edX, EMBL-EBI Training, Galaxy Training Network i materiały ELIXIR.

Praktyka

Galaxy, UniProt, PRIDE/ProteomeXchange, STRING/BioGRID/IntAct i AlphaFold DB pozwalają ćwiczyć na rzeczywistych danych oraz dokumentacji.

Konferencje i warsztaty

Wymieniono HUPO, wydarzenia EMBO/EMBL, CPTAC Workshops oraz wydarzenia ELIXIR i programy dla początkujących.

Literatura

Polecono książki Introduction to Proteomics oraz Bioinformatics Data Skills, a także czasopisma Nature Methods, Molecular & Cellular Proteomics, Bioinformatics i Journal of Proteome Research.

Pojęcia i rozróżnienia

Hasło	Znaczenie
Ścieżka narzędziowa	Nauka konkretnych pipeline'ów i formatów.
Ścieżka analityczna	Statystyka, R/Python i wizualizacja.
Ścieżka biologiczna	Interpretacja funkcji, szlaków, PTM i interakcji.
Ścieżka strukturalna	PDB, Cryo-EM, AlphaFold, ChimeraX/PyMOL.

Pułapki interpretacyjne

- Dokumentacja narzędzia może zmieniać się szybciej niż podręcznik - przy praktyce należy sprawdzać wersję.
- Ćwiczenie na publicznych danych wymaga odtworzenia metadanych i parametrów eksperymentu.

Pytania kontrolne

1. Jaką ścieżkę rozwoju wybrać do analizy MS?
2. Które zasoby oferują otwarte dane do samodzielnej analizy?
3. Dlaczego dokumentowanie wersji narzędzi jest ważne?

Wróć do podręcznika, aby wykonać przypisane zadania praktyczne i case studies.

Zadania projektowe - mapa wymagań

Projekt 1 - konserwacja sekwencji enzymu

Wybór ludzkiego enzymu; zebranie 8-12 homologów; MSA w MAFFT lub Clustal Omega; oznaczenie centrum aktywnego, motywów i PTM; ocena konserwacji oraz raport do 400 słów.

Projekt 2 - predykcje ML dla trzech białek

DeepLoc 2.0 dla lokalizacji, DeepGOPlus dla funkcji i terminów GO, AlphaFold/ColabFold dla struktury; porównanie z UniProt i danymi eksperymentalnymi; tabela i raport do 400 słów.

Projekt 3 - kompleksowa charakterystyka białka

Wybór białka z eksperymentalną strukturą i danymi MS; samodzielna predykcja AlphaFold; superpozycja w ChimeraX; analiza interaktomu, ekspresji i zgodności predykcji funkcji/lokalizacji z eksperymentem.

Uniwersalna struktura raportu projektowego

- Cel i motywacja biologiczna.
- Źródła danych, identyfikatory i wersje narzędzi.
- Metody krok po kroku wraz z parametrami.
- Wyniki w tabelach i czytelnych wizualizacjach.
- Interpretacja: co wynika z danych, a co jest tylko predykcją.
- Ograniczenia analizy i możliwe źródła błędów.
- Bibliografia oraz odnośniki do baz.

Lista kontrolna przed testem

- ☐ Potrafię zdefiniować proteom i wyjaśnić jego dynamiczny charakter.
- ☐ Rozróżniam poziomy struktury białka oraz pojęcia kofaktor, koenzym, apoenzym i holoenzym.
- ☐ Dobieram właściwą bazę do sekwencji, danych MS, PTM, interakcji i lokalizacji.
- ☐ Rozpoznaję RAW, mzML, MGF, FASTA, PDB/mmCIF i MRC.
- ☐ Umiem opisać workflow bottom-up LC-MS/MS i problem inferencji białek.
- ☐ Rozróżniam SILAC, TMT/iTRAQ i label-free oraz kwantyfikację względną i bezwzględną.
- ☐ Wiem, dlaczego analiza PTM wymaga wzbogacania i lokalizacji miejsca modyfikacji.
- ☐ Interpretuję węzły, krawędzie, huby i moduły w sieci PPI.
- ☐ Porównuję krystalografię, NMR, Cryo-EM i predykcję AlphaFold.
- ☐ Rozumiem różnicę między predykcją ML a walidacją eksperymentalną.
- ☐ Dobieram volcano plot, heatmapę, PCA, boxplot i MSA do pytania.
- ☐ Wyjaśniam, dlaczego RNA i białko nie zawsze korelują.