

BIOINFORMATYKA W PROTEOMICE

Ściąga powtórkowa

Na podstawie podręcznika „Bioinformatyka w proteomice”, wersja 2025/26_2

Układ: definicje • procesy • narzędzia • pułapki • pytania kontrolne

Spis treści

1. Podstawy proteomiki i białek
 2. Bazy danych białkowych
 3. Formaty danych i przetwarzanie danych surowych
 4. Identyfikacja białek
 5. Kwantyfikacja białek
 6. Modyfikacje potranslacyjne (PTM)
 7. Interakcje i sieci białkowe
 8. Struktura białek: eksperyment i predykcja
 9. Uczenie maszynowe w proteomice
 10. Wizualizacja danych proteomicznych
 11. Integracja proteomiki z NGS
 12. Dalsza nauka i rozwój
- Macierz: formaty, bazy i narzędzia
- 20 pytań szybkiej powtórki

Mapa całego przedmiotu

Hasło	Znaczenie
1. Podstawy	białko → struktura → proteom → techniki
2. Bazy	sekwencje, MS, PTM, PPI, ekspresja
3. Formaty	RAW/mzML/MGF + FASTA + PDB/mmCIF/MRC
4. Identyfikacja	trypsyna → LC-MS/MS → PSM → białko → FDR
5. Kwantyfikacja	label-based / label-free; względna / bezwzględna
6. PTM	wzbogacanie → MS/MS → lokalizacja → interpretacja
7. PPI	eksperyment → baza → sieć → huby/moduły
8. Struktura	X-ray/NMR/Cryo-EM + modelowanie/AlphaFold
9. ML	cechy → model → predykcja → walidacja
10. Wizualizacja	boxplot, volcano, heatmap, PCA, sieć, MSA
11. Integracja	genom/RNA ↔ białko ↔ PTM; proteogenomika
12. Rozwój	kursy, dokumentacja, otwarte dane, literatura

1. Podstawy proteomiki i białek

Od biochemii do bioinformatyki proteomicznej: Proteomika powstała wraz z rozwojem metod badania białek, spektrometrii mas oraz mocy obliczeniowej. Jej przedmiotem nie jest wyłącznie pojedyncza cząsteczka, lecz całe zestawy białek obecne w określonej komórce, tkance lub organizmie w danym czasie i warunkach.

Białko i enzym: Białko jest biopolimerem aminokwasowym, który pełni funkcję biologiczną po uzyskaniu właściwego kształtu przestrzennego. Nie każde białko jest enzymem. Enzym jest szczególnym rodzajem białka katalizującym reakcję biochemiczną bez trwałego zużycia własnej struktury.

Centralny dogmat: Informacja o sekwencji białka jest zapisana w DNA, przepisywana na mRNA, a następnie tłumaczona przez rybosom na sekwencję aminokwasów. Sam polipeptyd zwykle nie wystarcza do uzyskania pełnej funkcji: potrzebne są fałdowanie, czasem kofaktory oraz obróbka potranslacyjna.

Poziomy struktury: Struktura pierwszorzędowa to sekwencja aminokwasów. Drugorzędowa obejmuje lokalne elementy, głównie alfa-helisy i beta-kartki. Trzeciorzędowa opisuje trójwymiarowe ułożenie jednego łańcucha, a czwartorzędowa - organizację kilku podjednostek w kompleks.

Must know

Hasło	Znaczenie
Sekwencja	Zapis jedno- lub trzyliterowy, od N-końca do C-końca.
Masa molekularna	Najczęściej podawana w Da, kDa lub MDa.
Współczynnik absorpcji	Zależy od składu aminokwasowego i służy m.in. do wyznaczania stężenia.
Punkt izoelektryczny (pI)	pH, przy którym ładunki dodatnie i ujemne białka się równoważą.
Struktura przestrzenna	Model trójwymiarowy opisujący ułożenie atomów i podjednostek.

Pułapka: Genom nie jest tym samym co proteom: proteom zależy od czasu, tkanki, warunków i modyfikacji.

2. Bazy danych białkowych

Znaczenie baz: Bazy danych organizują informacje potrzebne na każdym etapie proteomiki: od sekwencji i funkcji, przez surowe dane spektrometryczne, po modyfikacje, interakcje, ekspresję i lokalizację.

Bazy sekwencyjne i funkcjonalne: UniProt integruje sekwencję, funkcję, strukturę i PTM; Swiss-Prot jest adnotowany ręcznie, a TrEMBL automatycznie. RefSeq dostarcza referencyjne sekwencje, a Ensembl łączy dane genomowe z izoformami i alternatywnym splicingiem.

Repozytoria spektrometryczne: PRIDE i MassIVE przechowują publiczne zestawy danych proteomicznych. PeptideAtlas agreguje identyfikacje peptydów i wspiera budowę zasobów dla DIA. ProteomeXchange integruje repozytoria i ułatwia wymianę danych.

PTM i interakcje: PhosphoSitePlus i dbPTM gromadzą modyfikacje potranslacyjne. STRING łączy dane eksperymentalne i przewidywane, a BioGRID i IntAct bazują silnie na literaturze.

Must know

Hasło	Znaczenie
Pytanie o sekwencję/funkcję	UniProt, RefSeq, Ensembl
Surowe dane MS	PRIDE, MassIVE, ProteomeXchange
Modyfikacje PTM	PhosphoSitePlus, dbPTM
Interakcje PPI	STRING, BioGRID, IntAct
Tkanka/lokalizacja/abundancja	Human Protein Atlas, Cell Atlas, PaxDb

Pułapka: Wynik przewidywany w STRING nie ma tej samej rangi co interakcja potwierdzona eksperymentalnie.

3. Formaty danych i przetwarzanie danych surowych

Dane surowe: Najczęściej pochodzą ze spektrometrii mas, ale podręcznik uwzględnia też spektroskopię, fluorescencję i metody strukturalne. Standaryzacja jest konieczna, aby dane można było analizować, integrować i udostępniać.

Formaty firmowe: RAW, WIFF, D i TDF są generowane przez oprogramowanie aparatu i zawierają szczegółowe widma, metadane oraz parametry instrumentu. Ich ograniczeniem jest zależność od bibliotek i narzędzi producenta.

Formaty otwarte MS: mzML jest zalecanym, wszechstronnym standardem opartym na XML. mzXML jest starszy, mzData praktycznie wyparty. MGF jest prostym formatem tekstowym dla widm MS/MS. netCDF/ANDI-MS stosuje się rzadziej.

Narzędzia: ProteoWizard/MSConvert konwertuje formaty firmowe do mzML, mzXML lub MGF i wykonuje filtrację oraz centroidyzację. ThermoRawFileParser konwertuje pliki Thermo RAW. OpenMS oferuje modułowy pipeline. MaxQuant przetwarza RAW i zawiera Andromedę. Skyline wspiera analizy celowane. MSFragger/FragPipe szybko przeszukuje bazy i współpracuje z IonQuant.

Must know

Hasło	Znaczenie
RAW/WIFF/D/TDF	Formaty producentów instrumentów.
mzML	Główny otwarty format danych MS.
MGF	Tekstowy eksport widm MS/MS.
FASTA	Sekwencje używane do identyfikacji.

PDB/mmCIF	Modele atomowe struktur.
-----------	--------------------------

Pułapka: MaxQuant według podręcznika przyjmuje pliki RAW i nie obsługuje mzML.

4. Identyfikacja białek

Bottom-up LC-MS/MS: Białka są trawione, zwykle trypsyną, do peptydów. Peptydy rozdziela chromatografia, następnie są jonizowane, mierzone i fragmentowane. Widma MS/MS porównuje się z teoretycznymi widmami wynikającymi z sekwencji bazodanowych.

Silniki wyszukiwania: W podręczniku wymieniono m.in. Mascot, Sequest, Andromedę, MS-GF+ i MSFragger. Wynikiem są dopasowania widmo-peptyd, które następnie agreguje się na poziomie białek.

Inferencja białek: Ten sam peptyd może występować w kilku białkach lub izoformach. Peptydy unikatowe jednoznacznie wspierają identyfikację, a peptydy współdzielone prowadzą do grup białkowych i niepewności przypisania.

FDR: Wiarygodność identyfikacji ocenia się statystycznie, m.in. z wykorzystaniem strategii target-decoy i kontroli false discovery rate. Niski FDR ogranicza liczbę fałszywie dodatnich identyfikacji.

Must know

Hasło	Znaczenie
Trawienie	Generowanie peptydów, najczęściej trypsyną.
m/z	Stosunek masy do ładunku jonu.
MS/MS	Fragmentacja peptydu i widmo informujące o sekwencji.
PSM	Dopasowanie widma do peptydu.
Peptyd unikatowy	Wspiera jednoznaczną identyfikację białka.

Pułapka: Identyfikacja peptydu nie zawsze jednoznacznie identyfikuje pojedyncze białko.

5. Kwantyfikacja białek

Cel kwantyfikacji: Kwantyfikacja odpowiada na pytanie, ile białka znajduje się w próbce i jak jego poziom zmienia się między warunkami. Może mieć charakter względny lub bezwzględny.

SILAC: Ciężkie izotopy są wbudowywane do białek podczas hodowli komórkowej. Próbkę różni się masą, ale zachowują podobne właściwości chemiczne. Metoda jest precyzyjna, lecz ograniczona głównie do kontrolowanych hodowli.

TMT i iTRAQ: Znaczniki izobaryczne umożliwiają multipleksowanie wielu próbek. Po fragmentacji pojawiają się jony reporterowe, których intensywności służą do porównań ilościowych.

Label-free: W podejściu bez znakowania porównuje się intensywności pików lub liczbę widm/peptydów między oddzielnymi analizami. Metoda jest elastyczna i tańsza, ale bardziej podatna na zmienność między pomiarami.

Must know

Hasło	Znaczenie
Względna	Porównuje próbki lub warunki.

Bezwzględna	Daje ilość w jednostkach dzięki standardowi.
Label-based	Próbki rozróżniane znacznikiem.
Label-free	Oddzielne przebiegi porównywane obliczeniowo.
Multipleksowanie	Jednoczesna analiza wielu próbek w jednym eksperymencie.

Pułapka: Większy sygnał nie zawsze oznacza biologicznie istotną zmianę - potrzebne są normalizacja i statystyka.

6. Modyfikacje potranslacyjne (PTM)

Znaczenie PTM: PTM zachodzą po translacji i zwiększają różnorodność funkcjonalną proteomu. Regulują sygnalizację, cykl komórkowy, odpowiedź immunologiczną i procesy chorobowe.

Przykłady: Podręcznik wymienia fosforylację, acetylację, ubikwitynację, metylację, glikozylację, nitrozylację, sumoilację, cięcia proteolityczne i mostki disiarczkowe.

Trudności: PTM mogą być substechiometryczne, przejściowe i niestabilne. Zmiana masy bywa niewielka, a lokalizacja na konkretnym aminokwasie wymaga wysokiej rozdzielczości i odpowiedniej fragmentacji.

Workflow eksperymentalny: Obejmuje wzbogacenie zmodyfikowanych peptydów lub białek, trawienie, MS/MS i dobór fragmentacji, np. ETD lub HCD.

Must know

Hasło	Znaczenie
Fosforylacja	Często dynamiczna regulacja sygnalizacji.
Acetylacja	Może wpływać na aktywność, chromatynę i interakcje.
Ubikwitynacja	Może kierować białko do degradacji lub zmieniać sygnalizację.
Glikozylacja	Wpływa m.in. na białka sekrecyjne i błonowe.
Lokalizacja PTM	Przypisanie modyfikacji do konkretnej reszty aminokwasowej.

Pułapka: Wykrycie przesunięcia masy nie zawsze wystarcza do jednoznacznej lokalizacji PTM.

7. Interakcje i sieci białkowe

PPI: Funkcja, lokalizacja i stabilność białka zależą od interakcji z białkami, DNA, RNA, metabolitami i błonami. Proteomika bada zarówno pojedyncze pary, jak i całe sieci oddziaływań.

Rodzaje interakcji: Interakcje mogą być trwałe lub przejściowe, specyficzne lub niespecyficzne, bezpośrednie lub pośrednie. Ich znaczenie zależy od kontekstu komórkowego.

Metody eksperymentalne: Wymieniono m.in. yeast two-hybrid, koimmunoprecypitację, affinity purification-MS, proximity labeling, cross-linking MS i metody strukturalne.

Sieć jako graf: Białka są węzłami, a interakcje krawędziami. Analiza obejmuje stopień węzła, centralność, huby, klastry/moduły i nadreprezentację funkcji.

Must know

Hasło	Znaczenie
-------	-----------

Węzeł	Białko lub inna cząsteczka.
Krawędź	Relacja/interakcja.
Hub	Węzeł o wielu połączeniach.
Moduł/klaster	Gęsto połączona grupa elementów.
Centralność	Miara znaczenia położenia w sieci.

Pułapka: Krawędź w bazie nie zawsze oznacza bezpośredni kontakt fizyczny.

8. Struktura białek: eksperyment i predykcja

Struktura a funkcja: Przestrzenne ułożenie atomów warunkuje aktywność, wiązanie ligandów, interakcje i stabilność. Bioinformatyka strukturalna analizuje głównie poziom trzeciorzędowy i czwartorzędowy.

Krystalografia rentgenowska: Daje struktury o wysokiej rozdzielczości, ale wymaga kryształów i może nie odzwierciedlać pełnej dynamiki białka.

NMR: Pozwala analizować białka w roztworze i dynamikę, lecz jest ograniczony rozmiarem i złożonością próbki.

Cryo-EM: Szczególnie przydatny dla dużych kompleksów i białek błonowych. Wynikiem jest mapa gęstości, do której dopasowuje się model atomowy.

Must know

Hasło	Znaczenie
Rozdzielczość	Poziom szczegółowości danych eksperymentalnych.
pLDDT	Lokalna miara ufności modelu AlphaFold.
PAE	Niepewność wzajemnego położenia regionów/domen.
RMSD	Miara różnicy po nałożeniu struktur.
Ligand	Cząsteczka związana z białkiem.

Pułapka: Wysoki pLDDT lokalny nie gwarantuje poprawnej orientacji domen.

9. Uczenie maszynowe w proteomice

Dlaczego ML: Dane proteomiczne są duże, złożone i wielowymiarowe. ML automatyzuje wykrywanie wzorców i predykcję na podstawie danych uczących.

Uczenie nadzorowane: Model uczy się na przykładach z etykietami. Zastosowania obejmują klasyfikację funkcji, lokalizacji, interakcji i stanów chorobowych.

Uczenie nienadzorowane: Bez gotowych etykiet odkrywa grupy i strukturę danych, np. klastry profili ekspresji lub białek o podobnych cechach.

Deep learning: Sieci neuronowe uczą się złożonych reprezentacji sekwencji i struktur. Podręcznik przywołuje AlphaFold, PIPR i DeepGO jako przykłady.

Must know

Hasło	Znaczenie
Cecha	Zmienna wejściowa opisująca obiekt.
Etykieta	Znany wynik używany w uczeniu nadzorowanym.
Trening/walidacja/test	Rozdzielenie danych do uczenia, strojenia i oceny.

Overfitting	Dobre dopasowanie do treningu, słaba generalizacja.
Predykcja	Wynik modelu wymagający oceny ufności i walidacji.

Pułapka: Predykcja ML nie jest dowodem eksperymentalnym.

10. Wizualizacja danych proteomicznych

Rola wizualizacji: Wizualizacja upraszcza interpretację tysięcy pomiarów, ujawnia wzorce, anomalie, grupowanie i zależności między próbkami lub białkami.

Barplot i boxplot: Barplot pokazuje porównanie wartości, a boxplot rozkład, medianę i obserwacje odstające.

Scatter i MA plot: Scatter pokazuje zależność dwóch zmiennych. MA plot przedstawia różnicę logarymiczną względem średniego sygnału.

Volcano plot: Łączy wielkość zmiany, zwykle $\log_2$ fold change, z istotnością statystyczną. Pomaga wskazać białka silnie i istotnie zmienione.

Must know

Hasło	Znaczenie
$\log_2$FC	Wielkość względnej zmiany na skali $\log_2$.
p-value/FDR	Miara istotności i korekta wielokrotnych testów.
PCA	Redukcja wymiarów i wizualizacja zmienności.
Clustering	Grupowanie podobnych próbek lub białek.
MSA	Dopasowanie wielu sekwencji homologicznych.

Pułapka: Volcano plot bez progów i informacji o korekcie wielokrotnych testów może być mylący.

11. Integracja proteomiki z NGS

Biologia systemów: Integracja łączy dane genomowe, transkryptomiczne, proteomiczne i inne omiki, aby uzyskać pełniejszy obraz regulacji komórkowej.

RNA a białko: RNA-Seq mierzy transkrypty, a proteomika produkty białkowe, PTM i lokalizację. Korelacja jest często umiarkowana, ponieważ translacja, degradacja i stabilność białek podlegają dodatkowej regulacji.

Warianty i izoformy: RNA-Seq ujawnia alternatywny splicing i mutacje, a proteomika może próbować potwierdzać odpowiednie peptydy wariantowe lub izoformy.

Proteogenomika: Buduje spersonalizowane bazy sekwencji na podstawie danych NGS, a następnie wykorzystuje je do przeszukiwania widm MS.

Must know

Hasło	Znaczenie
RNA-Seq	Pomiar i charakterystyka transkryptów.
Proteogenomika	Wykorzystanie genomu/transkryptomu do interpretacji danych MS.
Neoantygen	Peptyd wynikający m.in. z wariantu somatycznego, potencjalnie rozpoznawany immunologicznie.

Mapowanie ID	Łączenie odpowiadających sobie genów, transkryptów i białek.
Multi-omics	Integracja wielu warstw molekularnych.

Pułapka: Brak korelacji RNA-białko nie oznacza błędu - może odzwierciedlać regulację potranslacyjną.

12. Dalsza nauka i rozwój

Ciągłość nauki: Proteomika i bioinformatyka szybko się zmieniają, dlatego rozwój wymaga regularnej pracy z kursami, dokumentacją, otwartymi danymi i literaturą.

Platformy: Podręcznik wskazuje m.in. Courserę, edX, EMBL-EBI Training, Galaxy Training Network i materiały ELIXIR.

Praktyka: Galaxy, UniProt, PRIDE/ProteomeXchange, STRING/BioGRID/IntAct i AlphaFold DB pozwalają ćwiczyć na rzeczywistych danych oraz dokumentacji.

Konferencje i warsztaty: Wymieniono HUPO, wydarzenia EMBO/EMBL, CPTAC Workshops oraz wydarzenia ELIXIR i programy dla początkujących.

Must know

Hasło	Znaczenie
Ścieżka narzędziowa	Nauka konkretnych pipeline'ów i formatów.
Ścieżka analityczna	Statystyka, R/Python i wizualizacja.
Ścieżka biologiczna	Interpretacja funkcji, szlaków, PTM i interakcji.
Ścieżka strukturalna	PDB, Cryo-EM, AlphaFold, ChimeraX/PyMOL.

Pułapka: Dokumentacja narzędzia może zmieniać się szybciej niż podręcznik - przy praktyce należy sprawdzać wersję.

Formaty, bazy i narzędzia - macierz

Hasło	Znaczenie
UniProt	sekwencja, funkcja, PTM, izoformy, kompleksy
PRIDE/MassIVE	publiczne dane spektrometrii mas
PhosphoSitePlus/dbPTM	modyfikacje potranslacyjne
STRING/BioGRID/IntAct	interakcje białkowe
HPA/PaxDb	lokalizacja, tkanki, abundancja
PDB/EMDB/AlphaFold DB	model eksperymentalny / mapa EM / predykcja
ProteoWizard	konwersja RAW → mzML
MaxQuant	identyfikacja i kwantyfikacja RAW; Andromeda
FragPipe/MSFragger	szybkie przeszukiwanie i kwantyfikacja
Skyline	analizy celowane i chromatogramy
Cytoscape	sieci biologiczne
PyMOL/ChimeraX	wizualizacja i porównanie struktur

20 pytań szybkiej powtórki

1. Co odróżnia proteom od genomu?
2. Jakie są cztery poziomy struktury białka?
3. Czym różni się enzym od dowolnego białka?
4. Do czego służą UniProt, PRIDE i STRING?
5. Dlaczego mzML jest ważny?
6. Jaką rolę pełni FASTA?
7. Co daje trawienie trypsyną?
8. Czym jest widmo MS/MS?
9. Dlaczego istnieje problem inferencji białek?
10. Co kontroluje FDR?
11. Czym różni się TMT od label-free?
12. Jak uzyskuje się kwantyfikację bezwzględną?
13. Dlaczego PTM bywają trudne do wykrycia?
14. Co oznacza lokalizacja PTM?
15. Czym są hub i moduł w sieci?
16. Jakie są mocne strony Cryo-EM?
17. Co oznacza niski pLDDT?
18. Dlaczego predykcja ML wymaga walidacji?
19. Jak czytać volcano plot i PCA?
20. Dlaczego RNA i białko mogą słabo korelować?