

BIOINFORMATYKA W PROTEOMICE

Zestaw zadań do wykonania

20 zadań kursowych + 3 warianty zadania projektowego

Opracowano na podstawie podręcznika „Bioinformatyka w proteomice”, wersja 2025/26_2.

Jak korzystać z zestawu

Dokument porządkuje treść zadań z podręcznika w kolejności kursu. Nie zawiera rozwiązań. Przy każdym zadaniu dodano krótką listę elementów, które warto zachować w sprawozdaniu, oraz miejsce na notatki.

Spis zadań

- 1-2. UniProt: podstawowe informacje o białkach
- 3. Eksploracja baz proteomicznych na przykładzie TP53
- 4-5. Struktury p53 w PDB i EMDB
- 6-7. Identyfikacja białek i trawienie trypsyną
- 8-9. Kwantyfikacja LFQ i log2 fold change
- 10. Fosforylacje EGFR
- 11-12. Sieć interakcji TP53 w STRING
- 13-14. Predykcja i porównanie struktury O14717
- 15-16. Predykcja funkcji i lokalizacji białek rybosomalnych
- 17-19. MSA, drzewo i WebLogo
- 20. Integracja ekspresji RNA i białka TP53
- Projekty 1-3. Analiza ewolucyjna, ML oraz kompleksowa charakterystyka białka

Rozdział 1. Podstawy białek i proteomiki

Zadanie 1. Porównanie insuliny, hemoglobiny i lizozymu

Narzędzia / zasoby: UniProt

W bazie UniProt wyszukaj następujące białka:

- Insulina (insulin, human)
- Hemoglobina (hemoglobin subunit beta, human)
- Lizozym (lysozyme C, human)

Dla każdego białka zbierz w tabeli porównawczej: nazwę białka, ID UniProt, sekwencję, masę molekularną (Mass w Da), funkcję oraz informację, czy białko występuje w kompleksie („Complex viewer”).

Białko	UniProt ID	Sekwencja	Masa [Da]	Funkcja	Kompleks?	Uwagi
Insulina						
Hemoglobina β						
Lizozym C						

Do oddania / sprawdzenia:

- ☐ Tabela porównawcza dla trzech białek
- ☐ Źródło danych: UniProt
- ☐ Sprawdzone pole „Complex viewer”

Zadanie 2. Analiza wariantów, mostków disiarczkowych i numeru EC

Narzędzia / zasoby: UniProt

1. Jaka mutacja w ludzkiej hemoglobinie powoduje odporność na malarię? Podaj numer pozycji w sekwencji oraz aminokwas, na który następuje podstawienie. Wskazówka: zakładka „Disease & Variants”.
2. Podaj numery cystein odpowiedzialnych za tworzenie mostków disiarczkowych pomiędzy łańcuchami A i B insuliny. Wskazówka: zakładka „PTM/Processing”.
3. Podaj numer EC lizozymu. Wyjaśnij, czym jest numer EC i dlaczego insulina oraz hemoglobina go nie mają.

Miejsce na odpowiedź / notatki

Rozdział 2. Bioinformatyczne bazy danych białkowych

Zadanie 3. Eksploracja baz danych na przykładzie białka p53

Narzędzia / zasoby: PRIDE Archive, PhosphoSitePlus, Human Protein Atlas, PaxDb

W każdej z poniższych baz wyszukaj ludzkie białko p53 (TP53) i wykonaj polecenia.

A. PRIDE Archive

- Wejdź do PRIDE Archive i wyszukaj TP53 (p53), Homo sapiens.
- Wybierz jeden projekt (dataset), w którym występuje TP53.
- Podaj identyfikator projektu.
- Opisz cel eksperymentu.
- Wskaż dostępne dane, np. surowe dane MS, identyfikacje peptydów i pliki wynikowe.

B. PhosphoSitePlus

- Wyszukaj TP53 (Homo sapiens).
- Na grafie białka zlokalizuj aminokwas K120 (lizyna 120).
- Zidentyfikuj oznaczone w tym miejscu modyfikacje potranslacyjne.

C. Human Protein Atlas

- Wyszukaj TP53.
- Określ, w jakiej części komórki zlokalizowane jest białko p53.
- Wskaż tkanki, w których obserwuje się jego najwyższy poziom ekspresji.

D. PaxDb

- Wyszukaj „TP53 Homo sapiens”.
- Sprawdź, czy dostępne są ilościowe dane o poziomie TP53.
- Wskaż tkanki z największą abundancją; posortuj tabelę „TP53 abundance information”.

Do oddania / sprawdzenia:

- ☐ Opis jednego datasetu PRIDE
- ☐ Modyfikacje K120
- ☐ Lokalizacja komórkowa i tkankowa
- ☐ Abundancja TP53 w PaxDb

Rozdział 3. Formaty danych i struktury białek

Zadanie 4. Struktura przestrzenna białka p53

Narzędzia / zasoby: RCSB Protein Data Bank; PDB ID: 3KMD

4. Otwórz strukturę 3KMD w widoku 3D.
5. Ustal metodę wyznaczenia struktury (np. NMR lub X-ray).
6. Policz łańcuchy białkowe i określ typ kompleksu (np. dimer, tetramer).

7. Sprawdź, czy w strukturze obecne są DNA lub inne ligandy.
8. Określ dominujące elementy struktury drugorzędowej: alfa-helisy czy beta-harmonijki.

Dla własnej eksploracji: kliknij cząsteczkę DNA i przeanalizuj oddziaływania zasad azotowych z aminokwasami p53.

Miejsce na odpowiedź / notatki

Zadanie 5. Kompleks p53 z nukleosomem w cryo-EM

Narzędzia / zasoby: EMDB: EMD-33533; PDB: 7XZX

- W EMDB wyszukaj EMD-33533.
- Obejrzyj galerię i opisz typy widocznych wizualizacji.
- Oceń, czy obraz cryo-EM pozwala dokładnie zobaczyć cząsteczkę.
- Wyjaśnij, czy do rozpoznania elementów strukturalnych potrzebny jest dopasowany model.
- W widoku 3D spróbuj odnaleźć fragment odpowiadający kompleksowi p53-DNA.
- Otwórz dopasowany model 7XZX w PDB.
- W zakładce „Macromolecules” sprawdź typy podjednostek histonowych i liczbę kopii każdej z nich.

Do oddania / sprawdzenia:

- ☐ Zrzut ekranu z EMDB/PDB
- ☐ Opis jakości mapy cryo-EM
- ☐ Lista podjednostek histonowych

Rozdział 4. Identyfikacja białek

Zadanie 6. Opis identyfikacji białka za pomocą spektrometrii mas

W kilku zdaniach opisz, jak spektrometria mas pozwala zidentyfikować białko w próbce biologicznej. Uwzględnij pojęcia:

- trypsyna - enzym rozcinający białka na krótsze peptydy
- masa cząsteczkowa peptydu (m/z)
- widmo MS/MS - fragmentacja peptydu
- baza danych sekwencji, np. UniProt

Miejsce na odpowiedź / notatki

Zadanie 7. Trawienie p53 i identyfikacja PTM

Narzędzia / zasoby: PeptideCutter; PhosphoSitePlus; UniProt ID P04637

9. W PeptideCutter sprawdź, na ile fragmentów trypsyna podzieliłaby ludzkie białko p53 (P04637).
10. W PhosphoSitePlus wyszukaj p53 i wypisz opisane modyfikacje potranslacyjne, np. fosforylację, acetylację i ubikwitynację.
11. Wyjaśnij, skąd pochodzą te dane i jaką rolę w ich identyfikacji odgrywa spektrometria mas.

Miejsce na odpowiedź / notatki

Rozdział 5. Kwantyfikacja białek

Zadanie 8. Interpretacja log2 fold change w metodzie LFQ

W Label-Free Quantification ilość białek porównuje się na podstawie intensywności sygnałów peptydów w spektrometrii mas, bez znaczników izotopowych. Znormalizowaną zmianę można wyrazić jako log2 fold change: $\log_2(\text{leczenie}/\text{kontrola})$.

12. Co oznacza $\log_2\text{FC} = 0$?
13. Co oznacza $\log_2\text{FC} = +2$ oraz $\log_2\text{FC} = -1$?
14. Jakie mogą być biologiczne przyczyny wzrostu lub spadku ekspresji białka po leczeniu?

Miejsce na odpowiedź / notatki

Zadanie 9. Obliczenia LFQ i wykres zmian ekspresji

Narzędzia / zasoby: Kalkulator / arkusz kalkulacyjny

Białko	Ctrl_1	Ctrl_2	Drug_1	Drug_2
A	100	120	400	420
B	200	180	100	90
C	50	55	52	54
D	80	82	160	170
E	500	480	125	130

15. Oblicz średnią intensywność każdego białka w kontroli i po leczeniu.
16. Oblicz $\log_2$ fold change = $\log_2(\text{leczenie}/\text{kontrola})$.
17. Oznacz białka regulowane w górę ($\log_2\text{FC} > 0$) i w dół ($\log_2\text{FC} < 0$).
18. Narysuj prosty wykres słupkowy zmian ekspresji.

Do oddania / sprawdzenia:

- ☐ Tabela obliczeń
- ☐ Klasyfikacja up/down
- ☐ Wykres słupkowy

Rozdział 6. Modyfikacje potranslacyjne

Zadanie 10. Fosforylacje EGFR

Narzędzia / zasoby: UniProt P00533; PhosphoSitePlus

UniProt

- Otwórz rekord P00533 (EGFR, Homo sapiens).
- Przejdź do „PTM / Processing”.
- Sprawdź, czy opisano fosforylacje i wypisz ich pozycje.

PhosphoSitePlus

- Wyszukaj „EGFR_HUMAN”.
- Sprawdź, czy są dane o fosforylacjach.
- Podaj liczbę pozycji, aminokwasy i miejsca modyfikacji.

Miejsce na odpowiedź / notatki

Rozdział 7. Interakcje i sieci białkowe

Zadanie 11. Budowa sieci interakcji TP53

Narzędzia / zasoby: STRING

19. Otwórz STRING i wyszukaj TP53 dla Homo sapiens.
20. W ustawieniach ustaw minimalny wynik interakcji na „high confidence” (0.700).
21. Pokaż maksymalnie 50 interaktorów pierwszego rzędu lub mniej, gdy sieć jest zbyt rozbudowana.

Do oddania / sprawdzenia:

- ☐ Zrzut sieci
- ☐ Zapisane parametry sieci

Zadanie 12. Eksploracja sieci TP53

Narzędzia / zasoby: STRING

- Zidentyfikuj trzy białka o największej liczbie interakcji (huby).
- Znajdź dwa białka związane z nowotworami, np. BRCA1 lub MDM2.

- Sprawdź, czy w sieci występują moduły funkcjonalne, np. regulacja cyklu komórkowego lub apoptozy.
- Kliknij wybrane białka i sprawdź ich funkcje oraz terminy GO.

Miejsce na odpowiedź / notatki

Rozdział 8. Analiza i predykcja struktury

Zadanie 13. Predykcja struktury O14717

Narzędzia / zasoby: UniProt; AlphaFold Server

22. Pobierz sekwencję białka tRNA (cytosine(38)-C(5))-methyltransferase, UniProt O14717.
23. Wklej sekwencję do serwera AlphaFold i uruchom predykcję.
24. Zapisz wynik w formacie PDB lub CIF.
25. Dołącz zrzut wizualizacji.
26. Zidentyfikuj regiony o niskiej ufności i oceń, czy tworzą strukturę drugorzędową.

Do oddania / sprawdzenia:

- ☐ Plik modelu
- ☐ Zrzut ekranu
- ☐ Opis regionów niskiej ufności

Zadanie 14. Porównanie modelu przewidzianego i eksperymentalnego

Narzędzia / zasoby: PyMOL lub ChimeraX; PDB ID 1G55

27. Otwórz model przewidziany (model0) w PyMOL lub ChimeraX.
28. Sprawdź w UniProt, czy istnieje struktura eksperymentalna; pobierz model 1G55.
29. Nałóż struktury: w PyMOL użyj align, a w ChimeraX narzędzi Structure Analysis i Matchmaker.
30. Na podstawie publikacji źródłowej (DOI 10.1093/nar/29.2.439) omów możliwe przyczyny niskiej ufności w wybranych obszarach.
31. Porównaj te obszary ze strukturą eksperymentalną i poziomami ufności predykcji.

Miejsce na odpowiedź / notatki

Rozdział 9. Uczenie maszynowe w proteomice

Zadanie 15. Predykcja funkcji i lokalizacji białek rybosomalnych

Narzędzia / zasoby: UniProt/PDB; DeepGOPlus lub PANNZER2; DeepLoc 2.0; opcjonalnie AlphaFold/ColabFold

32. Wybierz trzy białka rybosomalne z ludzkiego kompleksu 80S, np. RPL3, RPS6, RPL13A lub RPS27A.
33. Dla każdego pobierz sekwencję FASTA.
34. Przewidź funkcję za pomocą DeepGOPlus lub PANNZER2.
35. Przewidź lokalizację komórkową za pomocą DeepLoc 2.0.
36. Opcjonalnie przewidź strukturę 3D za pomocą AlphaFold lub ColabFold.

Do oddania / sprawdzenia:

- ☐ Trzy sekwencje FASTA
- ☐ Wyniki funkcji
- ☐ Wyniki lokalizacji
- ☐ Opcjonalne modele 3D

Zadanie 16. Podsumowanie wyników ML dla białek rybosomalnych

- Porównaj przewidziane funkcje z adnotacjami UniProt.
- Oceń, czy przewidziana lokalizacja ma sens w kontekście rybosomu.

Miejsce na odpowiedź / notatki

Rozdział 10. Wizualizacja i analiza ewolucyjna

Zadanie 17. Wielokrotne wyrównanie sekwencji (MSA)

Narzędzia / zasoby: MAFFT

W MAFFT wklej poniższe sekwencje FASTA. Możesz pozostawić ustawienia domyślne albo wybrać L-INS-i. Po obliczeniu pobierz MSA i otwórz „Start MSA Viewer”.

```
>Seq_A
MKTAIIGKGGIGRNPTVEVDLSTAGTEAMALKLSDNGIKVVVSEQHGPEFVDITGDA
FLKQPKNVIFADKTYERGLTPEQIRAAVHAAAKRGDCPVILVGNKCDLPQQPPPPQ
PQPARSGAVGAIVKVRGTPLSE
>Seq_B
MKTAIIGKGGIGRNPTVEVDLSTAGTEAMAFKLSNGIKVVVSEQYGPEFVDITGDT
FLKQPENNVIFADKTYERGLTPEQIKAAHGAASKRGDCPVILVGNKCDLPQQPPQQPQ
PQPAKSGAVGAIVKVRGTPL
>Seq_C
MKTAIIGKGGIGRNPTVEVDLSTPGSEAWALKISDNGVKVVVSEQHGPEFVDITGDA
FLKQPKNVIFADKTAERGLTPEQVQKAIHPATNRGDCPVILVGNKCDLAGGGSSGGG
GSTRNGAMGAIVKAKGSALEGH
>Seq_D
```

```

MKTAIIGKGGIGRNPTVEVDLSTPGSDFNWGFRVHDSGIRMVISQTHGPEFVDITGNP
YLKQAEVIFADKTSDKGLTCEQLHDSLFGVNGQDCPVILVGNKCDLSEEEDEKED
EDSRPGTLGALLKPRGTYFDSHIM
>Seq_E
MKTAIIGKGGIGRNPTVEVDLSTNGVQYPWSLTIQDPGVSMVITQPHGPEFVDITGEP
WLKQSDNVIFADKTSTKGLASDQFYDALGSGINSQDCPVILVGNKCDLPNNNNSTNSN
NTTRSGTYGAMVQPKGDFWQAHVPK
>Seq_F
MKTAIIGKGGIGRNPTVEVDLSTSGVDAFALHLDTPGVKVVVSQQHGPEFVDITGDS
YLKQPDNVIFADKTSEGLTPQQISAALNSAVKRGDCPVILVGNKCDLPKKRKKRKRK
KRPAGAVGAMVKVKGSPQLQE
>Seq_G
MKTAIIGKGGIGRNPTVEVDLSTPGAQDFWLSLIDDRGVSIVISETHGPEFVDITGQP
FLKQTKNVIFADKTAQKGLSAEQMQDVIHSGTTRGDCPVILVGNKCDLPTTTTATATV
TSTRQGSGLGALIKSQGAWLDGH

```

- Wskaż regiony konserwatywne o małej zmienności i podaj przybliżone zakresy pozycji w MSA.
- Wskaż regiony o dużej zmienności i podaj ich zakresy, np. 45-78.

Miejsce na odpowiedź / notatki

Zadanie 18. Drzewo podobieństwa sekwencji

Narzędzia / zasoby: MAFFT; Phylo.io

37. W wynikach MAFFT otwórz zakładkę Tree, pozostaw ustawienia domyślne i kliknij „Go!”.
38. Otwórz wynik w Phylo.io.
39. Wskaż klastry oraz pary lub grupy najbardziej podobnych sekwencji.
40. Sformułuj krótki wniosek o ewolucyjnej lub funkcjonalnej różnorodności analizowanych fragmentów.

Miejsce na odpowiedź / notatki

Zadanie 19. Logo sekwencyjne

Narzędzia / zasoby: WebLogo

41. Pobierz MSA w formacie FASTA i wklej je do WebLogo.
 42. Kliknij „Create Logo” i zapisz obraz do sprawozdania.
 43. Przeanalizuj region około pozycji 60-70: wskaż najwyższe litery i wyjaśnij ich znaczenie dla konserwacji ewolucyjnej.
 44. Porównaj logo z obserwacjami z zadania 17.
- Dla chętnych: napisz skrypt generujący logo z macierzy częstości aminokwasów, np. dla pozycji 10-30.

Do oddania / sprawdzenia:

- ☐ Obraz WebLogo
- ☐ Interpretacja pozycji 60-70

☐ Porównanie z MSA

Rozdział 11. Integracja proteomiki z NGS

Zadanie 20. Korelacja ekspresji RNA i białka TP53 w raku piersi

Narzędzia / zasoby: cBioPortal; TCGA PanCancer Atlas; RPPA

45. Wejdź do cBioPortal i kliknij „Explore”.
 46. Wybierz projekt „Breast Invasive Carcinoma (TCGA, PanCancer Atlas)”.
 47. Wyszukaj gen TP53.
 48. Otwórz zakładkę „Plots”.
 49. Ustaw oś X: TP53 mRNA Expression (RNA Seq V2 RSEM).
 50. Ustaw oś Y: TP53 Protein Expression (RPPA).
- Czy istnieje korelacja między RNA i białkiem TP53? Odnieś się do współczynników Spearmana i Pearsona.
 - Podaj proste przyczyny, dla których poziom RNA i białka nie zawsze jest identyczny.

Do oddania / sprawdzenia:

- ☐ Wykres rozrzutu
- ☐ Wartości korelacji
- ☐ Interpretacja biologiczna

Zadania projektowe

Wybierz jeden wariant projektu. Zadania mają charakter otwarty. Odpowiedź na każdy punkt nie powinna przekraczać jednej strony A4. Raport końcowy ma mieć format PDF.

Projekt 1. Konserwacja sekwencji i funkcji enzymu

Cel: zrozumienie, jak porównanie homologicznych sekwencji ujawnia ewolucyjną konserwację kluczowych elementów strukturalnych i funkcjonalnych białek enzymatycznych.

51. Wybierz ludzkie białko enzymatyczne, np. MAPK1, CDK2, LDHA, ENO1 lub GAPDH.
52. Znajdź rekord UniProt i zapisz ID. W sekcji Function odszukaj reszty centrum aktywnego, motywy katalityczne i znane PTM.
53. Zbierz około 8-12 homologicznych sekwencji z różnych gatunków przy użyciu UniProt lub BLAST. Zapisz je w FASTA z nazwami gatunków w nagłówkach.
54. Wykonaj MSA w MAFFT lub Clustal Omega. Umieść sekwencję ludzką jako pierwszą i zaznacz pozycje centrum aktywnego oraz motywów katalitycznych.
55. Oceń konserwację reszt centrum aktywnego i wskaż regiony silnie zmienne, delecje i insercje. Sprawdź związek regionów zmiennych z pętlami regulatorowymi lub domenami.
56. Nanieś PTM z UniProt lub PhosphoSitePlus na MSA. Oceń ich konserwację i położenie względem centrum aktywnego; opcjonalnie zwizualizuj w PyMOL, Chimera lub przeglądarce PDB.
57. Dołącz MSA z zaznaczeniami, tabelę ważnych reszt oraz interpretację do 400 słów.

Pozycja UniProt	Funkcja reszty	Konserwacja (tak/nie)	Uwagi

- Czy centrum aktywne jest silnie konserwowane?
- Czy PTM mogą regulować aktywność enzymu ze względu na położenie?
- Jakie wnioski wynikają z ewolucyjnej stabilności i regulacji białka?

Projekt 2. Predykcja funkcji, lokalizacji i struktury za pomocą ML

Cel: poznanie możliwości narzędzi machine learningowych i porównanie ich predykcji z danymi eksperymentalnymi.

58. Wybierz trzy dobrze opisane ludzkie białka i zanotuj ich ID UniProt oraz krótką charakterystykę.
59. Przewidź lokalizację każdego białka w DeepLoc 2.0. Zapisz lokalizacje i prawdopodobieństwa.
60. Przewidź funkcje w DeepGOPlus i zapisz terminy GO: procesy biologiczne, funkcje molekularne i lokalizacje komórkowe.
61. Uzyskaj modele 3D w AlphaFold lub ColabFold. Gdy istnieje struktura PDB, porównaj domeny i regiony aktywne.

62. Porównaj predykcje z UniProt i innymi bazami. Oceń zgodność z danymi eksperymentalnymi oraz ewentualne dodatkowe sugestie modeli.
63. Przygotuj tabelę lub raport do 400 słów.

Białko	UniProt: funkcja	DeepLoc	DeepGOPlus	AlphaFold	Uwagi / różnice

Projekt 3. Kompleksowa charakterystyka ludzkiego białka

Cel: kompleksowa charakterystyka wybranego białka z wykorzystaniem zintegrowanych metod bioinformatycznych i proteomicznych.

64. Wybierz ludzkie białko globularne lub błonowe, inne niż we wcześniejszych zadaniach, z eksperymentalną strukturą 3D obejmującą co najmniej 70% sekwencji. Białko musi mieć znaczenie medyczne i dostępne dane MS. Przedstaw sekwencję, parametry fizykochemiczne i motywację wyboru.
65. Wykonaj własną predykcję w AlphaFold Server, a następnie nałóż ją w ChimeraX na model eksperymentalny. Omów różnice, ufność i możliwe przyczyny rozbieżności.
66. Przeprowadź analizę interaktomu. Przedstaw wynik jako sieć i krótko skomentuj.
67. Ustal komórki i tkanki ekspresji. Wyszukaj dane MS, najlepiej zdrowie vs choroba, i przedstaw je graficznie.
68. Przewidź funkcję i lokalizację komórkową poznanymi narzędziami, a następnie porównaj z danymi eksperymentalnymi.

Do oddania / sprawdzenia:

- ☐ Sekwencja i parametry białka
- ☐ Model AlphaFold i porównanie z eksperymentem
- ☐ Sieć interakcji
- ☐ Wizualizacja ekspresji MS
- ☐ Porównanie predykcji z eksperymentem

Końcowa lista kontrolna

- Każdy wykres i zrzut ekranu ma podpis oraz wskazane źródło.
- Wyniki zawierają identyfikatory białek, projektów i struktur.
- W obliczeniach podano wzór i jednostki.
- Wnioski oddzielają obserwację od interpretacji.
- Raport projektowy zapisano jako PDF.